

ASP: una skill operativa de pre-mortem para agentes de programación con LLM

Un informe de experiencia

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Fecha: 7 de noviembre de 2026

Abstract

LLM coding assistants often produce *locally correct* code that omits failure modes a senior engineer would surface in a pre-mortem — a row-level security policy, an external API's rate limit, replica lag during a migration — and production then breaks in ways that are expensive to debug. We call these missing items *shadow points*. This experience report describes Anticipating Shadow Points (ASP), a 13-phase planning protocol shipped as a Claude Code skill that integrates Klein's (2007) pre-mortem with the multi-agent failure taxonomy of Cemri et al. (2025), checks the plan with a validator that does not share the planner's context, following the self-correction-limit literature (Huang et al., 2024; Tyen et al., 2024), and hands execution to a child subprocess with a file-based contract. We document the design, its deployment as an open-source plugin, and preliminary observations from five engineering evaluations, read by the author without blinding and with transcripts not preserved. A deterministic adjudicator ships with the skill; its scores on author-written fixtures exercise the instrument and nothing more, so we report no measured effect of ASP. We state in advance the result that would show one: in a real-mode benchmark with blind, independently written expected lists and eight replicates per task and condition, a measured benefit if the assisted condition's mean coverage beats the unassisted one on all five tasks and a one-sided, task-stratified permutation test gives $p < 0.05$; no measurable benefit if it fails on three or more; inconclusive otherwise; incomplete if the budget stops collection early. The protocol is drafted and not yet deposited.

Keywords: llm coding agents; pre-mortem; multi-agent failure modes; claude code; operational protocols; experience report :::

Whitepaper · Versión 2.1 · 2026-11 *(publicado por primera vez el 2026-05-18)*

DOI https://doi.org/10.5281/zenodo.20276631 *(concepto · resuelve a la última versión depositada)*

Estado Whitepaper técnico independiente · sin revisión por pares

Licencia Texto, figuras y datos del artículo — CC BY 4.0 · Software complementario — MIT

Replicación Todo número que las Secciones 5.3–5.4 calculan a partir de los datos y los fixtures del repositorio se recalcula con python run_all.py en el repositorio complementario y lo verifica una prueba; véase el Apéndice B.

Repositorio complementario Flores, C. U. (2026a), https://github.com/ulissesflores/anticipating-shadow-points

Whitepaper complementario Flores, C. U. (2026c). *Graceful Refusals as Unsignalled Failures: Characterising claude -p Exit-Code Semantics on Agent Declines.* Véase paper/graceful-refusals.md.

Resumen

Los asistentes de código basados en LLM a menudo producen código *localmente correcto* que omite modos de fallo que un ingeniero sénior plantearía en un pre-mortem —una política de seguridad por fila, el límite de tasa de una API externa, el retraso de réplica durante una migración— y la producción falla entonces de formas costosas de depurar. Llamamos *shadow points* a esos elementos ausentes. Este informe de experiencia describe Anticipating Shadow Points (ASP), un protocolo de planificación de 13 fases distribuido como skill de Claude Code que integra el pre-mortem de Klein (2007) con la taxonomía de fallos multiagente de Cemri et al. (2025), revisa el plan con un validador que no comparte el contexto del planificador, siguiendo la literatura sobre los límites de la autocorrección (Huang et al., 2024; Tyen et al., 2024), y entrega la ejecución a un subproceso hijo con un contrato en archivos. Documentamos el diseño, su despliegue como plugin de código abierto y observaciones preliminares de cinco evaluaciones de ingeniería, leídas por el autor sin cegamiento y sin transcripciones conservadas. Un adjudicador determinista acompaña la skill; sus puntuaciones sobre fixtures escritos por el autor ejercitan el instrumento y nada más, por lo que no informamos ningún efecto medido de ASP. Fijamos de antemano el resultado que lo mostraría: en un benchmark en modo real, con listas esperadas ciegas escritas por revisores independientes y ocho réplicas por tarea y condición, un beneficio medido si la cobertura media de la condición asistida supera a la no asistida en las cinco tareas y una prueba de permutación unilateral, estratificada por tarea, da $p < 0{,}05$; ningún beneficio medible si no la supera en tres o más; inconcluso en los demás casos; incompleto si el presupuesto detiene la recogida antes de tiempo. El protocolo está redactado y aún no se ha depositado.

Palabras clave: agentes de programación con llm; pre-mortem; modos de fallo multiagente; claude code; protocolos operativos; informe de experiencia

1. Introducción

Los equipos de software delegan cada vez más en asistentes de programación con IA el trabajo rutinario de ingeniería: añadir una columna a una base de datos de producción, desplegar una función que llama a una API externa, refactorizar una utilidad usada en treinta archivos. Cuando el asistente acierta, el día del ingeniero queda libre. Cuando se equivoca de forma *sutil* —escribiendo código que compila, pasa sus pruebas y se despliega, pero omite en silencio un paso que un ingeniero sénior habría señalado de antemano—, la producción se rompe de formas costosas de depurar. La ciencia de la decisión tiene una técnica para justo esa brecha, el pre-mortem (Klein, 2007), y la investigación sobre agentes dispone ahora de un catálogo de cómo fallan los sistemas multiagente basados en LLM (Cemri et al., 2025). Nuestra tesis es que ambos pertenecen juntos en tiempo de ejecución: antes de escribir código, debe obligarse al agente a ejecutar un pre-mortem frente a una taxonomía de fallos fija, y su plan debe ser revisado por un validador que no pueda ver el razonamiento del planificador.

El modo de fallo de producción dominante de los agentes de programación con LLM modernos no es, en nuestra experiencia, el código *malo*. Es el código *incompleto*: el agente hace lo que se le pidió, pero no lo que alguien con un contexto profundo del dominio se habría preguntado *antes de empezar*. El retraso de réplica durante una migración de esquema. La cabecera CORS de la función en el edge. La política de seguridad a nivel de fila que hay que actualizar para que coincida con la nueva columna. Llamamos **shadow points** a estos elementos ausentes: modos de fallo evidentes para un profesional al que ya le han quemado, e invisibles para un agente al que no.

Dos corrientes de la literatura convergen en esta brecha. La primera, en la ciencia de la decisión, es el **pre-mortem**: un ejercicio estructurado en el que un equipo imagina que un proyecto ya ha fracasado y enumera las causas antes de actuar. La técnica fue operacionalizada para equipos de

proyecto por Klein (2007) y se apoya en el trabajo empírico anterior de Mitchell, Russo y Pennington (1989) sobre la retrospectiva prospectiva (prospective hindsight); Klein (2007) la resume como un aumento de alrededor del 30% en la capacidad de identificar las razones de un resultado futuro, una cifra que no pudimos rederivar a partir del artículo de 1989 (Apéndice A). La segunda, en la investigación sobre agentes, es la reciente caracterización de los modos de fallo multiagente de Cemri et al. (2025), quienes derivaron una taxonomía de 14 modos a partir de 150 trazas semilla de sistemas multiagente basados en LLM (acuerdo entre anotadores κ=0,88) y publicaron un corpus de más de 1.600 trazas anotadas. Ninguna de las dos corrientes se ha integrado como una **disciplina de tiempo de ejecución** que se pueda obligar a seguir a un agente de programación en toda tarea no trivial.

Este artículo informa sobre **Anticipating Shadow Points (ASP)**, un protocolo de planificación de 13 fases distribuido como skill de Claude Code que combina el razonamiento de pre-mortem con la lista de verificación de 14 modos de MAST, separa la planificación de la validación bajo un aislamiento estricto de prompts y entrega la ejecución a un subproceso hijo con un contrato basado en archivos. Desplegamos la skill, la distribuimos por tres vías de instalación (marketplace de plugins, modo desarrollador, script independiente), la sometimos a cinco evaluaciones de ingeniería e informamos del diseño y de lo que las evaluaciones pueden y no pueden mostrar. La evaluación es preliminar y, tal como se corrige en esta versión, no medida: GREEN en cinco tareas y RED en tres, un despacho cada uno, un solo modelo, leída por el autor sin cegamiento, con las transcripciones en bruto no conservadas. La informamos como observación cualitativa; las cinco decisiones de diseño que tratamos como hipótesis están en la Sección 6.

1.1. Contribuciones

Este informe de experiencia aporta:

1. **El protocolo ASP como diseño documentado** — trece fases, cada una de las cuales emite un artefacto con nombre, organizadas en torno al principio de que ninguna implementación comienza antes de que se hayan sacado a la luz los shadow points.
2. **Doce restricciones operativas que llamamos "Iron Laws"**, cada una vinculada a una fuente primaria de la literatura o a una decisión de diseño documentada. Dos tienen una comprobación a nivel de shell en la plantilla ejecutora que se le dice al agente que ejecute (la salida JSON obligatoria de la Iron Law 12 y la bandera ASP_IN_GOAL de la Iron Law 9, definida para el hijo, cuya comprobación de entrada es un fragmento de Bash que la skill indica al agente que ejecute); las otras diez son instrucciones a nivel de prompt.
3. **Observaciones preliminares y cualitativas** de cinco evaluaciones de ingeniería, y un adjudicador determinista con procedencia criptográfica, ejercitado sobre fixtures construidos y listo para puntuar transcripciones reales sin depender de la adjudicación del autor (las listas esperadas siguen siendo del autor, y el sidecar opcional de sinónimos no se proporciona para ninguna tarea).
4. **Un hallazgo empírico aparte** sobre la semántica del código de salida de claude -p ante el rechazo cortés de un agente, caracterizado en el artículo complementario Flores (2026c). El hallazgo motivó dos de las Iron Laws, pero merece una caracterización independiente con un N mayor.

Este es un **informe de experiencia** en el sentido de los sistemas, no un artículo de benchmark. Documentamos un sistema que construimos, una metodología que desplegamos y lo que observamos; no afirmamos una contribución empírica sólida a la literatura de benchmarks de agentes LLM. La Sección 7 enumera en detalle las amenazas a la validez.

2. Antecedentes

Repasamos cuatro líneas de trabajo previo reciente que informan directamente el diseño de ASP (§§2.1–2.4) y luego situamos a ASP dentro de las disciplinas más antiguas de ingeniería de software y de calidad que transpone (§2.5). Mantenemos breve el repaso del trabajo reciente en comparación con los artículos habituales sobre sistemas de agentes, porque la contribución aquí es operativa y el contexto bibliográfico está al servicio de ella.

2.1. Pre-mortem y retrospectiva prospectiva

La técnica del pre-mortem pide a un equipo que imagine, antes de comprometerse, que un proyecto ya ha fracasado de forma catastrófica, y que enumere las causas. La base empírica es Mitchell, Russo y Pennington (1989), quienes mostraron que imaginar un hecho futuro como cierto (en lugar de incierto) produce explicaciones más largas y más episódicas; Klein (2007) resume el efecto como una mejora de alrededor del 30% en la identificación correcta de las razones de un resultado futuro. Klein (2007) operacionalizó el hallazgo como el "pre-mortem" de equipos de proyecto, y desde entonces la técnica se ha extendido por la ciencia de la decisión y la práctica de la gestión de proyectos. Su base experimental es escasa: no encontramos ninguna réplica ni metaanálisis del efecto del pre-mortem en Crossref, arXiv ni en una búsqueda web general (noviembre de 2026), lo que es una ausencia en esos índices, no una prueba de que no exista ninguna. Las normas de evaluación de riesgos catalogan técnicas vecinas —el análisis de escenarios y la técnica estructurada de hipótesis (SWIFT)—, pero el índice de IEC 31010:2019, Anexo B, no menciona el pre-mortem por su nombre. El término *prospective hindsight* también se ha reutilizado para una señal de aprendizaje por refuerzo sin relación (J. Zhang et al., 2026); nosotros lo usamos solo en el sentido de Mitchell et al. No encontramos ninguna integración previa del pre-mortem como disciplina de tiempo de ejecución para agentes de programación.

2.2. Modos de fallo multiagente (MAST)

Los agentes LLM intercalan razonamiento y acción en un único bucle (Yao et al., 2023) y se componen cada vez más en flujos de trabajo multiagente cuyos modos de fallo se acumulan. Cemri et al. (2025) presentan la **Multi-Agent System Failure Taxonomy (MAST)** con **MAST-Data**, un corpus de más de 1.600 trazas anotadas de siete frameworks multiagente populares como AG2 (antes AutoGen; Wu et al., 2023). A partir de un análisis riguroso de 150 trazas semilla (acuerdo entre anotadores κ=0,88), derivaron catorce modos de fallo organizados en tres categorías: especificación y diseño del sistema (5 modos), desalineación entre agentes (6 modos) y verificación y terminación de tareas (3 modos). La lista de 14 modos es el fundamento empírico reciente más sólido para una lista de verificación de modos de fallo; ASP adopta los nombres de los modos literalmente y operacionaliza cada uno en un prompt de pre-mortem más una mitigación en sus archivos de skill complementarios. Dos trabajos concurrentes amplían la línea de la taxonomía: Zhu et al. (2025) presentan AgentDebug y la AgentErrorTaxonomy (memoria / reflexión / planificación / acción / nivel de sistema), y S. Zhang et al. (2025), un Spotlight de ICML 2025, abre la **atribución automatizada de fallos** con el conjunto de datos Who&When. MAST es, por tanto, una taxonomía entre varias: TRAIL formaliza una taxonomía de errores agénticos sobre 148 trazas anotadas por humanos (Deshpande et al., 2025), AgentRx anota 170 trayectorias fallidas con un paso crítico y una categoría de una taxonomía de teoría fundamentada (Barke et al., 2026), y AgenTracer informa de que los LLM de razonamiento actuales atribuyen los fallos en trazas multiagente con una exactitud generalmente inferior al 10% (G. Zhang et al., 2025). ASP usa MAST como biblioteca de prompts para anticipar fallos, no como clasificador de los observados, de modo que la elección de la taxonomía delimita lo que la Fase 2 pregunta y no lo que puede detectar.

2.3. Límites de la autocorrección y aislamiento del validador

El argumento individual más sólido para separar el validador del planificador es el hallazgo convergente de tres trabajos primarios de que los LLM no pueden criticarse a sí mismos de forma fiable bajo un contexto compartido. Huang et al. (2024, ICLR) muestran que la autocorrección intrínseca sin retroalimentación externa a menudo degrada el rendimiento. Tyen et al. (2024) descomponen la autocorrección en localización y corrección y muestran empíricamente que los LLM no pueden *localizar* sus propios errores de razonamiento pero sí corregirlos si se les da la ubicación desde fuera: *la localización es el cuello de botella*. Zheng et al. (2023, NeurIPS D&B) documentan que los jueces LLM potentes favorecen en exceso las salidas de modelos de la misma familia (un "self-enhancement bias") incluso al juzgar objetivamente la calidad. Kamoi et al. (2024) repasan esta literatura y concluyen que la autocorrección fiable de los errores de razonamiento requiere retroalimentación o verificadores externos y no el juicio del modelo sin ayuda; los métodos de autorretroalimentación intrínseca como Self-Refine (Madaan et al., 2023) mejoran algunas tareas de generación pero no cierran la brecha de localización que aíslan Tyen et al. (2024). En conjunto, estos hallazgos sostienen que un validador que comparte contexto con un planificador hereda la calibración de confianza del planificador sobre el contenido compartido, incluido el contenido erróneo del que el planificador está seguro. El diseño de ASP impone un aislamiento estricto de prompts entre planificador y validador (Iron Law 2, más abajo) como contramovimiento arquitectónico. Kambhampati et al. (2024) llegan a la misma conclusión para la planificación: los LLM autorregresivos no pueden planificar ni autoverificarse por sí solos, pero pueden servir como fuentes aproximadas de conocimiento dentro de un bucle "LLM-Modulo" con verificadores externos —el papel que ASP asigna al validador aislado y a las pruebas de aceptación ejecutables.

2.4. El trabajo relacionado más cercano: PreFlect

El trabajo concurrente más cercano es **PreFlect** (Wang et al., 2026), que de forma similar desplaza el paradigma de la autorreflexión de la corrección a posteriori a la crítica previa a la ejecución de los planes del agente, destilando errores de planificación a partir de trayectorias históricas de agentes y añadiendo un mecanismo de replanificación dinámica. La similitud de alto nivel es significativa: tanto ASP como PreFlect identifican como una limitación que la reflexión convencional solo ocurra después de la ejecución, y desplazan la crítica *antes* de la acción. ASP se diferencia de PreFlect en cuatro ejes:

1. **Validador aislado por prompt.** PreFlect destila los errores en la propia crítica previa a la ejecución del agente; ASP impone un subagente validador de prompt separado que nunca ve la transcripción del planificador.
2. **Aislamiento a nivel de proceso para el ejecutor.** ASP lanza el ejecutor como un subproceso claude -p con un contrato basado en archivos; PreFlect opera dentro de un único proceso.
3. **Restricciones explícitas de tiempo de ejecución.** ASP enuncia doce Iron Laws, dos de ellas protegidas por comprobaciones ejecutables y diez como reglas a nivel de prompt; PreFlect se presenta como una metodología y no como un sistema de restricciones.
4. **Un hallazgo empírico a nivel de CLI** que caracteriza la semántica de salida de claude -p ante un rechazo cortés y que motiva dos de las Iron Laws; se informa por separado en Flores (2026c). El fenómeno en sí está documentado por el proveedor y en informes públicos de issues (catalogados en Flores, 2026c, §2); la contribución allí es un recuento medido y una propuesta de contrato de terminación tipado, no un descubrimiento.

2.5. Linaje clásico de la ingeniería de software y de la calidad

Las cuatro líneas anteriores sitúan a ASP dentro de la literatura reciente sobre agentes LLM. Un revisor de ingeniería de software o de calidad reconocerá, sin embargo, la maquinaria de ASP como una transposición de disciplinas que preceden a los LLM en décadas. Hacemos explícito el préstamo, porque ocultarlo sería a la vez deshonesto y más débil: lo nuevo en ASP no son las disciplinas sino su transposición a un entorno de ejecución de agentes no determinista y los mecanismos que las hacen cumplir allí.

No redundancia frente a reverificación defensiva: dónde se aparta ASP del diseño por contrato (Design by Contract). El esquema de micro-TODO de ASP (§3.4) es el diseño por contrato (Meyer, 1992) trasladado de la frontera de la rutina a la frontera de la tarea del agente. El contrato de Meyer reparte obligaciones a través de una frontera llamador/rutina: el llamador debe establecer la PRECONDICIÓN, que la rutina tiene entonces derecho a *asumir* —el principio de no redundancia de Meyer prohíbe que el cuerpo la vuelva a comprobar—, y la rutina debe garantizar la POSTCONDICIÓN en la que se apoya el llamador. De los siete campos del esquema, PRECONDITION, ACTION y POSTCONDITION se corresponden directamente con este contrato, con ACTION como el cuerpo de la rutina que envuelve el par pre/post. ASP se *aparta* entonces de Meyer a propósito: como el obligado es un modelo no determinista y no una rutina compilada, ASP no asume la postcondición, sino que la reverifica con un ACCEPTANCE-TEST externo, y añade un FALSIFICATION-TEST que no tiene análogo en la programación por contrato, importando en cambio la postura popperiana (Popper, 1959/2002) de que una afirmación gana confianza al sobrevivir a un intento de refutación y no solo por una comprobación confirmatoria. Este trueque de la no redundancia del diseño por contrato por la reverificación defensiva responde al mismo ethos de no confiar en nada que produce la disciplina del código de

salida de las Iron Laws 11–12; es una inversión meditada de Meyer, no un descuido. Las Iron Laws, a su vez, se enuncian como el análogo del tercer elemento del contrato en DbC —el invariante de clase— y no como una pre/postcondición por tarea; diez de ellas son instrucciones que se le dice al agente que mantenga, no comprobaciones que se ejecuten.

Enumeración de modos de fallo. La detección de shadow points (Fase 2) es una enumeración prospectiva de modos de fallo en la tradición del FMEA (MIL-STD-1629A, 1980; IEC 60812:2018). Deliberadamente *no* es un FMEA completo: ASP no realiza ninguna descomposición por componente ni puntuación de prioridad de riesgo (gravedad × ocurrencia × detección), de modo que la deuda es con la disciplina de enumeración prospectiva del FMEA, no con su mecánica ascendente. Tres entradas de la Fase 2 ocupan papeles que conviene separar: el pre-mortem (Klein, 2007; §2.1) aporta la *filosofía* —imaginar el fallo como ya cierto—; la taxonomía de catorce modos de MAST (Cemri et al., 2025; §2.2) aporta la *biblioteca* de modos de fallo; y la enumeración forzada frente a esa biblioteca fija se parece más, estructuralmente, al uso de palabras guía al estilo HAZOP (IEC 61882:2016) que al FMEA componente por componente. Lo que ASP añade es el sustrato: el "componente" cuyos modos de fallo se enumeran es un plan de LLM, y la enumeración la ejecuta un validador que no comparte el contexto del planificador (§2.3).

A prueba de errores. Un subconjunto de las Iron Laws (§3.3) son poka-yoke (Shingo, 1986) a nivel de protocolo: la plantilla ejecutora de claude-p-goal-runner.md define ASP_IN_GOAL para el hijo y pasa siempre --output-format json (Iron Laws 9 y 12); el contrato basado en archivos de la Iron Law 10 es una instrucción. Estas comprobaciones viven en una plantilla Bash que se le dice al agente que ejecute, no en un hook fuera del control del agente, y no son la imposibilidad física del poka-yoke auténtico —una variable de entorno puede desactivarse o no propagarse—, y las

demás leyes son honestamente compuertas procedimentales (Iron Laws 1, 2, 4, 5) o reglas de verificación que siguen dependiendo del operador, de las cuales la Iron Law 11 ("nunca confiar en $?") es el caso más claro: precisamente la dependencia de la vigilancia del operador frente a la cual se define el poka-yoke. El préstamo es la *postura* de prevención de errores aplicada a dos comprobaciones a nivel de shell en un script ejecutor que se le indica al agente que emita, no una afirmación de que ASP elimine la vigilancia del operador.

Verificación y validación independientes. El validador aislado por prompt de ASP (Iron Law 2) transpone el movimiento definitorio de la verificación y validación independientes (IV&V; IEEE Std 1012-2016) —un verificador mantenido independiente del desarrollador, en términos de IEEE 1012 técnica, gerencial y financieramente— de la separación organizativa a la separación de *prompts*: el subagente validador no comparte contexto con el planificador al que revisa. La justificación específica de los LLM para ese aislamiento es la literatura sobre autocorrección del §2.3; la *forma* del contramovimiento es la de IV&V.

Vocabulario de la confiabilidad. El comportamiento del código de salida detrás de las Iron Laws 11–12 tiene un nombre exacto en la taxonomía de la confiabilidad: un exit 0 ante un rechazo cortés es un *fallo no señalizado* (Avizienis et al., 2004), ni una caída ni una parada fail-silent. El término, sus antecedentes y la medición se desarrollan en el artículo complementario (Flores, 2026c); esta sección importa solo el vocabulario y no reabre aquí la cuestión de la novedad.

Garantía empírica. La preferencia por pruebas de aceptación y de falsación frente a códigos de estado en los que se confía tiene una base empírica en la patología adyacente. Yuan et al. (2014) encontraron que una gran mayoría de los fallos catastróficos en sistemas distribuidos intensivos en datos se remontan a un manejo defectuoso de errores no fatales que *sí* se señalaron. El caso del código de salida de ASP es el complemento —la señal estaba *ausente*—, de modo que ambos no

comparten una tesis; la estrecha lección que sí comparten es que un canal de estado no es un sustituto del desenlace, que es lo que existe un ACCEPTANCE-TEST externo para hacer cumplir.

Tabla 1 asigna cada mecanismo de ASP a su ancestro clásico y declara lo que ASP añade.

Tabla 1
Mecanismos de ASP y sus ancestros clásicos

Mecanismo de ASP	**Ancestro clásico**	**Lo que ASP añade (y *no* afirma)**
micro-TODO PRE/ACTION/POST + ACCEPTANCE-TEST	Diseño por contrato (Meyer, 1992)	un obligado no determinista cuya postcondición se reverifica con un comando externo y no se asume; no la idea del contrato
micro-TODO FALSIFICATION-TEST	Falsación popperiana (Popper, 1959/2002)	un paso de refutación en la frontera de la tarea del agente; sin análogo en el diseño por contrato
Detección de shadow points (Fase 2)	Enumeración al estilo FMEA (MIL-STD-1629A; IEC 60812:2018) + palabras guía de HAZOP, sobre la biblioteca MAST (Cemri et al., 2025)	enumeración de un plan de LLM bajo aislamiento; sin puntuación de prioridad de riesgo ni descomposición por componente
Iron Laws 9 y 12 como comprobaciones a nivel de shell	Poka-yoke (Shingo, 1986)	dos comprobaciones en un script ejecutor que se le indica al agente que emita; no una imposibilidad física, y la Iron Law 10 es una instrucción
Validador aislado por prompt (Iron Law 2)	IV&V (IEEE Std 1012-2016)	independencia organizativa reformulada como aislamiento de prompts; no es IV&V
Nunca confiar en $? (Iron Laws 11–12)	Fallo no señalizado (Avizienis et al., 2004); Yuan et al. (2014)	caracterizado en el artículo complementario (Flores, 2026c); no la clase de fallo

Leída en conjunto, la sección hace una afirmación deliberadamente modesta: la maquinaria de ASP es una *integración* de disciplinas establecidas de confiabilidad e ingeniería de la calidad —contrato, enumeración de modos de fallo, IV&V, prevención de errores— en un único protocolo cuya contribución es operativa y no conceptual. Lo que esa integración añade más allá de sus ancestros es su aplicación en un entorno de ejecución de agentes no determinista: las Iron Laws (dos de ellas protegidas por comprobaciones ejecutables), el aislamiento a nivel de prompt y de proceso del §3.2 y el adjudicador determinista reproducible del §5, con el hallazgo sobre el código

de salida de claude -p caracterizado por separado en el artículo complementario. Esta es la afirmación de informe de experiencia del §1, no una afirmación de novedad frente a la literatura clásica.

3. El protocolo ASP

3.1. Visión general

ASP es un protocolo de 13 fases que avanza desde la recepción hasta la conformidad de entrega. Cada fase emite un artefacto con nombre (Tabla 2). El principio que organiza las fases es que ninguna implementación comienza antes de que los shadow points se hayan sacado a la luz (Fase 2), validado de forma independiente (Fase 5) y aprobado por el usuario (Fase 7); la ejecución se delega a un subproceso hijo con un contrato basado en archivos (Fase 9).

Tabla 2
Fases de ASP y los artefactos que emiten. La Fase 0 tiene dos subfases (0a antes de la investigación, 0b después), de modo que trece fases ocupan catorce filas

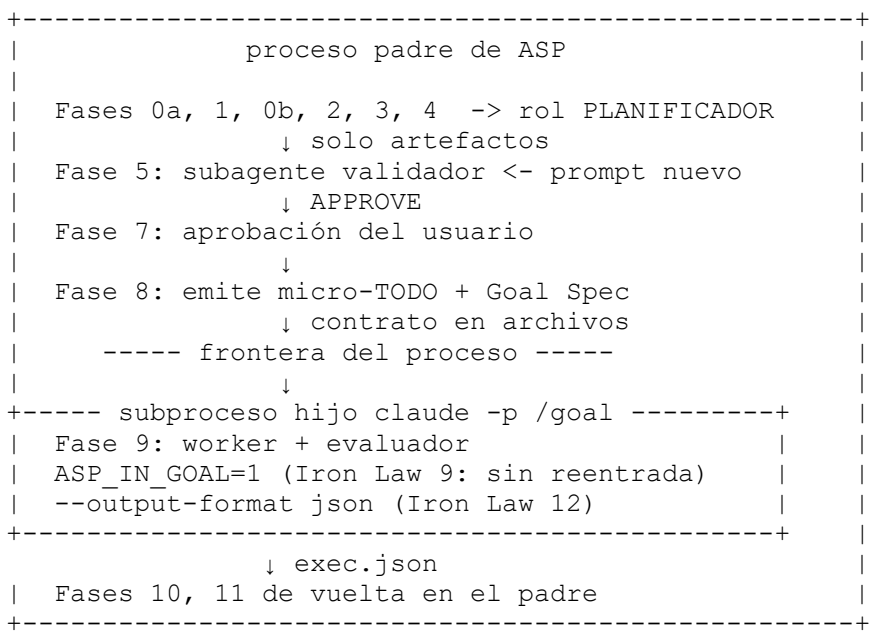
#	Fase	Artefacto	Fundamento del diseño
0a	Preguntas y respuestas previas a la investigación	bloque intake	Buena práctica de Anthropic Skills: salidas intermedias verificables
1	Investigación en paralelo	Resumen de la investigación + bloque de recall	Patrón de despacho de subagentes
0b	Preguntas y respuestas posteriores a la investigación	Intake refinado (omitible)	Igual que 0a
2	Detección de shadow points	Lista categorizada + mitigaciones	Klein (2007) + Cemri et al. (2025)
3	Project Charter	Charter completado	Traspaso duradero basado en artefactos
4	Plan macro + registro	Plan macro + entregables D01–D*n*	Plan-and-Act (Erdogan et al., 2025)
5	Validador independiente	APPROVE / REVISE	Huang et al. (2024) + Tyen et al. (2024) + Zheng et al. (2023)
6	Bucle interno (tope=3)	Plan de la revisión final	Iteración acotada; FM-1.5
7	Aprobación del usuario	Go / no-go	Compuerta con humano en el bucle
8	Micro-TODO + Goal Spec	TaskCreate por paso + Goal Spec	Traspaso al ejecutor
9	Ejecución mediante el subproceso /goal	Tareas marcadas como completadas con evidencia	Aislamiento a nivel de proceso; véase Flores (2026c)
10	Conformidad por entregable	Cada entregable aceptado o rechazado	Contrato de aceptación

#	Fase	Artefacto	Fundamento del diseño
11	Informe de ejecución + memoria	Artefacto de cierre + escritura de memoria	Memoria al estilo Reflexion (Shinn et al., 2023)
12	(Opcional) publicación pública	Marketplace de plugins + release de GitHub	Capa de distribución

3.2. Posicionamiento arquitectónico

ASP separa tres roles de agente con traspasos explícitos solo mediante artefactos (Figura 1):

Figura 1
Separación en tres roles de ASP. Las fases del planificador se ejecutan en el padre



Nota. El validador se ejecuta en el padre pero en un prompt de subagente nuevo que recibe solo artefactos, nunca la transcripción del planificador. El worker se ejecuta en un subproceso hijo claude -p con un contrato basado en archivos.

3.3. Iron Laws

Enunciamos doce restricciones operativas y las llamamos Iron Laws (Tabla 3). Las Iron Laws 9 y 12 tienen comprobaciones a nivel de shell en la plantilla ejecutora y en el fragmento de entrada que se le indica al agente que ejecute; las demás son reglas que la skill instruye al agente a seguir.

El cumplimiento de ambos tipos no se ha medido. Cada una se vincula a su derivación: una fuente primaria de la literatura, una recomendación documentada de Anthropic o una decisión empírica de diseño.

Tabla 3
Las 12 Iron Laws y su derivación

#	Ley	Derivación
1	Ninguna implementación sin una pasada previa de shadow points	Klein (2007) + Cemri et al. (2025)
2	Ninguna aprobación del plan sin una pasada de validador independiente (prompt separado)	Huang et al. (2024) + Tyen et al. (2024) + Zheng et al. (2023); mitiga FM-3.3
3	Ningún micro-TODO sin plan macro + charter + entregables aprobados por el usuario	Anthropic Skills: salidas intermedias verificables
4	Ninguna finalización de paso sin evidencia reciente de pruebas de aceptación	Cemri et al. (2025) FM-3.1 + FM-3.2 + FM-2.6
5	Ningún entregable aceptado sin que coincida el archivo o la salida de evidencia	Cemri et al. (2025) FM-3.1
6	Ningún cierre de proyecto sin informe de ejecución + escritura de memoria	Búfer de memoria de Shinn et al. (2023)
7	Ningún bucle sin tope (tope por defecto=3 rondas de validador)	Cemri et al. (2025) FM-1.5
8	Ninguna ejecución de la Fase 9 sin despacho del evaluador en los puntos de control (salvo con --quick)	Planificador/ejecutor de Erdogan et al. (2025)
9	Ningún ASP reentrante dentro del hijo claude -p /goal (guarda con la variable de entorno ASP_IN_GOAL)	Mitigación de la explosión de costes; decisión de diseño
10	Ningún lanzamiento de claude -p /goal sin contrato basado en archivos	Mitigación de la divergencia de estado entre subprocesos; decisión de diseño
11	Nunca confiar en $? de claude -p para el éxito o fracaso semántico	Observación empírica, caracterizada en Flores (2026c)
12	Toda invocación de claude -p debe usar --output-format json o stream-json	Corolario de la Iron Law 11

3.4. El contrato micro-TODO

En la frontera entre la planificación y la ejecución (Fase 8), ASP emite una lista de tareas contractual. Cada tarea se crea mediante la primitiva TaskCreate con siete campos etiquetados:

- **PRECONDITION** — invariante que debe cumplirse antes del paso.
- **ACTION** — comando exacto o edición literal.

- **POSTCONDITION** — cambio de estado que efectúa el paso.
- **ACCEPTANCE-TEST** — comando y salida esperada que prueban la postcondición.
- **FALSIFICATION-TEST** — comando u observación que probaría que el paso falló.
- **DEPENDS-ON** — identificadores de tareas previas (estructura de DAG).
- **DELIVERABLE-ID** — a qué entregable del registro contribuye este paso.

Este esquema es lo que hace auditable la lista de tareas: ninguna tarea se marca como completada sin evidencia de pruebas de aceptación (Iron Law 4); ningún entregable se da por conforme sin evidencia coincidente (Iron Law 5). El esquema se comparte con el Goal Spec que consume el subproceso de la Fase 9.

4. Despliegue operativo

ASP se distribuye como plugin de Claude Code por tres vías de instalación, cada una adecuada para un público distinto:

1. **Marketplace de plugins** (recomendado para usuarios finales):

   ```
   claude plugin marketplace add ulissesflores/anticipating-shadow-points
   claude plugin install anticipating-shadow-points@anticipating-shadow-points
   ```

   Invocación: /anticipating-shadow-points:asp <task> o /asp a secas.

2. **Modo desarrollador** (para colaboradores): claude --plugin-dir ./ carga la skill in situ; útil al iterar sobre la propia skill.

3. **Script de instalación independiente** (para usuarios que no usan el gestor de plugins): ./scripts/install.sh copia la skill en el directorio de skills de Claude Code del usuario.

El plugin usa el formato oficial de manifiesto .claude-plugin/plugin.json de Anthropic (Claude Code 2.1+; Anthropic, 2026a), y el repositorio funciona además como marketplace autoalojado mediante .claude-plugin/marketplace.json en la raíz del repositorio.

Permisos. Desde la versión 1.0.4 del plugin, el ejecutor de la Fase 9 lanza el hijo claude -p **sin ninguna opción de permisos**: el hijo se ejecuta bajo la propia configuración de permisos de Claude Code del usuario, y la skill nunca los concede, amplía ni elude. Las versiones anteriores pasaban --permission-mode bypassPermissions; eso se eliminó después de que el directorio de plugins de Claude rechazara la inclusión porque un plugin no debe concederse permisos a sí mismo. En modo no interactivo, una acción que el usuario no ha permitido de antemano se deniega en lugar de solicitarse; el padre lee el campo permission_denials del resultado JSON del hijo e informa al usuario de cualquier denegación en lugar de reintentar con un permiso más amplio. Esto hace que la ejecución autónoma sea estrictamente más débil que en el despliegue de mayo de 2026, y más segura: la skill solo puede hacer lo que el operador ya permitió. La propia skill está implementada como una skill basada en Markdown que sigue el documento de buenas prácticas de Agent Skills de Anthropic (Anthropic, 2026b), con archivos complementarios para la lista de verificación MAST, los prompts de pre-mortem por modo y las siete plantillas de artefactos a las que se refiere la Sección 3.1.

La documentación se publica como sitio de GitHub Pages, con traducciones del README al español, portugués, italiano y hebreo; las tres últimas están asistidas por IA y pendientes de revisión por hablantes nativos. Todo el código fuente —archivos de la skill, manifiestos del plugin, documentación, artefactos de prueba, código del benchmark— tiene licencia MIT; el texto del artículo, las figuras y los datos tienen licencia CC BY 4.0.

5. Observaciones preliminares

Sometimos a ASP a cinco evaluaciones de ingeniería estructuradas, que abarcan dominios heterogéneos. Esta sección separa tres cosas que la versión 1.0 confundía: lo que el autor observó en despachos reales de modelo (5.2), lo que el adjudicador determinista muestra sobre sí mismo con fixtures construidos (5.3) y lo que no se ha medido en absoluto.

5.1. El conjunto de evaluaciones

Tabla 4
Las cinco evaluaciones de ingeniería

ID	Dominio	Tarea (abreviada)	Tamaño esperado	Aceptación
E1	Migración de esquema	Columna NOT NULL añadida a user_profiles, de 1M de filas	10	≥ 80%
E2	Despliegue en el edge	Función en el edge que llama a una API externa con límite de tasa	10	≥ 80%
E3	Refactorización	Utilidad de formateo de fechas usada en más de 30 archivos	10	≥ 80%
E4	Política RLS	Política de seguridad a nivel de fila que referencia una columna nueva	10	≥ 80%
E5	Planificación de tareas	Tarea cron cuyo script entra en conflicto con un servicio desactivado	10	≥ 80%

Cada evaluación especifica un INPUT (el enunciado de una tarea tal como un ingeniero sénior podría formulárselo a un colega), una lista EXPECTED de shadow points que un profesional competente sacaría a la luz y un umbral de ACCEPTANCE (por defecto 80%). E5 no es portable: dos de sus diez puntos esperados (1 y 8) dependen de la memoria privada de proyecto del autor y no pueden surgir solo a partir de su INPUT, de modo que mide la evocación de memoria tanto como la planificación. El texto completo de cada evaluación está en el repositorio complementario.

5.2. Lo que se observó en despachos reales (autor, no ciego)

El 2026-05-17 las evaluaciones se despacharon a subagentes nuevos: GREEN (con la disciplina de ASP inyectada: encuadre de pre-mortem, enumeración forzada de los 14 modos de MAST, exigencia de mitigación) en las cinco, y RED (a quien se pidió planificar como lo haría un ingeniero sénior, sin ningún framework) en tres, E1–E3; E4 y E5 se añadieron después y se ejecutaron solo en GREEN. Todos se ejecutaron con el modelo de sesión de la época (Claude Opus 4.7; el modelo no se registró por despacho), un despacho por condición. Los subagentes heredaron las instrucciones globales de agente del autor, de modo que la condición RED fue una línea base competente, no ingenua. El autor leyó cada plan frente a la lista esperada y registró un juicio de cobertura; los resúmenes, con los identificadores de subagente, están versionados en tests/baseline-pressure-tests.md y tests/evals-summary.md. Las transcripciones en bruto no se versionaron y ya no están disponibles. Los prompts RED registrados allí son formulaciones en portugués, más breves, de E1–E3 que omiten detalles que las listas esperadas puntúan después: el prompt RED de E2 no indica el límite de tasa de 100 req/s de Resend, y el de E1 no dice que el código de la aplicación ya referencia la nueva columna en cinco puntos de consulta. Parte del déficit de RED puede deberse, por tanto, a un artefacto del prompt y no a la ausencia del protocolo.

Bajo esa lectura no ciega, los tres planes RED cubrieron aproximadamente el 30–60% de sus listas esperadas (media cercana al 47%, contando las menciones parciales como cubiertas) y los planes GREEN cubrieron la totalidad o casi la totalidad de las suyas. Los resúmenes versionados, escritos en mayo de 2026, concluyen que ASP es “reproduciblemente mejor” (traducción nuestra); una nota añadida sobre ellos en la versión 2.0 retira esa conclusión, que no está respaldada. Estas cifras son un juicio del autor sobre texto no conservado, puntuado frente a listas escritas por el mismo autor, con el vocabulario de MAST que inyecta el prompt GREEN apareciendo en esas listas. Se

informan como observación, no como medición, y ningún número de este párrafo lo verifica la capa de replicación.

5.3. Lo que el adjudicador determinista muestra sobre sí mismo

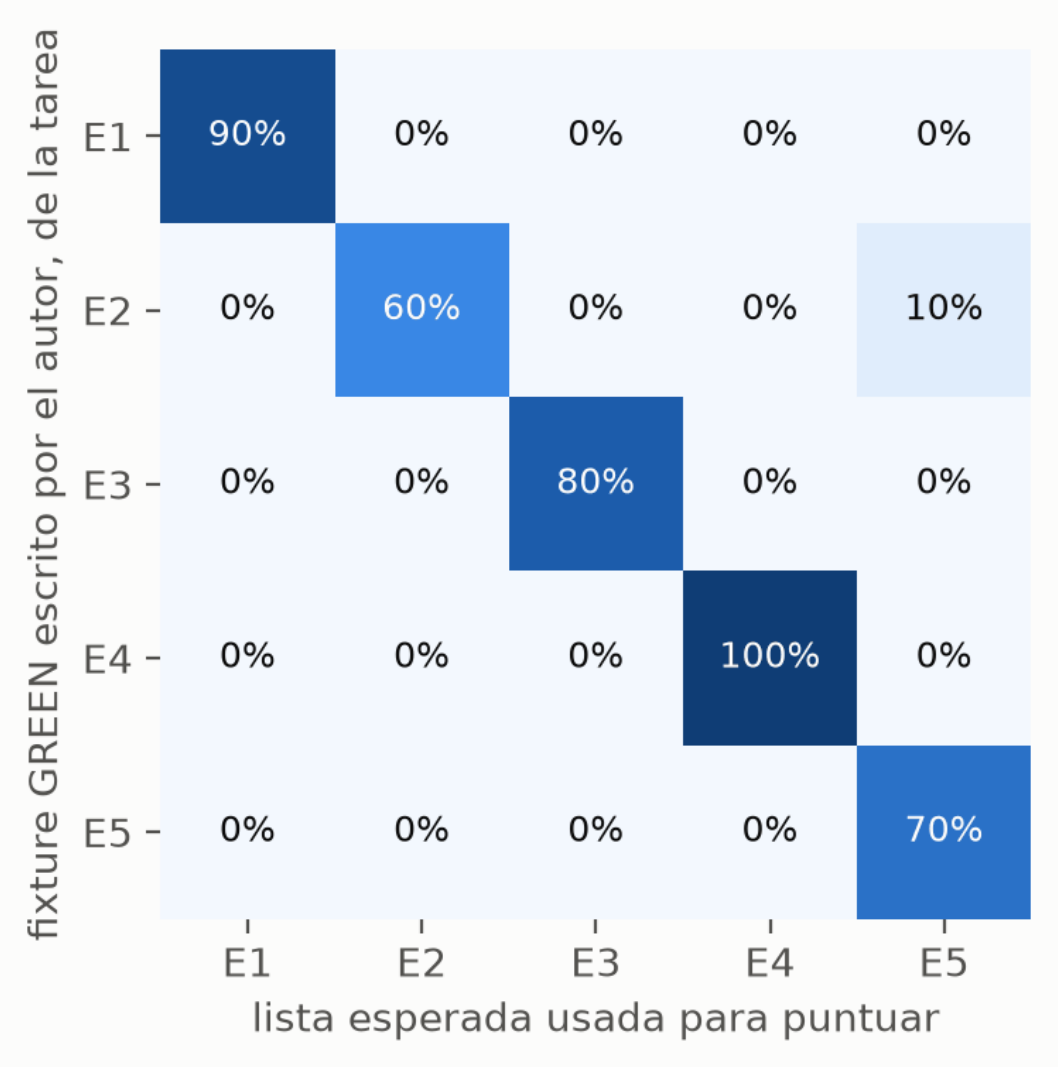
El paquete benchmark/ puntúa un plan frente a una lista esperada con un matcher determinista de 4 capas (nombre exacto, sidecar de sinónimos, ventana deslizante de Jaccard, sin coincidencia). En la ejecución publicada, cada una de las 42 coincidencias procede de la primera capa (nombre exacto); no existe sidecar de sinónimos para ninguna tarea y la capa de Jaccard nunca se activa. Su única ejecución publicada es una ejecución en **modo mock**: los textos RED y GREEN son fixtures que el autor escribió para ejercitar el pipeline de extremo a extremo (benchmark/tests/fixtures/mock_runs/); con ellos, las capas 2 y 3 nunca producen una coincidencia (los solapamientos de la capa 3 se calculan y quedan por debajo del umbral), y solo las pruebas unitarias ejercitan una coincidencia a través de esas capas, deliberadamente más débiles para RED y deliberadamente alineadas con la lista esperada para GREEN. Con esos fixtures, el matcher puntúa RED en 4% y GREEN en 80% de media —una afirmación sobre cómo se escribieron los fixtures, no sobre ASP.

La propiedad útil que la ejecución mock sí establece es la **discriminación**: puntuar cada fixture GREEN frente a la lista esperada de una tarea *distinta* reduce la media del 80% al 0,5% (mayor celda fuera de tarea 10%; Figura 2). Es una evidencia más débil de lo que parece: el único acierto fuera de tarea es el nombre genérico de una palabra “Alerting”, y las demás celdas son cero porque la capa 1 exige que aparezca literalmente un nombre esperado completo. El matcher es además más estricto que los archivos de evaluación, que indican a un evaluador humano que acepte paráfrasis. La exhaustividad (recall) es otra cuestión, y los fixtures muestran un falso negativo: el fixture RED de E2 menciona un límite de tasa, reintentos y registro y aun así puntúa 0/10: su mejor

solapamiento de ventana con el punto esperado “Rate-limit backoff” (su nombre y su descripción) es un Jaccard de 0,11, por debajo del umbral de 0,30, y el matcher no hace stemming (“logging” no coincide con “logs”). La paráfrasis con bajo solapamiento léxico se pierde. La nueva puntuación expuso además un defecto, corregido en la v2.0: la ventana deslizante omitía los últimos tokens de un texto cuya longitud no coincidía con el paso; volver a puntuar todos los fixtures con la corrección no cambia ningún valor de cobertura, aunque el mejor solapamiento de tres puntos sin coincidencia sube ligeramente (E2 RED “Observability / logs” de 0,00 a 0,02), todavía muy por debajo del umbral. La capa 3 tiene además un techo aritmético: Jaccard divide por la unión, y una ventana de 40 tokens de los fixtures contiene de 27 a 40 palabras de contenido distintas (mediana 36); en cualquier ventana con 34 o más, un punto esperado con diez o menos tokens distintos no puede alcanzar 0,30 aunque el plan los repita todos, y 19 de los 50 puntos esperados son así de cortos. El protocolo en modo real cambia por ello la capa 3 antes del depósito (PREREGISTRATION.md). El matcher todavía no se ha aplicado a ninguna transcripción real. El protocolo en modo real, con listas esperadas redactadas de nuevo a ciegas por ingenieros independientes, se especifica en el PREREGISTRATION.md del repositorio y no se ha ejecutado. Su regla de decisión está fijada de antemano: con ocho réplicas por tarea y condición (80 despachos), un beneficio solo se informa si la cobertura media de la condición asistida supera a la de la no asistida en las cinco tareas y una prueba de permutación unilateral, estratificada por tarea, sobre la diferencia media por tarea (10 000 reetiquetados, semilla asp-bench-v1) da $p < 0,05$; ningún beneficio medible si no lo logra en tres o más; no concluyente en los demás casos; incompleto si el presupuesto detiene la recogida de datos. La cobertura se informará por capa del matcher, ya que la capa 1 premia a un plan que reutiliza literalmente los nombres esperados.

Figura 2

Comprobación del instrumento: cada fixture GREEN construido por el autor puntuado frente a la lista esperada de cada tarea. No es un efecto de ASP



Qué componente importaría más, si ASP tiene un efecto, se discute como hipótesis en la Sección 6.

5.4. El hallazgo sobre el código de salida de claude -p

Durante una batería de cuatro pruebas contra el ejecutor no interactivo claude -p, observamos que el binario devuelve el código de salida 0 incluso cuando el agente rechaza con cortesía el objetivo solicitado: el harness informa de un final de conversación exitoso a pesar de que el agente rechaza

semánticamente la tarea. El código de salida refleja el éxito a nivel de proceso del binario de la CLI, no el éxito semántico de la tarea del agente. Las Iron Laws 11 y 12 exigen --output-format json y leer is_error, terminal_reason y stop_reason. Esos campos separan un corte por límite de turnos y un rechazo de clasificador de un turno completado, pero no un rechazo generado por el modelo de una entrega; por ello el ejecutor marca además las respuestas cuyo texto coincide con un patrón de rechazo, una heurística que el artículo complementario pone a prueba.

Este hallazgo es observacionalmente significativo para cualquier cadena de herramientas que envuelva claude -p en un pipeline de shell. Como la observación procedía de un único escenario de rechazo de nuestra propia batería, la **caracterizamos de forma independiente** en el artículo complementario Flores (2026c), que informa de una medición con N=50 en cuatro categorías de prompts que provocan rechazo (imposibles en un solo turno, de capacidad, de seguridad, de ambigüedad) en Claude Code 2.1.200 en julio de 2026. El modelo de sesión fue Fable 5; Opus 4.8 respondió 16 de los 50 prompts, incluidos los 12 de seguridad —de manera coherente con un traspaso automático (fallback), aunque los envelopes registran qué modelo respondió, no por qué—. Veinticuatro ensayos terminaron con 0, todos con stop_reason: end_turn. El artículo complementario cuenta los rechazos entre ellos de cuatro maneras: 20 (40%, IC de Wilson al 95% 28–54%) con la etiqueta no ciega del autor; 19 (38%) con la mayoría de un codebook, escrito después de que el autor leyera las respuestas y aplicado por cinco evaluadores LLM, cuatro de los cuales devolvieron etiquetas idénticas, todos del linaje del modelo bajo prueba, de modo que la mayoría es una comprobación del codebook y no una estimación de acuerdo entre evaluadores; 12 (24%) contando solo los rechazos de seguridad y de comandos destructivos y excluyendo los ocho rechazos fundamentados de tareas imposibles en un solo turno; y 9 (18%) con el detector de frases bloqueado solo en inglés, que no capta las respuestas redactadas en portugués. Una instantánea

anterior (mayo de 2026, Claude Code 2.1.143, Opus 4.7) dio 60% con el mismo detector, con un modelo y un idioma de respuesta distintos. Un segundo evaluador humano y una tercera instantánea bajo un preregistro redactado son los seguimientos pendientes.

6. Hipótesis de diseño

Destacamos cinco decisiones de diseño que creemos fundamentales. Las cuatro primeras son hipótesis sobre ASP que ningún dato de aquí mide, cada una enunciada con la observación que la motivó; la quinta se apoya en la medición del artículo complementario.

Hipótesis: una taxonomía forzada saca a la luz más que un pre-mortem libre. En los borradores del autor, el pre-mortem libre se agrupaba en categorías de riesgo obvias (datos, integración) y subponderaba las menos salientes (hora y zona horaria, observabilidad, excelencia operativa, deriva de contratos). Ningún despacho puso a prueba el pre-mortem libre como condición (RED no tenía ningún framework), de modo que esto se apoya en la lectura que el autor hace de sus borradores. El prompt libre (“imagine the task has failed in 30 days; list 10+ causes”) sería entonces necesario pero no suficiente, y el interrogatorio de los 14 modos de MAST sacaría a la luz categorías de las que la pasada libre se aleja agrupándose.

Hipótesis: el aislamiento de prompts del validador importa. Esperamos que los validadores que comparten contexto con los planificadores reproduzcan la confianza del planificador sobre el contenido compartido. La literatura convergente sobre los límites de la autocorrección intrínseca, el fallo de localización de errores y el sesgo de autopotenciación de los jueces apunta a ello; no lo hemos puesto a prueba dentro de ASP.

Hipótesis: los traspasos basados en archivos resisten mejor la presión de contexto que los basados en transcripciones. ASP persiste en disco el charter, el plan macro, el registro de

entregables y el goal spec antes de lanzar el ejecutor. El hijo recibe solo el texto del Goal Spec por stdin y devuelve un resultado JSON; el padre reconstruye el estado a partir de ese resultado y de los archivos en disco, de modo que ninguno de los dos depende de una transcripción que pueda haberse comprimido o truncado. No hemos comparado los dos traspasos.

Hipótesis: las restricciones enunciadas (Iron Laws) hacen más difícil omitir una skill. En nuestra experiencia, las skills que se leen como "pautas" a menudo se omiten bajo presión de contexto. Las skills que emiten una lista de innegociables, con plantillas cuyos campos deben rellenarse antes de la siguiente fase, son en nuestro uso más difíciles de omitir. El cumplimiento no se ha medido.

Medido en otro lugar: tratar los códigos de salida de claude -p como señales de éxito semántico es una trampa silenciosa. Este es el hallazgo informado en Flores (2026c); lo mencionamos aquí porque la implicación de diseño (Iron Laws 11 y 12) fue importante para la fiabilidad del sistema.

7. Amenazas a la validez

Tratamos las amenazas de forma explícita en las cuatro categorías habituales en los informes empíricos de ingeniería de software.

Validez de constructo. El mismo investigador que diseñó el protocolo redactó las listas de shadow points esperados *y* adjudicó a mano la cobertura. Incluso con una rúbrica escrita, esta es la mayor amenaza individual para la interpretabilidad de la observación. El adjudicador determinista que distribuimos la mitigaría una vez aplicado a transcripciones reales y conservadas; en esta versión solo se ha ejecutado sobre fixtures construidos (§5.3), y no aborda la cuestión previa de si las

propias listas esperadas están sesgadas hacia lo que ASP saca a la luz. **La redacción ciega de nuevo por revisores independientes es el seguimiento más sólido.**

Validez interna. Con un despacho por celda, GREEN en cinco tareas y RED en tres, la evaluación a lo sumo sugiere que el protocolo puede cambiar las transcripciones en estos casos; *no* basta para estimar un tamaño del efecto, establecer causalidad ni respaldar inferencia estadística, y no se informa de ninguna prueba estadística. No se ha realizado ninguna ablación formal de componentes (la atribución cualitativa de carácter fundamental a la lista de verificación MAST del §6 es una hipótesis). El umbral de aceptación del 80% es elección del autor y no se deriva de la literatura previa.

Validez externa. Un único modelo subyacente (Claude Opus 4.7, presumido a partir de la sesión; no registrado por despacho), un único entorno (la estación de trabajo macOS del autor y la versión de Claude Code de mayo de 2026, no registrada por despacho), cinco tareas de ingeniería extraídas de la experiencia del autor en su dominio. No afirmamos ninguna generalización más allá de estas condiciones.

Fiabilidad. Todos los enunciados INPUT de las evaluaciones, las listas de shadow points esperados, los fixtures de la ejecución mock y el código del adjudicador determinista están versionados en el repositorio complementario; las transcripciones de los despachos del 2026-05-17 no se conservaron, de modo que las observaciones del §5.2 no pueden volver a comprobarse. El paquete de benchmark construye un manifiesto encadenado criptográficamente por ejecución, de modo que cualquier byte editado bajo un directorio de ejecución invalida el hash del manifiesto.

8. Limitaciones y trabajo futuro

Las limitaciones de este informe de experiencia se corresponden una a una con las amenazas anteriores. Los seguimientos de mayor prioridad, por orden, son:

1. **Redacción ciega de nuevo** de las listas de shadow points esperados por 2 o más revisores independientes sin exposición a ASP, y luego una ejecución en modo real cuyas transcripciones se conserven y se sellen con hash, adjudicada a ciegas. Calcular el κ de Cohen del acuerdo entre adjudicadores; volver a medir la cobertura.
2. **Ablación formal** de la hipótesis de carácter fundamental: lista de verificación MAST activada/desactivada (poniendo a prueba la hipótesis del §6), aislamiento de prompts del validador activado/desactivado, intake de la Fase 0a activado/desactivado. Todavía no existe ningún protocolo de ablación; el Protocolo 2 de PREREGISTRATION.md cubre solo RED frente a GREEN, con 8 réplicas por celda y un presupuesto fijo en lugar de un análisis de potencia.
3. **Un segundo evaluador humano y una tercera instantánea de claude -p** para el hallazgo complementario (Flores, 2026c, §8), esta última bajo el Protocolo 1 de PREREGISTRATION.md.
4. **Evaluación entre modelos.** Volver a ejecutar en Claude Sonnet, GPT-5, Gemini 2.5 y un modelo de pesos abiertos.
5. **Comparación directa con PreFlect.** Ejecutar ASP y una reimplementación de PreFlect sobre el mismo conjunto de tareas.

6. **Adjudicador basado en embeddings** como v0.2 del benchmark, con un modelo sentence-transformer fijado, para elevar el piso de exhaustividad en paráfrasis léxicamente disjuntas.
7. **Replicación en benchmarks estandarizados.** El conjunto de cinco tareas no es un benchmark público de agentes; replicar la dirección en SWE-bench (Jimenez et al., 2024) o en una suite estandarizada comparable pondría a prueba si sobrevive fuera de las tareas elegidas por el autor.
8. **Revisión por hablantes nativos** de las traducciones de la documentación al ES, IT y HE.
9. **Destino de envío.** Los foros de talleres —la línea de agentes LLM de NeurIPS, el taller de agentes de ICLR, la línea de agentes de AAAI— son el encaje adecuado para la escala empírica actual. El envío a la línea principal requiere los seguimientos anteriores.

9. Conclusión

Describimos ASP, una skill operativa de pre-mortem para agentes de programación con LLM, que integra el hallazgo de retrospectiva prospectiva de Mitchell, Russo y Pennington (1989), la operacionalización del pre-mortem de Klein (2007) y la taxonomía de fallos de 14 modos MAST de Cemri et al. (2025) como disciplina de tiempo de ejecución bajo un contrato de doce Iron Laws. La skill se distribuye como código abierto con tres vías de instalación. En las tres tareas ejecutadas en ambas condiciones, el autor observó, sin cegamiento y sobre transcripciones que no se conservaron, que los planes asistidos cubrían más de los modos de fallo esperados; no se ha medido ningún efecto. El adjudicador determinista distribuido con la skill solo se ha ejercitado sobre fixtures construidos, donde separa nombres esperados completos pero no tiene exhaustividad

medida; una ejecución en modo real con listas redactadas de forma independiente, redactada para su preregistro, es el siguiente paso decisivo.

Observamos además que claude -p devuelve el código de salida 0 incluso cuando el agente rechaza con cortesía el objetivo solicitado. El proveedor documenta el comportamiento para su API; el artículo complementario (Flores, 2026c) añade un recuento en la frontera de la CLI.

El seguimiento más sólido es la readjudicación ciega. El trabajo complementario más útil es un segundo evaluador humano y una tercera instantánea preregistrada de la medición de claude -p (Flores, 2026c).

Agradecimientos

Este informe de experiencia se preparó en colaboración explícita con un humano en el bucle y con Claude (Anthropic, Opus 4.7), usado como socio de redacción, verificación y revisión. Las decisiones de metodología, el diseño empírico y la finalización las realizó el autor humano. El modelo de colaboración está documentado en las Partes 5–6 de docs/ARCHITECTURE.md del repositorio complementario.

El autor agradece a los mantenedores del framework de skills obra/superpowers, a los colaboradores del estándar abierto agentskills.io y al equipo de Claude Code de Anthropic por la primitiva /goal, cuyo comportamiento empírico motivó las Iron Laws 11 y 12.

Referencias (APA, 7.ª edición)

Anthropic. (2026a). *Claude Code* [Software documentation]. https://code.claude.com

Anthropic. (2026b). *Agent Skills best practices* [Software documentation]. https://platform.claude.com/docs/en/agents-and-tools/agent-skills/best-practices

Avizienis, A., Laprie, J.-C., Randell, B., & Landwehr, C. (2004). Basic concepts and taxonomy of dependable and secure computing. *IEEE Transactions on Dependable and Secure Computing*, *1*(1), 11–33. https://doi.org/10.1109/TDSC.2004.2

Barke, S., Goyal, A., Khare, A., Singh, A., Nath, S., & Bansal, C. (2026). *AgentRx: Diagnosing AI agent failures from execution trajectories*. arXiv:2602.02475. https://arxiv.org/abs/2602.02475

Cemri, M., Pan, M. Z., Yang, S., Agrawal, L. A., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Klein, D., Ramchandran, K., Zaharia, M., Gonzalez, J. E., & Stoica, I. (2025). Why do multi-agent LLM systems fail? *Advances in Neural Information Processing Systems, 38*, 135676–135729. https://doi.org/10.52202/085713-4082

Deshpande, D., Gangal, V., Mehta, H., Krishnan, J., Kannappan, A., & Qian, R. (2025). *TRAIL: Trace reasoning and agentic issue localization*. arXiv:2505.08638. https://arxiv.org/abs/2505.08638

Erdogan, L. E., Lee, N., Kim, S., Moon, S., Furuta, H., Anumanchipalli, G., Keutzer, K., & Gholami, A. (2025). *Plan-and-Act: Improving planning of agents for long-horizon tasks*. ICML 2025. https://arxiv.org/abs/2503.09572

Flores, C. U. (2026a). *ASP — Anticipating Shadow Points: Claude Code plugin and replication package* (Version 2.0.0) [Computer software].

https://github.com/ulissesflores/anticipating-shadow-points. https://doi.org/10.5281/zenodo.20276631

Flores, C. U. (2026c). *Graceful refusals as unsignalled failures: Characterising claude -p exit-code semantics on agent declines* (Version 2.2) [Technical note]. In Flores (2026a). https://doi.org/10.5281/zenodo.20276631

Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). *Large language models cannot self-correct reasoning yet*. ICLR 2024. https://arxiv.org/abs/2310.01798

IEEE. (2017). *IEEE standard for system, software, and hardware verification and validation* (IEEE Std 1012-2016). https://doi.org/10.1109/IEEESTD.2017.8055462

International Electrotechnical Commission. (2016). *Hazard and operability studies (HAZOP studies) — Application guide* (IEC 61882:2016, Edition 2.0). https://webstore.iec.ch/en/publication/24321

International Electrotechnical Commission. (2018). *Failure modes and effects analysis (FMEA and FMECA)* (IEC 60812:2018). https://webstore.iec.ch/en/publication/26359

International Electrotechnical Commission. (2019). *Risk management — Risk assessment techniques* (IEC 31010:2019, Edition 2.0). https://webstore.iec.ch/en/publication/59809

Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). *SWE-bench: Can language models resolve real-world GitHub issues?* ICLR 2024. https://arxiv.org/abs/2310.06770

Kambhampati, S., Valmeekam, K., Guan, L., Verma, M., Stechly, K., Bhambri, S., Saldyt, L., & Murthy, A. (2024). *LLMs can't plan, but can help planning in LLM-Modulo frameworks*. ICML 2024 (position paper). https://arxiv.org/abs/2402.01817

Kamoi, R., Zhang, Y., Zhang, N., Han, J., & Zhang, R. (2024). When can LLMs actually correct their own mistakes? A critical survey of self-correction of LLMs. *Transactions of the Association for Computational Linguistics*. https://arxiv.org/abs/2406.01297

Klein, G. (2007). Performing a project premortem. *Harvard Business Review*, *85*(9), 18–19.

Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegreffe, S., Alon, U., Dziri, N., Prabhumoye, S., Yang, Y., Gupta, S., Majumder, B. P., Hermann, K., Welleck, S., Yazdanbakhsh, A., & Clark, P. (2023). *Self-Refine: Iterative refinement with self-feedback*. NeurIPS 2023. https://arxiv.org/abs/2303.17651

Meyer, B. (1992). Applying "design by contract." *Computer*, *25*(10), 40–51. https://doi.org/10.1109/2.161279

Mitchell, D. J., Russo, J. E., & Pennington, N. (1989). Back to the future: Temporal perspective in the explanation of events. *Journal of Behavioral Decision Making*, *2*(1), 25–38. https://doi.org/10.1002/bdm.3960020103

Popper, K. R. (2002). *The logic of scientific discovery*. Routledge. (Original work published 1959)

Shingo, S. (1986). *Zero quality control: Source inspection and the poka-yoke system* (A. P. Dillon, Trans.). Productivity Press. (Original work published 1985)

Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., & Yao, S. (2023). *Reflexion: Language agents with verbal reinforcement learning*. NeurIPS 2023. https://arxiv.org/abs/2303.11366

Tyen, G., Mansoor, H., Cărbune, V., Chen, P., & Mak, T. (2024). LLMs cannot find reasoning errors, but can correct them given the error location. In *Findings of the Association for Computational Linguistics: ACL 2024*. https://arxiv.org/abs/2311.08516

U.S. Department of Defense. (1980). *Procedures for performing a failure mode, effects and criticality analysis* (MIL-STD-1629A). https://everyspec.com/MIL-STD/MIL-STD-1600-1699/MIL_STD_1629A_1556/

Wang, H., Cao, Y., Lin, L., & Chen, J. (2026). *PreFlect: From retrospective to prospective reflection in large language model agents*. arXiv. https://arxiv.org/abs/2602.07187

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). *AutoGen: Enabling next-gen LLM applications via multi-agent conversation*. arXiv. https://arxiv.org/abs/2308.08155

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). *ReAct: Synergizing reasoning and acting in language models*. ICLR 2023. https://arxiv.org/abs/2210.03629

Yuan, D., Luo, Y., Zhuang, X., Rodrigues, G. R., Zhao, X., Zhang, Y., Jain, P. U., & Stumm, M. (2014). Simple testing can prevent most critical failures: An analysis of production failures in distributed data-intensive systems. In *Proceedings of the 11th USENIX Symposium on Operating Systems Design and Implementation (OSDI '14)* (pp. 249–265). USENIX Association. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/yuan

Zhang, G., Wang, J., Chen, J., Zhou, W., Wang, K., & Yan, S. (2025). *AgenTracer: Who is inducing failure in the LLM agentic systems?* arXiv:2509.03312. https://arxiv.org/abs/2509.03312

Zhang, J., Peng, X., Chen, Q., Li, Y., Hayashi, H., & Wu, C.-S. (2026). *Prospective hindsight: Self-calibrating reinforcement learning via prediction-reality gaps*. arXiv:2610.02740. https://arxiv.org/abs/2610.02740

Zhang, S., Yin, M., Zhang, J., Liu, J., Han, Z., Zhang, J., Li, B., Wang, C., Wang, H., Chen, Y., & Wu, Q. (2025). *Which agent causes task failures and when? On automated failure attribution of LLM multi-agent systems*. ICML 2025 Spotlight. https://arxiv.org/abs/2505.00212

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS 2023 D&B. https://arxiv.org/abs/2306.05685

Zhu, K., Liu, Z., Li, B., Tian, M., Yang, Y., Zhang, J., Han, P., Xie, Q., Cui, F., Zhang, W., Ma, X., Yu, X., Ramesh, G., Wu, J., Liu, Z., Lu, P., Zou, J., & You, J. (2025). *Where LLM agents fail and how they can learn from failures*. arXiv. https://arxiv.org/abs/2509.25370

Apéndice A — Estado de la verificación de citas

Toda afirmación del cuerpo cita una fuente primaria cuando existe. Los párrafos siguientes registran cuándo se comprobó cada grupo de referencias.

Las referencias presentes en la versión 1.0 se verificaron mediante consulta directa de la URL el 2026-05-17; las referencias añadidas en la revisión de julio de 2026 (Flores, 2026c; las entradas del linaje clásico de la Sección 2.5) se comprobaron al añadirse; y las entradas añadidas en noviembre de 2026 (Barke et al., 2026; Deshpande et al., 2025; Kambhampati et al., 2024; G. Zhang et al., 2025; J. Zhang et al., 2026) se comprobaron frente a sus registros de arXiv, y Cemri et al. (2025) frente a su registro en las actas de NeurIPS. Los nombres de los 14 modos de MAST se citan literalmente de Cemri et al. (2025) y se listan en el archivo de skill complementario skills/anticipating-shadow-points/mast-checklist.md. Mitchell et al. (1989) es el estudio primario de la retrospectiva prospectiva; la cifra de ≈30% es el resumen que hace Klein (2007) de aquel, que no pudimos rederivar a partir del artículo de 1989, y Klein (2007) es además la receta operativa.

Las nueve referencias introducidas en el §2.5 (Avizienis et al., 2004; International Electrotechnical Commission [IEC 60812:2018], 2018; International Electrotechnical Commission [IEC 61882:2016], 2016, comprobada frente al catálogo de la IEC el 2026-11-07; IEEE [Std 1012-2016], 2017; Meyer, 1992; Popper, 1959/2002; Shingo, 1986; U.S. Department of Defense [MIL-STD-1629A], 1980; Yuan et al., 2014) se verificaron frente a su fuente primaria —DOI, ISBN o entrada de catálogo de la norma— el 2026-07-08.

Apéndice B — Conjunto de evaluaciones y reproducibilidad

Las cinco evaluaciones de ingeniería están versionadas en el repositorio complementario:

- skills/anticipating-shadow-points/evals/01-supabase-migration.md (E1)
- skills/anticipating-shadow-points/evals/02-edge-function-deploy.md (E2)
- skills/anticipating-shadow-points/evals/03-refactor-shared-util.md (E3)
- skills/anticipating-shadow-points/evals/04-rls-policy-change.md (E4)
- skills/anticipating-shadow-points/evals/05-cron-skill-conflict.md (E5)

Cada archivo contiene el enunciado INPUT, la lista de shadow points EXPECTED y el umbral de ACCEPTANCE, todos redactados por el diseñador del protocolo. El paquete de benchmark en benchmark/ proporciona:

- un adjudicador determinista de 4 capas (exacto / sinónimo / Jaccard / sin coincidencia);
- procedencia criptográfica por ejecución (entorno, código, entradas, salidas y adjudicación con hash en una cadena de tipo Merkle);
- un subcomando verify que recorre de nuevo un directorio de ejecución e informa de cualquier deriva a nivel de byte;
- 31 pruebas unitarias que fijan el contrato de determinismo y el analizador de respuestas.

Reproducir los números calculados de las Secciones 5.3–5.4 (sin llamadas a modelos). Desde un clon del repositorio, python run_all.py vuelve a puntuar los fixtures construidos por el autor de la ejecución mock del benchmark con el adjudicador distribuido, recalcula la matriz de discriminación, regenera la Figura 2, verifica cada número (tests/test_paper_numbers.py, que también verifica que la ejecución esté etiquetada como mock) y comprueba un único hash de

cadena SHA-256 sobre código, pruebas, entradas congeladas, datos y resultados (output/hash-chain.md). Las observaciones del autor de la Sección 5.2 no pueden reproducirse: sus transcripciones no se conservaron. Esta versión sustituye a la versión 1.0 (https://doi.org/10.5281/zenodo.20277015), que presentaba las puntuaciones del adjudicador sobre estos fixtures como una lectura de transcripciones de modelo.

Recoger evidencia real (cuesta llamadas a modelos). Instale el paquete de benchmark y ejecute asp-benchmark run --mode real --model <model> seguido de asp-benchmark verify <run-id>. Esto no se ha hecho para ningún número publicado, y el comando actual aún no es el Protocolo 2: envía una plantilla de un solo turno en lugar de la skill distribuida, ejecuta una réplica por tarea en un orden fijo y no pasa ninguna opción de entorno limpio. PREREGISTRATION.md lista los cambios que el ejecutor y el matcher necesitan antes de cualquier despacho. El protocolo se especifica de forma independiente de la implementación en Python en benchmark/PROTOCOL.md, de modo que pueda reimplementarse en otro lenguaje.

Sobre el autor

Carlos Ulisses Flores es CTO e Investigador Jefe de Codex Hash Research Laboratory, un laboratorio independiente de I+D en São Paulo, Brasil. Construye sistemas de producción donde el fallo silencioso sale caro —históricamente en trading algorítmico, IoT embebido y criptografía en el borde, y hoy en herramientas de IA agéntica—. La skill ASP descrita en este whitepaper surgió de esta última línea de trabajo; el hallazgo empírico informado en el whitepaper complementario surgió de usar el ejecutor claude -p de Anthropic como núcleo de ejecución autónoma y de verlo devolver el código de salida 0 ante un rechazo cortés del agente.

Escribe en portugués, inglés, español e italiano.

Identificadores · ORCID: 0000-0002-6034-7765 · Lattes: 6905246706890561

Contacto · c.ulisses@gmail.com · https://ulissesflores.com