

ASP: una skill operativa di pre-mortem per agenti di programmazione basati su LLM

Un resoconto di esperienza

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Data: 7 novembre 2026

Abstract

LLM coding assistants often produce *locally correct* code that omits failure modes a senior engineer would surface in a pre-mortem — a row-level security policy, an external API's rate limit, replica lag during a migration — and production then breaks in ways that are expensive to debug. We call these missing items *shadow points*. This experience report describes Anticipating Shadow Points (ASP), a 13-phase planning protocol shipped as a Claude Code skill that integrates Klein's (2007) pre-mortem with the multi-agent failure taxonomy of Cemri et al. (2025), checks the plan with a validator that does not share the planner's context, following the self-correction-limit literature (Huang et al., 2024; Tyen et al., 2024), and hands execution to a child subprocess with a file-based contract. We document the design, its deployment as an open-source plugin, and preliminary observations from five engineering evaluations, read by the author without blinding and with transcripts not preserved. A deterministic adjudicator ships with the skill; its scores on author-written fixtures exercise the instrument and nothing more, so we report no measured effect of ASP. We state in advance the result that would show one: in a real-mode benchmark with blind, independently written expected lists and eight replicates per task and condition, a measured benefit if the assisted condition's mean coverage beats the unassisted one on all five tasks and a one-sided, task-stratified permutation test gives $p < 0.05$; no measurable benefit if it fails on three or more; inconclusive otherwise; incomplete if the budget stops collection early. The protocol is drafted and not yet deposited.

Keywords: llm coding agents; pre-mortem; multi-agent failure modes; claude code; operational protocols; experience report :::

Whitepaper · Versione 2.1 · 2026-11 *(prima pubblicazione 2026-05-18)*

DOI https://doi.org/10.5281/zenodo.20276631 *(concept · rimanda all'ultima versione depositata)*

Stato Whitepaper tecnico indipendente · non sottoposto a revisione tra pari

Licenza Testo del paper, figure e dati — CC BY 4.0 · Software complementare — MIT

Replicazione Ogni numero che le Sezioni 5.3–5.4 calcolano a partire dai dati e dalle fixture del repository è ricalcolato da python run_all.py nel repository complementare e verificato da un test; si veda l'Appendice B.

Repository complementare Flores, C. U. (2026a), https://github.com/ulissesflores/anticipating-shadow-points

Whitepaper complementare Flores, C. U. (2026c). *Graceful Refusals as Unsignalled Failures: Characterising claude -p Exit-Code Semantics on Agent Declines.* Si veda paper/graceful-refusals.md.

Riassunto

Gli assistenti di programmazione basati su LLM producono spesso codice *localmente corretto* che omette modi di fallimento che un ingegnere esperto solleverebbe in un pre-mortem — una policy di sicurezza a livello di riga, il limite di frequenza di un'API esterna, il ritardo di replica durante una migrazione — e la produzione si rompe poi in modi costosi da diagnosticare. Chiamiamo *shadow point* questi elementi mancanti. Questo resoconto di esperienza descrive Anticipating Shadow Points (ASP), un protocollo di pianificazione in 13 fasi distribuito come skill di Claude Code che integra il pre-mortem di Klein (2007) con la tassonomia dei fallimenti multi-agente di Cemri et al. (2025), controlla il piano con un validatore che non condivide il contesto del pianificatore, seguendo la letteratura sui limiti dell'autocorrezione (Huang et al., 2024; Tyen et al., 2024), e affida l'esecuzione a un sottoprocesso figlio con un contratto su file. Documentiamo il progetto, il suo rilascio come plugin open source e osservazioni preliminari da cinque valutazioni di ingegneria, lette dall'autore senza cecità e senza trascrizioni conservate. Un giudicatore deterministico accompagna la skill; i suoi punteggi su fixture scritte dall'autore esercitano lo strumento e nient'altro, perciò non riportiamo alcun effetto misurato di ASP. Fissiamo in anticipo il risultato che lo mostrerebbe: in un benchmark in modalità reale, con liste attese cieche scritte da revisori indipendenti e otto repliche per compito e condizione, un beneficio misurato se la copertura media della condizione assistita supera quella non assistita su tutti e cinque i compiti e un test di permutazione unilaterale, stratificato per compito, dà $p < 0,05$; nessun beneficio misurabile se non la supera su tre o più; inconcludente negli altri casi; incompleto se il budget interrompe la raccolta. Il protocollo è redatto e non ancora depositato.

Parole chiave: agenti di programmazione llm; pre-mortem; modi di guasto multi-agente; claude code; protocolli operativi; resoconto di esperienza

1. Introduzione

I team di sviluppo software delegano sempre più spesso lavoro ingegneristico di routine — aggiungere una colonna a un database di produzione, distribuire una funzione che chiama un'API esterna, rifattorizzare un'utility usata in trenta file — ad assistenti di programmazione basati su IA. Quando l'assistente fa la cosa giusta, la giornata dell'ingegnere si libera. Quando sbaglia in modo *sottile* — scrivendo codice che compila, supera i propri test, va in produzione, ma omette in silenzio un passo che un ingegnere senior avrebbe segnalato in anticipo — la produzione si rompe in modi costosi da diagnosticare. La scienza delle decisioni ha una tecnica proprio per questa lacuna, il pre-mortem (Klein, 2007), e la ricerca sugli agenti dispone ora di un catalogo di come falliscono i sistemi LLM multi-agente (Cemri et al., 2025). La nostra tesi è che le due cose appartengano allo stesso posto a runtime: prima di scrivere codice, un agente dovrebbe essere costretto a eseguire un pre-mortem contro una tassonomia di fallimenti fissa, e il suo piano dovrebbe essere controllato da un validatore che non può vedere il ragionamento del pianificatore.

Il modo di fallimento dominante in produzione dei moderni agenti di programmazione LLM, nella nostra esperienza, non è il codice *sbagliato*. È il codice *incompleto*: l'agente fa ciò che gli è stato chiesto, ma non ciò che qualcuno con una profonda conoscenza del dominio si sarebbe chiesto *prima di cominciare*. Il ritardo di replica durante una migrazione di schema. L'header CORS sulla edge function. La policy di sicurezza a livello di riga che va aggiornata per corrispondere alla nuova colonna. Chiamiamo questi elementi mancanti **shadow point** — modi di guasto ovvi per un professionista che ne è stato scottato, invisibili a un agente che non lo è stato.

Due filoni di letteratura convergono su questa lacuna. Il primo, nella scienza delle decisioni, è il **pre-mortem**: un esercizio strutturato in cui un team immagina che un progetto sia già fallito ed elenca le cause prima di agire. La tecnica è stata resa operativa per i team di progetto da Klein

(2007) e fondata sul precedente lavoro empirico di Mitchell, Russo e Pennington (1989) sulla *prospective hindsight*; Klein (2007) la riassume come un aumento di circa il 30% della capacità di individuare le ragioni di un esito futuro, una cifra che non siamo riusciti a ricalcolare dall'articolo del 1989 (Appendice A). Il secondo, nella ricerca sugli agenti, è la recente caratterizzazione dei modi di fallimento multi-agente di Cemri et al. (2025), che hanno derivato una tassonomia di 14 modi da 150 tracce iniziali di sistemi LLM multi-agente (accordo tra annotatori κ=0,88) e hanno rilasciato un corpus di oltre 1.600 tracce annotate. Nessuno dei due filoni è stato integrato come **disciplina di runtime** che un agente di programmazione possa essere costretto a seguire a ogni compito non banale.

Questo articolo riferisce su **Anticipating Shadow Points (ASP)**, un protocollo di pianificazione in 13 fasi distribuito come skill di Claude Code che combina il ragionamento da pre-mortem con la checklist MAST a 14 modi, separa pianificazione e validazione con un rigoroso isolamento dei prompt e affida l'esecuzione a un sottoprocesso figlio con un contratto basato su file. Abbiamo rilasciato la skill, distribuita attraverso tre percorsi di installazione (marketplace dei plugin, modalità sviluppatore, script autonomo), l'abbiamo sottoposta a cinque valutazioni ingegneristiche e riportiamo il progetto e ciò che le valutazioni possono e non possono mostrare. La valutazione è preliminare e, come corretto in questa versione, non misurata: GREEN su cinque compiti e RED su tre, un'esecuzione ciascuno, un solo modello, letto dall'autore senza procedura in cieco, con le trascrizioni grezze non conservate. La riportiamo come osservazione qualitativa; le cinque scelte di progetto che trattiamo come ipotesi sono nella Sezione 6.

1.1. Contributi

Questo resoconto di esperienza contribuisce con:

1. **Il protocollo ASP come progetto documentato** — tredici fasi, ciascuna delle quali emette un artefatto con nome, organizzate attorno al principio che nessuna implementazione inizia prima che gli shadow point siano stati portati alla luce.
2. **Dodici vincoli operativi che chiamiamo "Iron Laws"**, ciascuno legato a una fonte primaria della letteratura o a una decisione di progetto documentata. Due hanno un controllo a livello di shell nel template del runner che all'agente viene detto di eseguire (l'output JSON obbligatorio della Iron Law 12 e il flag ASP_IN_GOAL della Iron Law 9, impostato per il figlio, il cui controllo all'ingresso è uno snippet Bash che la skill dice all'agente di eseguire); gli altri dieci sono istruzioni a livello di prompt.
3. **Osservazioni preliminari e qualitative** da cinque valutazioni ingegneristiche, e un giudicatore deterministico con provenienza crittografica, messo alla prova su fixture costruite e pronto a valutare trascrizioni reali senza fidarsi del giudizio dell'autore (gli elenchi attesi restano comunque dell'autore, e il file laterale di sinonimi facoltativo non è fornito per alcun compito).
4. **Un risultato empirico separato** sulla semantica del codice di uscita di claude -p nel rifiuto garbato dell'agente, caratterizzato nell'articolo complementare Flores (2026c). Il risultato ha motivato due delle Iron Law ma merita una caratterizzazione indipendente su un N più grande.

Questo è un **resoconto di esperienza** nel senso dell'ingegneria dei sistemi, non un articolo di benchmark. Documentiamo un sistema che abbiamo costruito, una metodologia che abbiamo adottato e ciò che abbiamo osservato; non rivendichiamo un contributo empirico solido alla letteratura sui benchmark degli agenti LLM. La Sezione 7 elenca nel dettaglio le minacce alla validità.

2. Contesto

Passiamo in rassegna quattro filoni di lavoro recente che informano direttamente il progetto di ASP (§§2.1–2.4), poi collochiamo ASP entro le discipline più antiche di ingegneria del software e della qualità che esso traspone (§2.5). Manteniamo breve la rassegna del lavoro recente rispetto ai tipici articoli sui sistemi di agenti, perché il contributo qui è operativo e il contesto bibliografico è al suo servizio.

2.1. Pre-mortem e prospective hindsight

La tecnica del pre-mortem chiede a un team di immaginare, prima di impegnarsi, che un progetto sia già fallito in modo catastrofico, e di elencarne le cause. La base empirica è Mitchell, Russo e Pennington (1989), che hanno mostrato che immaginare un evento futuro come certo (anziché incerto) produce spiegazioni più lunghe e più episodiche; Klein (2007) riassume l'effetto come un guadagno di circa il 30% nell'individuare correttamente le ragioni di un esito futuro. Klein (2007) ha reso operativo il risultato come "pre-mortem" di team di progetto, e la tecnica si è poi diffusa nella pratica della scienza delle decisioni e della gestione dei progetti. La sua base sperimentale è esile: non abbiamo trovato alcuna replica né meta-analisi dell'effetto pre-mortem in Crossref, arXiv o in una ricerca web generale (novembre 2026), il che è un'assenza in quegli indici, non la prova che non ne esistano. Gli standard di valutazione del rischio catalogano tecniche affini — l'analisi di scenario e la tecnica strutturata what-if (SWIFT) — ma l'indice dell'IEC 31010:2019, Allegato B, non elenca il pre-mortem per nome. Il termine *prospective hindsight* è stato inoltre riutilizzato per un segnale di apprendimento per rinforzo non correlato (J. Zhang et al., 2026); noi lo usiamo solo nel senso di Mitchell et al. Non abbiamo trovato alcuna integrazione precedente del pre-mortem come disciplina di runtime per agenti di programmazione.

2.2. Modi di fallimento multi-agente (MAST)

Gli agenti LLM alternano ragionamento e azione in un unico ciclo (Yao et al., 2023) e sono sempre più composti in flussi di lavoro multi-agente i cui modi di fallimento si sommano. Cemri et al. (2025) introducono la **Multi-Agent System Failure Taxonomy (MAST)** con **MAST-Data**, un corpus di oltre 1.600 tracce annotate provenienti da sette framework multi-agente diffusi come AG2 (già AutoGen; Wu et al., 2023). Da un'analisi rigorosa di 150 tracce iniziali (accordo tra annotatori κ=0,88), hanno derivato quattordici modi di fallimento organizzati in tre categorie: specifica e progetto del sistema (5 modi), disallineamento tra agenti (6 modi) e verifica e terminazione del compito (3 modi). L'elenco dei 14 modi è il più solido fondamento empirico recente per una checklist di modi di fallimento; ASP adotta alla lettera i nomi dei modi e rende operativo ciascuno in un prompt di pre-mortem più una mitigazione nei file della skill complementare. Due lavori concomitanti estendono la direzione della tassonomia: Zhu et al. (2025) introducono AgentDebug e la AgentErrorTaxonomy (memoria / riflessione / pianificazione / azione / livello di sistema), e S. Zhang et al. (2025), un ICML 2025 Spotlight, apre l'**attribuzione automatica dei fallimenti** con il dataset Who&When. MAST è dunque una tassonomia tra le altre: TRAIL formalizza una tassonomia di errori agentici su 148 tracce annotate da esseri umani (Deshpande et al., 2025), AgentRx annota 170 traiettorie fallite con un passo critico e una categoria tratta da una tassonomia fondata sui dati (grounded theory) (Barke et al., 2026), e AgenTracer riporta che gli attuali LLM di ragionamento attribuiscono i fallimenti nelle tracce multi-agente con un'accuratezza generalmente inferiore al 10% (G. Zhang et al., 2025). ASP usa MAST come libreria di prompt per anticipare i fallimenti, non come classificatore di quelli osservati, quindi la scelta della tassonomia delimita ciò che la Fase 2 chiede anziché ciò che può rilevare.

2.3. Limiti dell'autocorrezione e isolamento del validatore

L'argomento singolo più forte per separare il validatore dal pianificatore è il risultato convergente di tre lavori primari secondo cui gli LLM non riescono a criticarsi in modo affidabile sotto contesto condiviso. Huang et al. (2024, ICLR) mostrano che l'autocorrezione intrinseca senza feedback esterno spesso degrada le prestazioni. Tyen et al. (2024) scompongono l'autocorrezione in localizzazione e correzione e mostrano empiricamente che gli LLM non riescono a *localizzare* i propri errori di ragionamento ma possono correggerli se la posizione viene fornita dall'esterno — *la localizzazione è il collo di bottiglia*. Zheng et al. (2023, NeurIPS D&B) documentano che i giudici LLM forti favoriscono eccessivamente gli output di modelli della stessa famiglia (un "self-enhancement bias") anche quando giudicano oggettivamente la qualità. Kamoi et al. (2024) passano in rassegna questa letteratura e concludono che un'autocorrezione affidabile degli errori di ragionamento richiede feedback esterno o verificatori anziché il solo giudizio del modello; metodi di autofeedback intrinseco come Self-Refine (Madaan et al., 2023) migliorano alcuni compiti di generazione ma non colmano il divario di localizzazione isolato da Tyen et al. (2024). Insieme, questi risultati sostengono che un validatore che condivide il contesto con un pianificatore eredita la calibrazione della fiducia del pianificatore sui contenuti condivisi, compresi i contenuti errati di cui il pianificatore è sicuro. Il progetto di ASP impone un rigoroso isolamento dei prompt tra pianificatore e validatore (Iron Law 2 più avanti) come contromossa architetturale. Kambhampati et al. (2024) giungono alla stessa conclusione per la pianificazione: gli LLM auto-regressivi non possono da soli pianificare né auto-verificare, ma possono servire come fonti approssimate di conoscenza dentro un ciclo "LLM-Modulo" con verificatori esterni — il ruolo che ASP assegna al validatore isolato e ai test di accettazione eseguibili.

2.4. Il lavoro correlato più vicino: PreFlect

Il lavoro concomitante più vicino è **PreFlect** (Wang et al., 2026), che analogamente sposta il paradigma dell'autoriflessione dalla correzione a posteriori alla critica dei piani dell'agente prima dell'esecuzione, distillando gli errori di pianificazione dalle traiettorie storiche degli agenti e aggiungendo un meccanismo di ripianificazione dinamica. La somiglianza di fondo è significativa: sia ASP sia PreFlect individuano nel carattere solo post-esecuzione della riflessione convenzionale un limite e spostano la critica *prima* dell'azione. ASP si differenzia da PreFlect lungo quattro assi:

1. **Validatore isolato a livello di prompt.** PreFlect distilla gli errori nella critica pre-esecuzione dell'agente stesso; ASP impone un sottoagente validatore con prompt separato che non vede mai la trascrizione del pianificatore.
2. **Isolamento a livello di processo per l'esecutore.** ASP avvia l'esecutore come sottoprocesso claude -p con un contratto basato su file; PreFlect opera all'interno di un singolo processo.
3. **Vincoli di runtime espliciti.** ASP enuncia dodici Iron Law, due delle quali protette da controlli eseguibili e dieci come regole a livello di prompt; PreFlect è presentato come una metodologia anziché come un sistema di vincoli.
4. **Un risultato empirico a livello di CLI** che caratterizza la semantica del codice di uscita di claude -p nel rifiuto garbato, e che ha motivato due delle Iron Law; è riportato separatamente in Flores (2026c). Il fenomeno stesso è documentato dal fornitore e in segnalazioni pubbliche di issue (catalogate in Flores, 2026c, §2); il contributo lì è un conteggio misurato e un contratto di terminazione tipizzato proposto, non una scoperta.

2.5. La genealogia classica dell'ingegneria del software e della qualità

I quattro filoni sopra collocano ASP nella recente letteratura sugli agenti LLM. Un revisore di ingegneria del software o della qualità riconoscerà tuttavia i meccanismi di ASP come una trasposizione di discipline che precedono gli LLM di decenni. Rendiamo esplicito il prestito, perché nasconderlo sarebbe al tempo stesso disonesto e più debole: ciò che è nuovo in ASP non sono le discipline ma la loro trasposizione in un runtime di agenti non deterministico e i meccanismi che le fanno rispettare lì.

Non ridondanza contro riverifica difensiva: dove ASP si discosta dal Design by Contract. Lo schema dei micro-TODO di ASP (§3.4) è il Design by Contract (Meyer, 1992) spostato dal confine della routine al confine del compito dell'agente. Il contratto di Meyer assegna obblighi attraverso un confine tra chiamante e routine: il chiamante deve stabilire la PRECONDIZIONE, che la routine ha poi diritto di *assumere* — il principio di non ridondanza di Meyer vieta al corpo di ricontrollarla — e la routine deve garantire la POSTCONDIZIONE su cui il chiamante fa affidamento. Dei sette campi dello schema, PRECONDITION, ACTION e POSTCONDITION corrispondono direttamente a questo contratto, con ACTION come corpo della routine che la coppia pre/post racchiude. ASP poi *si discosta* da Meyer di proposito: poiché l'obbligato è un modello non deterministico anziché una routine compilata, ASP non assume la postcondizione — la riverifica con un ACCEPTANCE-TEST esterno, e aggiunge un FALSIFICATION-TEST che non ha analogo nella programmazione per contratto, importando invece la posizione popperiana (Popper, 1959/2002) secondo cui un'affermazione guadagna fiducia sopravvivendo a un tentativo di confutazione anziché da un controllo di conferma soltanto. Questo scambio della non ridondanza del Design by Contract con la riverifica difensiva è lo stesso ethos del non fidarsi di nulla che produce la disciplina dei codici di uscita delle Iron Law 11–12; è un'inversione ponderata

di Meyer, non una svista. Le Iron Law, a loro volta, sono enunciate come l'analogo del terzo elemento del contratto del DbC — l'invariante di classe — anziché come una pre/postcondizione per singolo compito; dieci di esse sono istruzioni che l'agente deve rispettare, non controlli che vengono eseguiti.

Enumerazione dei modi di guasto. Il rilevamento degli shadow point (Fase 2) è un'enumerazione prospettica dei modi di guasto nella tradizione della FMEA (MIL-STD-1629A, 1980; IEC 60812:2018). Non è deliberatamente una FMEA completa: ASP non esegue alcuna scomposizione per componente né alcun punteggio di priorità di rischio (gravità × occorrenza × rilevabilità), quindi il debito è verso la disciplina di enumerazione prospettica della FMEA, non verso i suoi meccanismi bottom-up. Tre input della Fase 2 occupano ruoli che vale la pena distinguere: il pre-mortem (Klein, 2007; §2.1) fornisce la *filosofia* — immaginare il fallimento come già certo; la tassonomia MAST a quattordici modi (Cemri et al., 2025; §2.2) fornisce la *libreria* di modi di guasto; e l'enumerazione forzata rispetto a quella libreria fissa è più vicina, strutturalmente, al prompting con parole guida in stile HAZOP (IEC 61882:2016) che alla FMEA componente per componente. Ciò che ASP aggiunge è il substrato — il "componente" di cui si enumerano i modi di guasto è un piano LLM, e l'enumerazione è eseguita da un validatore che non condivide il contesto del pianificatore (§2.3).

Prevenzione degli errori. Un sottoinsieme delle Iron Law (§3.3) sono poka-yoke (Shingo, 1986) a livello di protocollo: il template del runner in claude-p-goal-runner.md imposta ASP_IN_GOAL per il figlio e passa sempre --output-format json (Iron Law 9 e 12); il contratto basato su file della Iron Law 10 è un'istruzione. Questi controlli vivono in un template Bash che all'agente viene detto di eseguire, non in un hook al di fuori del controllo dell'agente, e non sono l'impossibilità fisica del vero poka-yoke — un flag d'ambiente può essere rimosso o non propagarsi — e le restanti

leggi sono onestamente porte procedurali (Iron Law 1, 2, 4, 5) o regole di verifica che dipendono ancora dall'operatore, di cui la Iron Law 11 ("mai fidarsi di $?") è il caso più chiaro: proprio la dipendenza dalla vigilanza dell'operatore contro cui il poka-yoke è definito. Il prestito è la *posizione* di prevenzione degli errori applicata a due controlli a livello di shell in uno script runner che all'agente viene chiesto di emettere, non l'affermazione che ASP elimini la vigilanza dell'operatore.

Verifica e validazione indipendenti. Il validatore di ASP isolato a livello di prompt (Iron Law 2) trasferisce la mossa che definisce la Verifica e Validazione Indipendenti (IV&V; IEEE Std 1012-2016) — un verificatore mantenuto indipendente dallo sviluppatore, nei termini dell'IEEE 1012 dal punto di vista tecnico, gestionale e finanziario — dalla separazione organizzativa alla separazione *di prompt*: il sottoagente validatore non condivide alcun contesto con il pianificatore che controlla. La giustificazione specifica per gli LLM di tale isolamento è la letteratura sull'autocorrezione della §2.3; la *forma* della contromossa è quella dell'IV&V.

Vocabolario della fidatezza. Il comportamento dei codici di uscita alla base delle Iron Law 11–12 ha un nome esatto nella tassonomia della fidatezza: un exit 0 su un rifiuto garbato è un *fallimento non segnalato* (Avizienis et al., 2004), né un crash né un arresto fail-silent. Il termine, la sua letteratura precedente e la misura sono sviluppati nell'articolo complementare (Flores, 2026c); questa sezione importa solo il vocabolario e non riapre qui la questione della novità.

Garanzia empirica. La preferenza per i test di accettazione e di falsificazione rispetto ai codici di stato di cui ci si fida ha una base empirica nella patologia adiacente. Yuan et al. (2014) hanno trovato che una larga maggioranza dei fallimenti catastrofici nei sistemi distribuiti ad alta intensità di dati risale alla gestione difettosa di errori non fatali che *erano* stati segnalati. Il caso del codice di uscita di ASP è il complemento — il segnale era *assente* — quindi i due non condividono una

tesi; la stretta lezione che condividono è che un canale di stato non è un sostituto dell'esito, cosa che un ACCEPTANCE-TEST esterno esiste per imporre.

Tabella 1 mappa ciascun meccanismo di ASP al suo antenato classico e indica che cosa ASP aggiunge.

Tabella 1
I meccanismi di ASP e i loro antenati classici

Meccanismo di ASP	**Antenato classico**	**Che cosa ASP aggiunge (e *non* rivendica)**
micro-TODO PRE/ACTION/POST + ACCEPTANCE-TEST	Design by Contract (Meyer, 1992)	un obbligato non deterministico la cui postcondizione è riverificata da un comando esterno, non assunta; non l'idea di contratto
micro-TODO FALSIFICATION-TEST	Falsificazione popperiana (Popper, 1959/2002)	un passo di confutazione al confine del compito dell'agente; nessun analogo nel Design by Contract
Rilevamento degli shadow point (Fase 2)	Enumerazione in stile FMEA (MIL-STD-1629A; IEC 60812:2018) + parole guida HAZOP, sulla libreria MAST (Cemri et al., 2025)	enumerazione di un piano LLM sotto isolamento; nessun punteggio di priorità di rischio, nessuna scomposizione per componente
Iron Law 9 e 12 come controlli a livello di shell	Poka-yoke (Shingo, 1986)	due controlli in uno script runner che all'agente viene chiesto di emettere; non impossibilità fisica, e la Iron Law 10 è un'istruzione
Validatore isolato a livello di prompt (Iron Law 2)	IV&V (IEEE Std 1012-2016)	indipendenza organizzativa riformulata come isolamento di prompt; non IV&V
Mai fidarsi di $? (Iron Law 11–12)	Fallimento non segnalato (Avizienis et al., 2004); Yuan et al. (2014)	caratterizzato nell'articolo complementare (Flores, 2026c); non la classe di fallimento

Letta nel suo insieme, la sezione avanza una pretesa deliberatamente modesta: i meccanismi di ASP sono un'*integrazione* di discipline consolidate di affidabilità e ingegneria della qualità — contratto, enumerazione dei modi di guasto, IV&V, prevenzione degli errori — in un unico protocollo il cui contributo è operativo anziché concettuale. Ciò che tale integrazione aggiunge oltre i suoi antenati è la loro applicazione in un runtime di agenti non deterministico: le Iron Law (due delle quali protette da controlli eseguibili), l'isolamento a livello di prompt e di processo della §3.2 e il giudicatore deterministico riproducibile della §5, con il risultato sul codice di uscita di

claude -p caratterizzato separatamente nell'articolo complementare. Questa è la tesi del resoconto di esperienza della §1, non una pretesa di novità rispetto alla letteratura classica.

3. Il protocollo ASP

3.1. Panoramica

ASP è un protocollo in 13 fasi che procede dall'acquisizione (intake) fino all'approvazione della consegna. Ogni fase emette un artefatto con nome (Tabella 2). Il principio che organizza le fasi è che nessuna implementazione inizia prima che gli shadow point siano stati portati alla luce (Fase 2), validati in modo indipendente (Fase 5) e approvati dall'utente (Fase 7); l'esecuzione è delegata a un sottoprocesso figlio con un contratto basato su file (Fase 9).

Tabella 2
Fasi di ASP e artefatti che emettono. La fase 0 ha due sotto-fasi (0a prima della ricerca, 0b dopo), perciò tredici fasi occupano quattordici righe

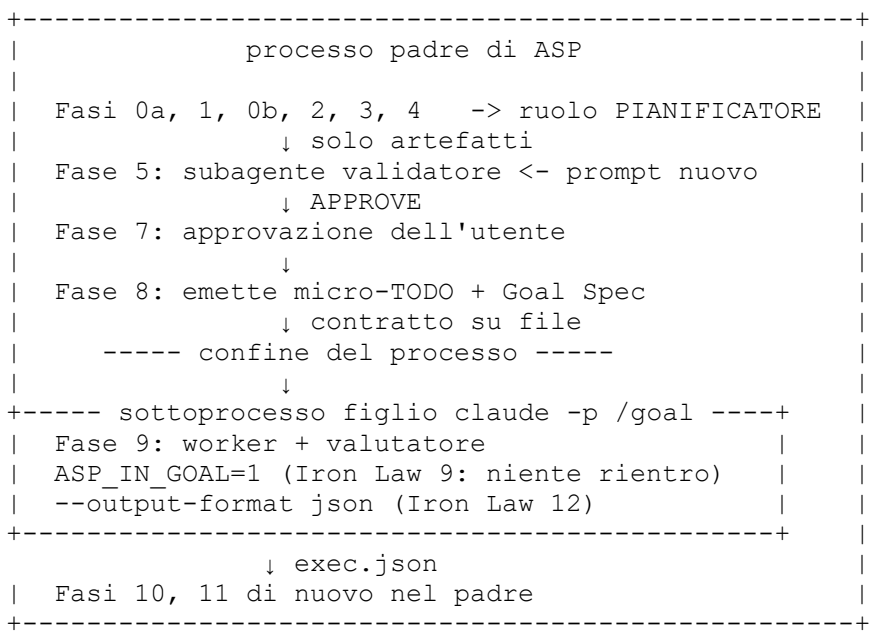
#	Fase	Artefatto	Motivazione di progetto
0a	Q&A pre-ricerca	blocco intake	Buona pratica di Anthropic Skills: output intermedi verificabili
1	Ricerca parallela	Sintesi della ricerca + blocco di recall	Pattern di dispatch dei sottoagenti
0b	Q&A post-ricerca	Intake raffinato (saltabile)	Come 0a
2	Rilevamento degli shadow point	Elenco categorizzato + mitigazioni	Klein (2007) + Cemri et al. (2025)
3	Project Charter	Charter compilata	Passaggio durevole basato su artefatti
4	Piano macro + registro	Piano macro + deliverable D01–D*n*	Plan-and-Act (Erdogan et al., 2025)
5	Validatore indipendente	APPROVE / REVISE	Huang et al. (2024) + Tyen et al. (2024) + Zheng et al. (2023)
6	Ciclo interno (limite=3)	Piano della revisione finale	Iterazione limitata; FM-1.5
7	Approvazione dell'utente	Go / no-go	Porta con intervento umano (human-in-the-loop)
8	Micro-TODO + Goal Spec	TaskCreate per passo + Goal Spec	Passaggio all'esecutore
9	Esecuzione tramite sottoprocesso /goal	Task contrassegnati come completati con evidenza	Isolamento a livello di processo; si veda Flores (2026c)
10	Approvazione per singolo deliverable	Ogni deliverable accettato o rifiutato	Contratto di accettazione

#	Fase	Artefatto	Motivazione di progetto
11	Rapporto di esecuzione + memoria	Artefatto di chiusura + scrittura in memoria	Memoria in stile Reflexion (Shinn et al., 2023)
12	Rilascio pubblico (opt-in)	Marketplace dei plugin + release GitHub	Livello di distribuzione

3.2. Posizionamento architetturale

ASP separa tre ruoli di agente con passaggi esclusivamente tramite artefatti (Figura 1):

Figura 1
La separazione di ASP in tre ruoli



Nota. Le fasi del pianificatore girano nel processo padre. Il validatore gira nel padre ma in un prompt di sottoagente nuovo che riceve solo artefatti, mai la trascrizione del pianificatore. Il worker gira in un sottoprocesso figlio claude -p con un contratto basato su file.

3.3. Iron Law

Enunciamo dodici vincoli operativi e li chiamiamo Iron Law (Tabella 3). Le Iron Law 9 e 12 hanno controlli a livello di shell nel template del runner e nello snippet d'ingresso che all'agente viene detto di eseguire; le altre sono regole che la skill istruisce l'agente a seguire. La conformità a

entrambi i tipi non è stata misurata. Ciascuna è mappata alla propria derivazione: una fonte primaria della letteratura, una raccomandazione documentata di Anthropic o una decisione di progetto empirica.

Tabella 3
Le 12 Iron Law e la loro derivazione

#	Legge	Derivazione
1	Nessuna implementazione senza prima un passaggio sugli shadow point	Klein (2007) + Cemri et al. (2025)
2	Nessuna approvazione del piano senza un passaggio di validatore indipendente (prompt separato)	Huang et al. (2024) + Tyen et al. (2024) + Zheng et al. (2023); mitiga FM-3.3
3	Nessun micro-TODO senza piano macro + charter + deliverable approvati dall'utente	Anthropic Skills: output intermedi verificabili
4	Nessun completamento di passo senza evidenza fresca del test di accettazione	Cemri et al. (2025) FM-3.1 + FM-3.2 + FM-2.6
5	Nessun deliverable accettato senza file/output di evidenza corrispondente	Cemri et al. (2025) FM-3.1
6	Nessuna chiusura di progetto senza rapporto di esecuzione + scrittura in memoria	Shinn et al. (2023) memory buffer
7	Nessun ciclo senza limite (limite predefinito=3 round di validatore)	Cemri et al. (2025) FM-1.5
8	Nessuna esecuzione di Fase 9 senza dispatch del valutatore ai checkpoint (tranne con --quick)	Erdogan et al. (2025) pianificatore/esecutore
9	Nessun ASP rientrante dentro il figlio claude -p /goal (protezione con variabile d'ambiente ASP_IN_GOAL)	Mitigazione dell'esplosione dei costi; decisione di progetto
10	Nessun avvio di claude -p /goal senza contratto basato su file	Mitigazione della divergenza di stato del sottoprocesso; decisione di progetto
11	Mai fidarsi di $? di claude -p per il successo/ fallimento semantico	Osservazione empirica, caratterizzata in Flores (2026c)
12	Tutte le invocazioni di claude -p devono usare --output-format json o stream-json	Corollario della Iron Law 11

3.4. Il contratto dei micro-TODO

Al confine tra pianificazione ed esecuzione (Fase 8), ASP emette un elenco di task contrattuale. Ogni task è creato tramite la primitiva TaskCreate con sette campi etichettati:

- **PRECONDITION** — invariante che deve valere prima del passo.
- **ACTION** — comando esatto o modifica letterale.

- **POSTCONDITION** — cambiamento di stato effettuato dal passo.
- **ACCEPTANCE-TEST** — comando e output atteso che dimostrano la postcondizione.
- **FALSIFICATION-TEST** — comando od osservazione che dimostrerebbe il fallimento del passo.
- **DEPENDS-ON** — identificatori dei task a monte (struttura a DAG).
- **DELIVERABLE-ID** — a quale deliverable del registro contribuisce questo passo.

Questo schema è ciò che rende verificabile l'elenco dei task: nessun task è contrassegnato come completato senza evidenza del test di accettazione (Iron Law 4); nessun deliverable è approvato senza evidenza corrispondente (Iron Law 5). Lo schema è condiviso con la Goal Spec consumata dal sottoprocesso della Fase 9.

4. Rilascio operativo

ASP è distribuito come plugin di Claude Code attraverso tre percorsi di installazione, ciascuno adatto a un pubblico diverso:

1. **Marketplace dei plugin** (consigliato per gli utenti finali):

   ```
   claude plugin marketplace add ulissesflores/anticipating-shadow-points
   claude plugin install anticipating-shadow-points@anticipating-shadow-points
   ```

   Invocazione: /anticipating-shadow-points:asp <task> oppure semplicemente /asp.

2. **Modalità sviluppatore** (per i contributori): claude --plugin-dir ./ carica la skill sul posto; utile quando si itera sulla skill stessa.

3. **Script di installazione autonomo** (per chi non usa il gestore di plugin):

   ./scripts/install.sh copia la skill nella directory delle skill di Claude Code dell'utente.

Il plugin usa il formato ufficiale di manifest .claude-plugin/plugin.json di Anthropic (Claude Code 2.1+; Anthropic, 2026a), e il repository funge anche da marketplace self-hosted tramite .claude-plugin/marketplace.json nella radice del repository.

Permessi. Dalla versione 1.0.4 del plugin il runner della Fase 9 avvia il figlio claude -p **senza alcun flag di permesso**: il figlio gira con le impostazioni di permesso di Claude Code dell'utente stesso, e la skill non li concede, non li amplia né li aggira mai. Le versioni precedenti passavano --permission-mode bypassPermissions; ciò è stato rimosso dopo che la directory dei plugin di Claude ha rifiutato l'inserimento, perché un plugin non deve concedersi permessi da sé. In modalità non interattiva un'azione che l'utente non ha preautorizzato viene negata anziché richiesta; il padre legge il campo permission_denials del risultato JSON del figlio e segnala all'utente ogni diniego anziché riprovare con un permesso più ampio. Questo rende l'esecuzione autonoma strettamente più debole che nel rilascio di maggio 2026, e più sicura: la skill può fare solo ciò che l'operatore ha già consentito. La skill stessa è implementata come skill in Markdown secondo il documento di buone pratiche delle Agent Skills di Anthropic (Anthropic, 2026b), con file complementari per la checklist MAST, i prompt di pre-mortem per singolo modo e i sette template di artefatto citati nella Sezione 3.1.

La documentazione è pubblicata come sito GitHub Pages, con traduzioni del README in spagnolo, portoghese, italiano ed ebraico; le ultime tre sono assistite da IA e in attesa di revisione da parte di madrelingua. Il codice sorgente completo — file della skill, manifest dei plugin, documentazione, artefatti di test, codice del benchmark — è concesso in licenza MIT; il testo del paper, le figure e i dati sono CC BY 4.0.

5. Osservazioni preliminari

Abbiamo sottoposto ASP a cinque valutazioni ingegneristiche strutturate che coprono domini eterogenei. Questa sezione separa tre cose che la versione 1.0 confondeva: ciò che l'autore ha osservato in esecuzioni reali del modello (5.2), ciò che il giudicatore deterministico mostra di sé su fixture costruite (5.3) e ciò che non è stato affatto misurato.

5.1. L'insieme di valutazioni

Tabella 4
Le cinque valutazioni ingegneristiche

ID	Dominio	Compito (abbreviato)	Dimensione attesa	Accettazione
E1	Migrazione di schema	Colonna NOT NULL aggiunta a user_profiles da 1M righe	10	≥ 80%
E2	Deploy su edge	Edge function che chiama un'API esterna con rate limit	10	≥ 80%
E3	Refactoring	Utility di formattazione delle date usata in oltre 30 file	10	≥ 80%
E4	Policy RLS	Policy di sicurezza a livello di riga che fa riferimento a una nuova colonna	10	≥ 80%
E5	Pianificazione	Cron job il cui script è in conflitto con un servizio disattivato	10	≥ 80%

Ogni valutazione specifica un INPUT (un enunciato del compito come un ingegnere senior potrebbe formularlo a un collega), un elenco EXPECTED di shadow point che un professionista competente farebbe emergere e una soglia di ACCEPTANCE (predefinita 80%). E5 non è portabile: due dei suoi dieci punti attesi (1 e 8) dipendono dalla memoria privata di progetto dell'autore e non possono emergere dal solo INPUT, perciò misura il richiamo dalla memoria tanto quanto la pianificazione. Il testo completo di ciascuna valutazione è nel repository complementare.

5.2. Che cosa è stato osservato in esecuzioni reali (autore, non in cieco)

Il 2026-05-17 le valutazioni sono state assegnate a sottoagenti nuovi: GREEN (con la disciplina ASP iniettata: inquadramento da pre-mortem, enumerazione forzata dei 14 modi MAST, obbligo di mitigazione) su tutte e cinque, e RED (a cui era chiesto di pianificare come farebbe un ingegnere senior, senza alcun framework) su tre, E1–E3; E4 ed E5 sono state aggiunte dopo ed eseguite solo in GREEN. Tutte sono girate sul modello di sessione dell'epoca (Claude Opus 4.7; il modello non è stato registrato per singola esecuzione), un'esecuzione per condizione. I sottoagenti hanno ereditato le istruzioni globali dell'agente dell'autore, perciò la condizione RED era una base di riferimento competente, non ingenua. L'autore ha letto ogni piano rispetto all'elenco atteso e ha registrato un giudizio di copertura; i riepiloghi, con gli identificatori dei sottoagenti, sono sottoposti a commit in tests/baseline-pressure-tests.md e tests/evals-summary.md. Le trascrizioni grezze non sono state sottoposte a commit e non sono più disponibili. I prompt RED lì registrati sono formulazioni in portoghese più brevi di E1–E3 che omettono dettagli che gli elenchi attesi valutano poi: il prompt RED di E2 non indica il limite di frequenza di 100 req/s di Resend, e quello di E1 non dice che il codice dell'applicazione fa già riferimento alla nuova colonna in cinque punti di query. Parte del divario di RED può dunque essere un artefatto del prompt, non dell'assenza del protocollo.

Con questa lettura non in cieco, i tre piani RED hanno coperto all'incirca il 30–60% dei rispettivi elenchi attesi (media prossima al 47%, contando le menzioni parziali come coperte) e i piani GREEN hanno coperto tutti o quasi i propri. I riepiloghi sottoposti a commit, scritti a maggio 2026, concludono che ASP è "riproducibilmente migliore" (traduzione nostra); una nota aggiunta sopra di essi nella versione 2.0 ritira quella conclusione, che non è sostenuta. Queste cifre sono un giudizio dell'autore su testo non conservato, valutato rispetto a elenchi scritti dallo stesso autore,

e con il vocabolario MAST iniettato dal prompt GREEN che compare in quegli elenchi. Sono riportate come osservazione, non come misura, e nessun numero di questo paragrafo è verificato dal livello di replicazione.

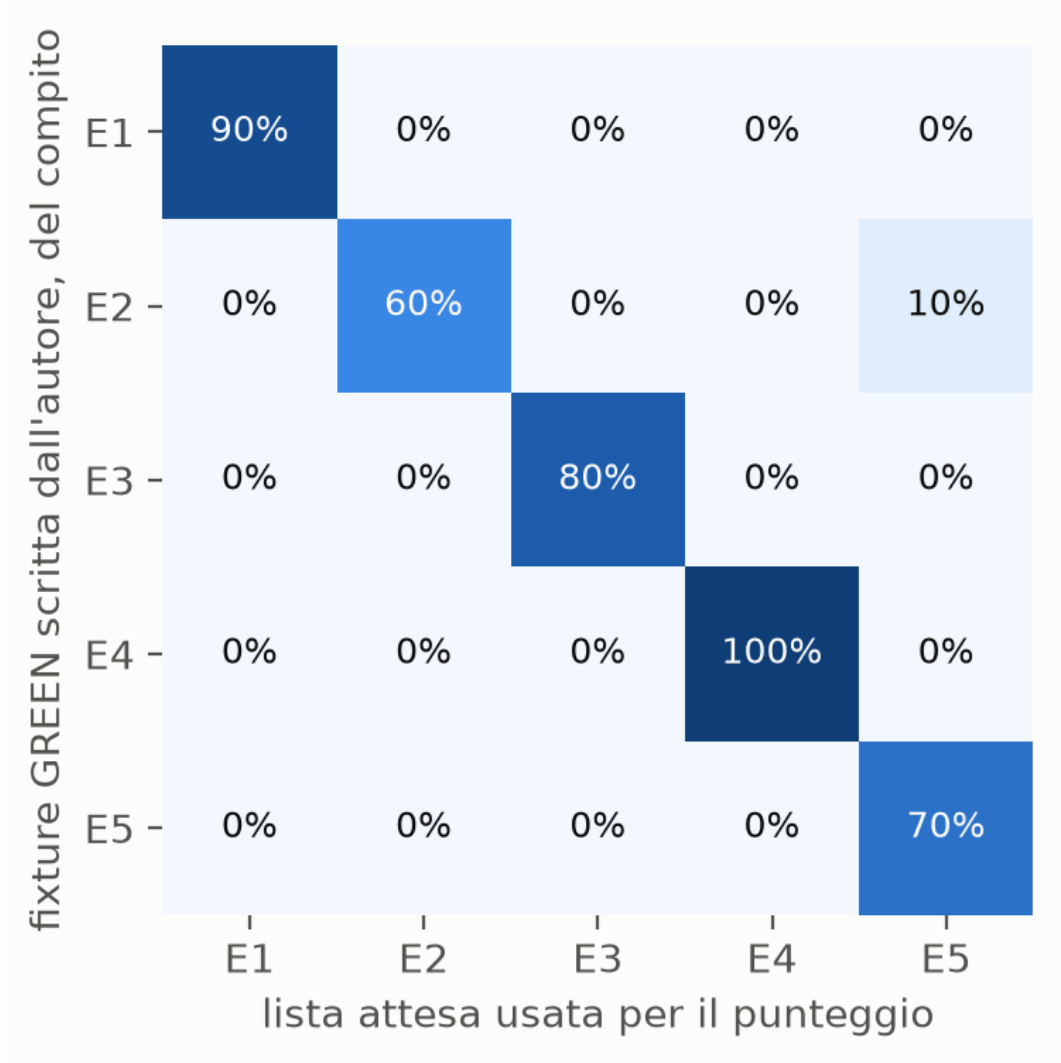
5.3. Che cosa mostra il giudicatore deterministico di sé

Il pacchetto benchmark/ valuta un piano rispetto a un elenco atteso con un matcher deterministico a 4 livelli (nome esatto, file laterale di sinonimi, finestra scorrevole di Jaccard, non corrispondente). Nell'esecuzione pubblicata tutte le 42 corrispondenze provengono dal primo livello (nome esatto); non esiste alcun file laterale di sinonimi per alcun compito, e il livello di Jaccard non scatta mai. La sua unica esecuzione pubblicata è un'esecuzione in **modalità mock**: i testi RED e GREEN sono fixture che l'autore ha scritto per esercitare la pipeline da un capo all'altro (benchmark/tests/fixtures/mock_runs/); su di esse i livelli 2 e 3 non producono mai una corrispondenza (le sovrapposizioni del livello 3 sono calcolate e restano sotto la soglia), e solo i test unitari esercitano una corrispondenza attraverso quei livelli, deliberatamente più deboli per RED e deliberatamente allineati all'elenco atteso per GREEN. Su quelle fixture il matcher valuta RED al 4% e GREEN all'80% in media — un'affermazione su come sono state scritte le fixture, non su ASP.

La proprietà utile che l'esecuzione mock stabilisce è la **discriminazione**: valutare ciascuna fixture GREEN rispetto all'elenco atteso di un compito *diverso* abbassa la media dall'80% allo 0,5% (la cella fuori compito più alta 10%; Figura 2). È un'evidenza più debole di quanto sembri: l'unica corrispondenza fuori compito è il nome generico di una sola parola "Alerting", e le altre celle sono zero perché il livello 1 richiede che un intero nome atteso compaia alla lettera. Il matcher è inoltre più severo dei file di valutazione, che dicono a un valutatore umano di accettare le parafrasi. Il recall è una questione a parte, e le fixture mostrano un falso negativo: la fixture RED di E2

menziona un rate limit, i retry e il logging e ottiene comunque 0/10: la sua migliore sovrapposizione di finestra con il punto atteso “Rate-limit backoff” (il suo nome e la sua descrizione) è un Jaccard di 0,11, sotto la soglia di 0,30, e il matcher non fa stemming (“logging” non corrisponde a “logs”). Le parafrasi con bassa sovrapposizione lessicale sfuggono. La rivalutazione ha inoltre portato alla luce un difetto, corretto nella v2.0: la finestra scorrevole saltava gli ultimi token di un testo la cui lunghezza non cadeva sul passo; rivalutare ogni fixture con la correzione non cambia alcun valore di copertura, benché la migliore sovrapposizione di tre punti non corrispondenti salga leggermente (E2 RED “Observability / logs” da 0,00 a 0,02), restando ben al di sotto della soglia. Il livello 3 ha anche un tetto aritmetico: Jaccard divide per l’unione, e una finestra di 40 token delle fixture contiene da 27 a 40 parole di contenuto distinte (mediana 36); in qualsiasi finestra con 34 o più, un punto atteso con dieci o meno token distinti non può raggiungere 0,30 nemmeno se il piano li ripete tutti, e 19 dei 50 punti attesi sono così brevi. Il protocollo in modalità reale cambia perciò il livello 3 prima del deposito (PREREGISTRATION.md). Il matcher non è ancora stato applicato ad alcuna trascrizione reale. Il protocollo in modalità reale, con elenchi attesi riscritti in cieco da ingegneri indipendenti, è specificato nel PREREGISTRATION.md del repository e non è stato eseguito. La sua regola decisionale è fissata in anticipo: con otto repliche per compito e condizione (80 esecuzioni), un beneficio è riportato solo se la copertura media della condizione assistita supera quella della non assistita su tutti e cinque i compiti e un test di permutazione unilaterale, stratificato per compito, sulla differenza media per compito (10 000 riassegnazioni delle etichette, seme asp-bench-v1) dà $p < 0,05$; nessun beneficio misurabile se non lo fa su tre o più; inconcludente altrimenti; incompleto se il budget interrompe la raccolta. La copertura sarà riportata per livello di matcher, poiché il livello 1 premia un piano che riusa alla lettera i nomi attesi.

Figura 2
Verifica dello strumento: ogni fixture GREEN costruita dall'autore valutata rispetto all'elenco atteso di ogni compito. Non è un effetto di ASP



Quale componente conterebbe di più, se ASP ha un effetto, è discusso come ipotesi nella Sezione 6.

5.4. Il risultato sul codice di uscita di claude -p

Durante una batteria di quattro test contro il runner non interattivo claude -p, abbiamo osservato che il binario restituisce codice di uscita 0 anche quando l'agente rifiuta garbatamente l'obiettivo richiesto — l'harness riporta una conclusione riuscita della conversazione nonostante l'agente

rifiuti semanticamente il compito. Il codice di uscita riflette il successo a livello di processo del binario della CLI, non il successo semantico del compito dell'agente. Le Iron Law 11 e 12 richiedono --output-format json e la lettura di is_error, terminal_reason e stop_reason. Quei campi separano un'interruzione per limite di turni e un rifiuto del classificatore da un turno completato, ma non un rifiuto generato dal modello da una consegna; il runner segnala perciò anche le risposte il cui testo corrisponde a un pattern di rifiuto, un'euristica che l'articolo complementare mette alla prova.

Questo risultato è significativo sul piano osservativo per qualsiasi toolchain che incapsuli claude -p in una pipeline di shell. Poiché l'osservazione proveniva da un singolo scenario di rifiuto nella nostra batteria, lo **caratterizziamo in modo indipendente** nell'articolo complementare Flores (2026c), che riporta una misura su N=50 in quattro categorie di prompt che provocano un rifiuto (impossibile in un solo turno, capacità, sicurezza, ambiguità) su Claude Code 2.1.200 a luglio 2026. Il modello di sessione era Fable 5; Opus 4.8 ha risposto a 16 dei 50 prompt, compresi tutti i 12 prompt di sicurezza — coerentemente con un passaggio automatico a un modello di riserva, benché gli envelope registrino quale modello ha risposto, non perché. Ventiquattro prove sono uscite con 0, tutte con stop_reason: end_turn. L'articolo complementare conta in quattro modi i rifiuti tra di esse: 20 (40%, IC di Wilson al 95% 28–54%) con l'etichetta non in cieco dell'autore; 19 (38%) con la maggioranza di un codebook, scritto dopo che l'autore aveva letto le risposte, e applicato da cinque valutatori LLM, quattro dei quali hanno restituito etichette identiche, tutti della stessa famiglia del modello sotto test, così che la maggioranza è un controllo del codebook, non una stima dell'accordo tra valutatori; 12 (24%) contando solo i rifiuti di sicurezza e di comandi distruttivi ed escludendo gli otto rifiuti motivati di compiti impossibili in un solo turno; e 9 (18%) con il rilevatore di frasi bloccato solo in inglese, che non coglie le risposte scritte in portoghese.

Un'istantanea precedente (maggio 2026, Claude Code 2.1.143, Opus 4.7) dava il 60% con lo stesso rilevatore, su un modello e una lingua di risposta diversi. Un secondo valutatore umano e una terza istantanea secondo una preregistrazione redatta sono i seguiti ancora aperti.

6. Ipotesi di progetto

Evidenziamo cinque scelte di progetto che riteniamo portanti. Le prime quattro sono ipotesi su ASP che nessun dato qui misura, ciascuna enunciata con l'osservazione che l'ha motivata; la quinta poggia sulla misura dell'articolo complementare.

Ipotesi: una tassonomia forzata fa emergere più di un pre-mortem a forma libera. Nelle bozze dell'autore, il pre-mortem a forma libera si concentrava sulle categorie di rischio ovvie (dati, integrazione) e sottopesava quelle meno salienti (tempo/fuso orario, osservabilità, eccellenza operativa, deriva dei contratti). Nessuna esecuzione ha messo alla prova il pre-mortem a forma libera come condizione (RED non aveva alcun framework), perciò ciò poggia sulla lettura delle bozze da parte dell'autore. Il prompt a forma libera ("immagina che il compito sia fallito tra 30 giorni; elenca oltre 10 cause") sarebbe allora necessario ma non sufficiente, e l'interrogazione MAST a 14 modi farebbe emergere categorie da cui il passaggio a forma libera si allontana.

Ipotesi: l'isolamento di prompt del validatore conta. Ci aspettiamo che i validatori che condividono il contesto con i pianificatori riproducano la fiducia del pianificatore sui contenuti condivisi. La letteratura convergente sui limiti dell'autocorrezione intrinseca, sul fallimento della localizzazione degli errori e sul self-enhancement bias dei giudici indica tutta questa direzione; non l'abbiamo messo alla prova dentro ASP.

Ipotesi: i passaggi basati su file reggono meglio alla pressione sul contesto di quelli basati sulla trascrizione. ASP scrive su disco charter, piano macro, registro dei deliverable e goal spec

prima che l'esecutore venga avviato. Il figlio riceve su stdin solo il testo della Goal Spec e restituisce un risultato JSON; il padre ricostruisce lo stato da quel risultato e dai file su disco, così nessuno dei due dipende da una trascrizione che potrebbe essere stata compressa o troncata. Non abbiamo confrontato i due tipi di passaggio.

Ipotesi: i vincoli enunciati (Iron Law) rendono una skill più difficile da saltare. Nella nostra esperienza, le skill che si leggono come "linee guida" vengono spesso saltate sotto pressione sul contesto. Le skill che emettono una checklist di punti non negoziabili, con template i cui campi vanno compilati prima della fase successiva, sono nel nostro uso più difficili da saltare. Il rispetto non è stato misurato.

Misurato altrove: trattare i codici di uscita di claude -p come segnali di successo semantico è una trappola silenziosa. Questo è il risultato riportato in Flores (2026c); lo menzioniamo qui perché l'implicazione di progetto (Iron Law 11 e 12) è stata rilevante per l'affidabilità del sistema.

7. Minacce alla validità

Trattiamo le minacce in modo esplicito nelle quattro categorie standard dei resoconti empirici di ingegneria del software.

Validità di costrutto. Lo stesso ricercatore che ha progettato il protocollo ha scritto gli elenchi degli shadow point attesi *e* ha giudicato a mano la copertura. Anche con una rubrica scritta, questa è la singola minaccia maggiore all'interpretabilità dell'osservazione. Il giudicatore deterministico che distribuiamo la mitigherebbe una volta applicato a trascrizioni reali e conservate; in questa versione è stato eseguito solo su fixture costruite (§5.3), e non affronta la questione preliminare se gli elenchi attesi stessi siano sbilanciati verso ciò che ASP fa emergere. **La riscrittura in cieco da parte di revisori indipendenti è il seguito più forte.**

Validità interna. Con un'esecuzione per cella, GREEN su cinque compiti e RED su tre, la valutazione al più suggerisce che il protocollo possa cambiare le trascrizioni in questi casi; *non* è sufficiente per stimare una dimensione dell'effetto, stabilire causalità o sostenere inferenza statistica, e non è riportato alcun test statistico. Non è stata eseguita alcuna ablazione formale dei componenti (l'attribuzione qualitativa di ruolo portante alla checklist MAST nella §6 è un'ipotesi). La soglia di accettazione dell'80% è una scelta dell'autore e non è derivata dalla letteratura precedente.

Validità esterna. Un solo modello sottostante (Claude Opus 4.7, presunto dalla sessione; non registrato per singola esecuzione), un solo ambiente (la workstation macOS dell'autore e la versione di Claude Code di maggio 2026, non registrata per singola esecuzione), cinque compiti ingegneristici tratti dall'esperienza di dominio dell'autore. Non rivendichiamo alcuna generalizzazione oltre queste condizioni.

Affidabilità. Tutti gli enunciati INPUT delle valutazioni, gli elenchi degli shadow point attesi, le fixture delle esecuzioni mock e il codice del giudicatore deterministico sono sottoposti a commit nel repository complementare; le trascrizioni delle esecuzioni del 2026-05-17 non sono state conservate, perciò le osservazioni della §5.2 non possono essere ricontrollate. Il pacchetto di benchmark costruisce per ogni esecuzione un manifest concatenato crittograficamente, così che qualsiasi byte modificato sotto una directory di esecuzione invalida l'hash del manifest.

8. Limiti e lavori futuri

I limiti di questo resoconto di esperienza corrispondono uno a uno alle minacce qui sopra. I seguiti a priorità più alta, in ordine, sono:

1. **Riscrittura in cieco** degli elenchi degli shadow point attesi da parte di 2+ revisori indipendenti senza alcuna esposizione ad ASP, poi un'esecuzione in modalità reale le cui trascrizioni siano conservate e sigillate con hash, giudicata in cieco. Calcolare il κ di Cohen per l'accordo tra giudicatori; misurare di nuovo la copertura.
2. **Ablazione formale** dell'ipotesi portante: checklist MAST attiva/disattiva (verificando l'ipotesi della §6), isolamento di prompt del validatore attivo/disattivo, intake della Fase 0a attivo/disattivo. Non esiste ancora alcun protocollo di ablazione; il Protocollo 2 di PREREGISTRATION.md copre solo RED contro GREEN, con 8 repliche per cella con un budget fisso anziché un'analisi di potenza.
3. **Un secondo valutatore umano e una terza istantanea di claude -p** per il risultato complementare (Flores, 2026c, §8), quest'ultima secondo il Protocollo 1 di PREREGISTRATION.md.
4. **Valutazione cross-modello.** Rieseguire su Claude Sonnet, GPT-5, Gemini 2.5 e un modello a pesi aperti.
5. **Confronto diretto con PreFlect.** Eseguire ASP e una reimplementazione di PreFlect sullo stesso insieme di compiti.
6. **Giudicatore basato su embedding** come v0.2 del benchmark, con modello sentence-transformer fissato, per alzare la soglia minima di recall sulle parafrasi lessicalmente disgiunte.
7. **Replicazione su benchmark standardizzato.** L'insieme di cinque compiti non è un benchmark pubblico per agenti; replicare la direzione su SWE-bench (Jimenez et al.,

2024) o su una suite standardizzata comparabile verificherebbe se regge fuori dai compiti scelti dall'autore.

8. **Revisione da parte di madrelingua** delle traduzioni della documentazione in ES, IT ed HE.
9. **Sede di sottomissione.** Le sedi workshop — NeurIPS LLM-agents track, ICLR agents workshop, AAAI agents track — sono la scelta adatta alla scala empirica attuale. La sottomissione al main track richiede i seguiti di cui sopra.

9. Conclusione

Abbiamo descritto ASP, una skill operativa di pre-mortem per agenti di programmazione LLM, che integra il risultato sulla *prospective hindsight* di Mitchell, Russo e Pennington (1989), la resa operativa del pre-mortem di Klein (2007) e la tassonomia dei fallimenti a 14 modi MAST di Cemri et al. (2025) come disciplina di runtime sotto un contratto di dodici Iron Law. La skill è distribuita open source con tre percorsi di installazione. Sui tre compiti eseguiti in entrambe le condizioni l'autore ha osservato, senza procedura in cieco e su trascrizioni che non sono state conservate, che i piani assistiti coprivano una quota maggiore dei modi di fallimento attesi; non è stato misurato alcun effetto. Il giudicatore deterministico distribuito con la skill è stato esercitato solo su fixture costruite, dove separa interi nomi attesi ma non ha un recall misurato; un'esecuzione in modalità reale con elenchi scritti in modo indipendente, redatta per la preregistrazione, è il prossimo passo decisivo.

Abbiamo inoltre osservato che claude -p restituisce codice di uscita 0 anche quando l'agente rifiuta garbatamente l'obiettivo richiesto. Il fornitore documenta il comportamento per la sua API; l'articolo complementare (Flores, 2026c) aggiunge un conteggio al confine della CLI.

Il seguito più forte è la nuova valutazione in cieco. Il lavoro complementare più utile è un secondo valutatore umano e una terza istantanea preregistrata della misura su claude -p (Flores, 2026c).

Ringraziamenti

Questo resoconto di esperienza è stato preparato in esplicita collaborazione con intervento umano (human-in-the-loop) con Claude (Anthropic, Opus 4.7), usato come partner di stesura, verifica e revisione. Le decisioni metodologiche, il disegno empirico e la finalizzazione sono stati svolti dall'autore umano. Il modello di collaborazione è documentato in docs/ARCHITECTURE.md, Parti 5–6, del repository complementare.

L'autore ringrazia i manutentori del framework di skill obra/superpowers, i contributori dello standard aperto agentskills.io e il team di Claude Code di Anthropic per la primitiva /goal il cui comportamento empirico ha motivato le Iron Law 11 e 12.

Riferimenti bibliografici (APA, 7ª edizione)

Anthropic. (2026a). *Claude Code* [Software documentation]. https://code.claude.com

Anthropic. (2026b). *Agent Skills best practices* [Software documentation]. https://platform.claude.com/docs/en/agents-and-tools/agent-skills/best-practices

Avizienis, A., Laprie, J.-C., Randell, B., & Landwehr, C. (2004). Basic concepts and taxonomy of dependable and secure computing. *IEEE Transactions on Dependable and Secure Computing*, *1*(1), 11–33. https://doi.org/10.1109/TDSC.2004.2

Barke, S., Goyal, A., Khare, A., Singh, A., Nath, S., & Bansal, C. (2026). *AgentRx: Diagnosing AI agent failures from execution trajectories*. arXiv:2602.02475. https://arxiv.org/abs/2602.02475

Cemri, M., Pan, M. Z., Yang, S., Agrawal, L. A., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Klein, D., Ramchandran, K., Zaharia, M., Gonzalez, J. E., & Stoica, I. (2025). Why do multi-agent LLM systems fail? *Advances in Neural Information Processing Systems, 38*, 135676–135729. https://doi.org/10.52202/085713-4082

Deshpande, D., Gangal, V., Mehta, H., Krishnan, J., Kannappan, A., & Qian, R. (2025). *TRAIL: Trace reasoning and agentic issue localization*. arXiv:2505.08638. https://arxiv.org/abs/2505.08638

Erdogan, L. E., Lee, N., Kim, S., Moon, S., Furuta, H., Anumanchipalli, G., Keutzer, K., & Gholami, A. (2025). *Plan-and-Act: Improving planning of agents for long-horizon tasks*. ICML 2025. https://arxiv.org/abs/2503.09572

Flores, C. U. (2026a). *ASP — Anticipating Shadow Points: Claude Code plugin and replication package* (Version 2.0.0) [Computer software].

https://github.com/ulissesflores/anticipating-shadow-points. https://doi.org/10.5281/zenodo.20276631

Flores, C. U. (2026c). *Graceful refusals as unsignalled failures: Characterising claude -p exit-code semantics on agent declines* (Version 2.2) [Technical note]. In Flores (2026a). https://doi.org/10.5281/zenodo.20276631

Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). *Large language models cannot self-correct reasoning yet*. ICLR 2024. https://arxiv.org/abs/2310.01798

IEEE. (2017). *IEEE standard for system, software, and hardware verification and validation* (IEEE Std 1012-2016). https://doi.org/10.1109/IEEESTD.2017.8055462

International Electrotechnical Commission. (2016). *Hazard and operability studies (HAZOP studies) — Application guide* (IEC 61882:2016, Edition 2.0). https://webstore.iec.ch/en/publication/24321

International Electrotechnical Commission. (2018). *Failure modes and effects analysis (FMEA and FMECA)* (IEC 60812:2018). https://webstore.iec.ch/en/publication/26359

International Electrotechnical Commission. (2019). *Risk management — Risk assessment techniques* (IEC 31010:2019, Edition 2.0). https://webstore.iec.ch/en/publication/59809

Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). *SWE-bench: Can language models resolve real-world GitHub issues?* ICLR 2024. https://arxiv.org/abs/2310.06770

Kambhampati, S., Valmeekam, K., Guan, L., Verma, M., Stechly, K., Bhambri, S., Saldyt, L., & Murthy, A. (2024). *LLMs can't plan, but can help planning in LLM-Modulo frameworks*. ICML 2024 (position paper). https://arxiv.org/abs/2402.01817

Kamoi, R., Zhang, Y., Zhang, N., Han, J., & Zhang, R. (2024). When can LLMs actually correct their own mistakes? A critical survey of self-correction of LLMs. *Transactions of the Association for Computational Linguistics*. https://arxiv.org/abs/2406.01297

Klein, G. (2007). Performing a project premortem. *Harvard Business Review*, *85*(9), 18–19.

Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegreffe, S., Alon, U., Dziri, N., Prabhumoye, S., Yang, Y., Gupta, S., Majumder, B. P., Hermann, K., Welleck, S., Yazdanbakhsh, A., & Clark, P. (2023). *Self-Refine: Iterative refinement with self-feedback*. NeurIPS 2023. https://arxiv.org/abs/2303.17651

Meyer, B. (1992). Applying "design by contract." *Computer*, *25*(10), 40–51. https://doi.org/10.1109/2.161279

Mitchell, D. J., Russo, J. E., & Pennington, N. (1989). Back to the future: Temporal perspective in the explanation of events. *Journal of Behavioral Decision Making*, *2*(1), 25–38. https://doi.org/10.1002/bdm.3960020103

Popper, K. R. (2002). *The logic of scientific discovery*. Routledge. (Original work published 1959)

Shingo, S. (1986). *Zero quality control: Source inspection and the poka-yoke system* (A. P. Dillon, Trans.). Productivity Press. (Original work published 1985)

Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., & Yao, S. (2023). *Reflexion: Language agents with verbal reinforcement learning*. NeurIPS 2023. https://arxiv.org/abs/2303.11366

Tyen, G., Mansoor, H., Cărbune, V., Chen, P., & Mak, T. (2024). LLMs cannot find reasoning errors, but can correct them given the error location. In *Findings of the Association for Computational Linguistics: ACL 2024*. https://arxiv.org/abs/2311.08516

U.S. Department of Defense. (1980). *Procedures for performing a failure mode, effects and criticality analysis* (MIL-STD-1629A). https://everyspec.com/MIL-STD/MIL-STD-1600-1699/MIL_STD_1629A_1556/

Wang, H., Cao, Y., Lin, L., & Chen, J. (2026). *PreFlect: From retrospective to prospective reflection in large language model agents*. arXiv. https://arxiv.org/abs/2602.07187

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). *AutoGen: Enabling next-gen LLM applications via multi-agent conversation*. arXiv. https://arxiv.org/abs/2308.08155

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). *ReAct: Synergizing reasoning and acting in language models*. ICLR 2023. https://arxiv.org/abs/2210.03629

Yuan, D., Luo, Y., Zhuang, X., Rodrigues, G. R., Zhao, X., Zhang, Y., Jain, P. U., & Stumm, M. (2014). Simple testing can prevent most critical failures: An analysis of production failures in distributed data-intensive systems. In *Proceedings of the 11th USENIX Symposium on Operating Systems Design and Implementation (OSDI '14)* (pp. 249–265). USENIX Association. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/yuan

Zhang, G., Wang, J., Chen, J., Zhou, W., Wang, K., & Yan, S. (2025). *AgenTracer: Who is inducing failure in the LLM agentic systems?* arXiv:2509.03312. https://arxiv.org/abs/2509.03312

Zhang, J., Peng, X., Chen, Q., Li, Y., Hayashi, H., & Wu, C.-S. (2026). *Prospective hindsight: Self-calibrating reinforcement learning via prediction-reality gaps*. arXiv:2610.02740. https://arxiv.org/abs/2610.02740

Zhang, S., Yin, M., Zhang, J., Liu, J., Han, Z., Zhang, J., Li, B., Wang, C., Wang, H., Chen, Y., & Wu, Q. (2025). *Which agent causes task failures and when? On automated failure attribution of LLM multi-agent systems*. ICML 2025 Spotlight. https://arxiv.org/abs/2505.00212

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS 2023 D&B. https://arxiv.org/abs/2306.05685

Zhu, K., Liu, Z., Li, B., Tian, M., Yang, Y., Zhang, J., Han, P., Xie, Q., Cui, F., Zhang, W., Ma, X., Yu, X., Ramesh, G., Wu, J., Liu, Z., Lu, P., Zou, J., & You, J. (2025). *Where LLM agents fail and how they can learn from failures*. arXiv. https://arxiv.org/abs/2509.25370

Appendice A — Stato della verifica delle citazioni

Ogni affermazione nel corpo del testo cita una fonte primaria ove ne esista una. I paragrafi che seguono registrano quando ciascun gruppo di riferimenti è stato controllato.

I riferimenti presenti nella versione 1.0 sono stati verificati con un recupero diretto dell'URL il 2026-05-17; i riferimenti aggiunti nella revisione di luglio 2026 (Flores, 2026c; le voci della genealogia classica della Sezione 2.5) sono stati controllati al momento dell'aggiunta; e le voci aggiunte a novembre 2026 (Barke et al., 2026; Deshpande et al., 2025; Kambhampati et al., 2024; G. Zhang et al., 2025; J. Zhang et al., 2026) sono state controllate rispetto ai loro record arXiv, e Cemri et al. (2025) rispetto al suo record negli atti di NeurIPS. I nomi dei 14 modi MAST sono citati alla lettera da Cemri et al. (2025) ed elencati nel file della skill complementare skills/anticipating-shadow-points/mast-checklist.md. Mitchell et al. (1989) è lo studio primario sulla prospective hindsight; la cifra del ≈30% è il riassunto che ne dà Klein (2007), che non siamo riusciti a ricalcolare dall'articolo del 1989, e Klein (2007) è anche la ricetta operativa.

I nove riferimenti introdotti nella §2.5 (Avizienis et al., 2004; International Electrotechnical Commission [IEC 60812:2018], 2018; International Electrotechnical Commission [IEC 61882:2016], 2016, controllato rispetto al catalogo IEC il 2026-11-07; IEEE [Std 1012-2016], 2017; Meyer, 1992; Popper, 1959/2002; Shingo, 1986; U.S. Department of Defense [MIL-STD-1629A], 1980; Yuan et al., 2014) sono stati verificati rispetto alla loro fonte primaria — DOI, ISBN o voce di catalogo dello standard — il 2026-07-08.

Appendice B — Insieme di valutazioni e riproducibilità

Le cinque valutazioni ingegneristiche sono sottoposte a commit nel repository complementare:

- skills/anticipating-shadow-points/evals/01-supabase-migration.md (E1)
- skills/anticipating-shadow-points/evals/02-edge-function-deploy.md (E2)
- skills/anticipating-shadow-points/evals/03-refactor-shared-util.md (E3)
- skills/anticipating-shadow-points/evals/04-rls-policy-change.md (E4)
- skills/anticipating-shadow-points/evals/05-cron-skill-conflict.md (E5)

Ogni file contiene l'enunciato INPUT, l'elenco EXPECTED degli shadow point e la soglia di ACCEPTANCE, tutti scritti dal progettista del protocollo. Il pacchetto di benchmark in benchmark/ fornisce:

- un giudicatore deterministico a 4 livelli (esatto / sinonimo / Jaccard / non corrispondente);
- una provenienza crittografica per ogni esecuzione (ambiente, codice, input, output e giudizio sottoposti ad hash in una catena in stile Merkle);
- un sottocomando verify che riesamina una directory di esecuzione e segnala ogni deriva a livello di byte;
- 31 test unitari che fissano il contratto di determinismo e il parser delle risposte.

Riprodurre i numeri calcolati delle Sezioni 5.3–5.4 (nessuna chiamata a modelli). Da un clone del repository, python run_all.py rivaluta con il giudicatore distribuito le fixture costruite dall'autore dell'esecuzione mock del benchmark, ricalcola la matrice di discriminazione, rigenera la Figura 2, verifica ogni numero (tests/test_paper_numbers.py, che verifica anche che

l’esecuzione sia etichettata mock) e controlla un unico hash di catena SHA-256 su codice, test, input congelati, dati e risultati (output/hash-chain.md). Le osservazioni dell’autore nella Sezione 5.2 non possono essere riprodotte: le loro trascrizioni non sono state conservate. Questa versione sostituisce la versione 1.0 (https://doi.org/10.5281/zenodo.20277015), che presentava i punteggi del giudicatore su queste fixture come una lettura di trascrizioni di modelli.

Raccogliere evidenza reale (costa chiamate a modelli). Installare il pacchetto di benchmark ed eseguire asp-benchmark run --mode real --model <model> seguito da asp-benchmark verify <run-id>. Ciò non è stato fatto per alcun numero pubblicato, e il comando di oggi non è ancora il Protocollo 2: invia un template a turno singolo anziché la skill distribuita, esegue una replica per compito in un ordine fisso e non passa alcun flag di ambiente pulito. PREREGISTRATION.md elenca le modifiche di cui il runner e il matcher hanno bisogno prima di qualsiasi esecuzione. Il protocollo è specificato indipendentemente dall’implementazione Python in benchmark/PROTOCOL.md, così da poter essere reimplementato in un altro linguaggio.

Sull’autore

Carlos Ulisses Flores è CTO e Ricercatore Capo presso il Codex Hash Research Laboratory, un laboratorio indipendente di R&S a San Paolo, in Brasile. Costruisce sistemi di produzione in cui il fallimento silenzioso è costoso — storicamente nel trading algoritmico, nell’IoT embedded e nella crittografia edge, e oggi negli strumenti di IA agentica. La skill ASP descritta in questo whitepaper è nata da quest’ultimo filone di lavoro; il risultato empirico riportato nel whitepaper complementare è nato dall’uso del runner claude -p di Anthropic come nucleo di esecuzione autonoma e dall’averlo visto restituire codice di uscita 0 davanti a un rifiuto garbato dell’agente.

Scrive in portoghese, inglese, spagnolo e italiano.

Identificatori · ORCID: 0000-0002-6034-7765 · Lattes: 6905246706890561

Contatto · c.ulisses@gmail.com · https://ulissesflores.com