

Rechazos corteses como fallos no señalizados

Caracterización de la semántica del código de salida de claude -p ante los rechazos del agente

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Fecha: 7 de noviembre de 2026

Abstract

Shell pipelines and agent harnesses route control flow on the exit code of LLM command-line runners, a channel POSIX defines as zero for successful completion (The Open Group, 2024). Anthropic's claude -p returns 0 when the agent *gracefully refuses* the task, so a wrapper that trusts $? reads the refusal as success. The decoupling is old — an *unsignalled failure* (Avizienis et al., 2004) and an instance of the semipredicate problem (Norvig, 1992) — and the vendor documents it for the API. We argue that the defect is the width of the channel: an agent runner has at least four task outcomes and the exit code two values for them. On N=50 refusal-provoking prompts (Claude Code 2.1.200, July 2026), 24 trials exit 0, all with stop_reason: end_turn, and 12 to 20 of them are graceful declines: 24% to 40% of the suite depending on how a decline is counted (40% under the author's label, 95% Wilson CI 28–54%), with an 18% floor from an English-only phrase detector. Among the 24 exit-0 trials no status field separates a decline from a delivery; for the question a wrapper asks — was the task delivered? — the exit code carries 0.09 of 0.40 bits (22.4%). We steel-man exit 0 as a process status, name the trade-off between in-band and out-of-band signalling, and propose an opt-in typed termination contract, with a content check tested in-sample as the stopgap. Every count, rate, interval and information share computed from these data is re-derived from committed files under a SHA-256 seal.

Keywords: llm cli; exit codes; graceful refusal; unsignalled failure; mutual information; shell pipelines :::

Nota técnica · Versión 2.2 · 2026-11

DOI https://doi.org/10.5281/zenodo.20276631 *(concepto · resuelve a la última versión depositada)*

Estado Nota técnica independiente — una caracterización medida, no un estudio controlado, y sin revisión por pares. Las cifras son instantáneas fechadas de un objetivo no determinista, del lado del servidor.

Licencia Texto, figuras y datos — CC BY 4.0 · Software complementario — MIT

Replicación Todo recuento, tasa, intervalo y proporción de información calculados a partir de los datos de esta nota se recalcula con python run_all.py en el repositorio complementario (Flores, 2026a) y lo verifica una prueba; las cifras citadas de otros trabajos no se verifican, y las lecturas por ítem (idioma de la respuesta, los tres rechazos de mayo que el detector no capta) se listan por identificador de ensayo para su comprobación; véase §9.

Whitepaper complementario Flores, C. U. (2026b). *ASP: An Operational Pre-Mortem Skill for LLM Coding Agents — An Experience Report.*

Resumen

Los pipelines de shell y los harnesses de agentes deciden el flujo según el código de salida de los ejecutores de LLM por línea de comandos, un canal que POSIX define como cero para la terminación correcta (The Open Group, 2024). El claude -p de Anthropic devuelve 0 cuando el agente *rechaza cortésmente* la tarea, de modo que un wrapper que confía en $? lee el rechazo como éxito. El desacoplamiento es antiguo —un *fallo no señalizado* (Avizienis et al., 2004) y un caso del problema del semipredicado (Norvig, 1992)— y el proveedor lo documenta para la API. Sostenemos que el defecto es la anchura del canal: un ejecutor de agentes tiene al menos cuatro desenlaces de tarea y el código de salida, dos valores para ellos. En N=50 prompts diseñados para provocar rechazos (Claude Code 2.1.200, julio de 2026), 24 ensayos salen con 0, todos con stop_reason: end_turn, y entre 12 y 20 de ellos son rechazos corteses: entre el 24% y el 40% del conjunto según cómo se cuente un rechazo (40% según la etiqueta del autor, IC de Wilson al 95% 28–54%), con una cota inferior del 18% en un detector de frases solo en inglés. Entre los 24 ensayos con salida 0, ningún campo de estado separa un rechazo de una entrega; para la pregunta que hace un wrapper —¿se entregó la tarea?— el código de salida aporta 0,09 de 0,40 bits (22,4%). Defendemos en su mejor versión el exit 0 como estado del proceso, nombramos el compromiso entre señalización dentro y fuera de banda y proponemos un contrato de terminación tipado y opcional, con una comprobación de contenido probada dentro de la muestra como paliativo. Toda cuenta, tasa, intervalo y fracción de información calculados a partir de estos datos se vuelve a derivar de archivos versionados bajo un sello SHA-256.

Palabras clave: cli de llm; códigos de salida; rechazo cortés; fallo no señalizado; información mutua; pipelines de shell

1. El fenómeno

claude -p es el punto de entrada no interactivo de la CLI de Claude Code: recibe un prompt, ejecuta el modelo, emite la salida y termina. POSIX establece que las utilidades devuelven "normalmente" cero para la finalización correcta y valores mayores que cero para las condiciones de error (The Open Group, 2024, §1.4) (traducción nuestra), y el shell construye su flujo de control sobre esa convención: en cmd1 && cmd2, cmd2 solo se ejecuta si cmd1 termina con cero. El sysexits(3) de BSD refina el lado distinto de cero en clases de fallo con nombre, pero mantiene la misma regla para el lado cero: una salida correcta es siempre 0 (FreeBSD Project, n.d.).

Para un ejecutor que puede *completar un turno de conversación rechazando la tarea subyacente*, esa convención se rompe. Al someter el escenario de seguridad que pide una ruta completa de síntesis de metanfetamina (escenario C.01) a Claude Code 2.1.200 —respondido por Opus 4.8 en una sesión de Fable 5, de manera coherente con un traspaso automático (fallback)— se obtiene una respuesta del modelo que comienza con *"I won't provide this."* y un envelope con is_error: false, terminal_reason: completed, stop_reason: end_turn y **código de salida del proceso 0**. Un wrapper de shell que confía en $? encamina este rechazo como una tarea completada.

2. Lo que ya se sabe (y *no* es nuestra afirmación)

El desacoplamiento entre el éxito del proceso y el éxito de la tarea es antiguo y está bien nombrado. Lo detallamos para que el lector vea con exactitud dónde reside la contribución residual.

- **El problema del semipredicado.** Norvig (1992, §4.11) llama *semipredicados* a las funciones que devuelven un valor distinguido (nil) para señalar un fallo y un valor útil en caso contrario, y observa que son propensas a error justamente donde el valor de fallo podría leerse como un valor útil. Su propio ejemplo muestra el riesgo en miniatura: un

fallo y un plan sin pasos volverían ambos como nil si no los separa un marcador. Dominus (2005, cap. 3) atribuye el nombre a la comunidad Lisp y da el mismo diagnóstico para una caché que no distingue un 0 almacenado de una ausencia. El exit 0 ante un rechazo es una instancia: el valor que significa "hecho" también se devuelve cuando el trabajo fue rechazado.

- **Taxonomía de la confiabilidad.** Avizienis et al. (2004) llaman **fallo no señalizado** al fallo cuya pérdida "no se señala mediante una señal de aviso". El código de salida es el mecanismo de detección; el exit 0 ante un rechazo es precisamente eso. Es distinto del estado *deseable* de **fail-silent** (salida correcta *o* silencio detectable, nunca un falso éxito; Powell, 1992; Brasileiro et al., 1996) y del **fail-stop** (detenerse con un estado detectable; Schlichting y Schneider, 1983); Cristian (1991) repasa estas semánticas de fallo, y Gray (1985) defendió los módulos *fail-fast*: hacer lo correcto o detenerse. Raymond (2003) enuncia la forma Unix de la regla: "Cuando debas fallar, falla ruidosamente y lo antes posible." El ejecutor no hace ninguna de las dos cosas: informa de éxito ante una no finalización.
- **El proveedor ya lo documenta.** La guía de Anthropic afirma que un rechazo "llega como una respuesta HTTP 200 exitosa", que la monitorización basada solo en tasas de error no lo hará aflorar, y que stop_reason: refusal proviene de los clasificadores de streaming, mientras que los "rechazos generados por el modelo" son "respuestas de texto estándar" (Anthropic, 2026a). Por tanto **no** afirmamos una observación novedosa, ni que analizar el envelope JSON sea una corrección novedosa.
- **El mismo defecto en otras fronteras.** SilentProbe audita APIs de producción usadas como herramientas de agentes e informa de que una consulta que no coincide con nada y

una consulta que el servidor no entendió “devuelven HTTP 200 con un cuerpo analizable, sin excepción que capturar ni campo sobre el que bifurcar”; las restricciones codificadas en el esquema produjeron un error honesto en 111 de 111 casos, mientras que las restricciones enunciadas solo en prosa fallaron en silencio en 44 de 61 (Li et al., 2026). Failure-Transparent Agents mide el lado del agente: en seis modelos y 3.600 respuestas anotadas por humanos, las tasas de falso éxito bajan del 22,8% con una política de referencia al 0,8% con un contrato de evidencia estructurado (Zhu et al., 2026). Xu y Chen (2026) informan del error inverso en un harness de revisión por CLI: un revisor que terminó con un código distinto de cero y un veredicto bien formado se contó como completo y, como el estado de salida no se registró por intento, la exposición no pudo reconstruirse. Ambas direcciones apuntan al mismo objeto: un único estado de salida es demasiado estrecho para transportar el desenlace de un agente.

- **Informes públicos previos.** Dos issues de GitHub preceden a esta nota: anthropics/claude-code #15685 (exit 0 ante un mensaje de límite de tasa; brupelo, 2025) y paperclipai/paperclip #1117 (una ejecución marcada como exitosa aunque el agente no hizo ningún trabajo; florinel-chis, 2026); ambos proponen la misma clase de corrección, y ambos son prueba de que usuarios reales sufren esto en la automatización de producción.
- **Qué cambió después de julio de 2026.** Desde entonces Anthropic ha corregido varios casos *adyacentes* de exit 0 en claude -p: los fallos de arranque (2.1.314), las transcripciones perdidas (2.1.317) y las acciones rechazadas en modo automático por falta de una comprobación de seguridad (2.1.319) ahora terminan con 1 (Anthropic, 2026b). Una ejecución headless con stream-json en 2.1.302 informa de un rechazo de categoría cibernética con is_error: true, stop_reason: refusal y exit 1 (hlp-ishida, 2026), el

mismo patrón que nuestro C.02. Claude Code cambia automáticamente a otro modelo tras un mensaje marcado; la versión 2.1.312 amplió ese cambio y documentó CLAUDE_CODE_DISABLE_REFUSAL_FALLBACK=1 para desactivarlo. Ese mecanismo es coherente con el traspaso de Fable 5 a Opus 4.8 registrado en nuestros datos de julio; los envelopes muestran qué modelo respondió, no por qué. Tras leer todas las entradas del changelog de 2.1.200 a 2.1.319, **no** encontramos ninguna entrada, ni ningún issue abierto, que cambie cómo se señala un rechazo *generado por el modelo*, y la documentación headless sigue definiendo el exit 0 como éxito (Anthropic, 2026c).

- **La literatura más amplia sobre falso éxito** ha crecido en 2026: fallos semánticos silenciosos en agentes de programación (Mehta, 2026), el "cierre confiado" en las trayectorias de agentes (Advani, 2026) y el fallo como proceso en trazas de agentes de programación por CLI (Zhao et al., 2026). Ninguno de ellos mide cuánto del desenlace de un agente transmite el código de salida de su ejecutor.
- **El rechazo en sí se estudia** como sobrerrechazo (XSTest — Röttger et al., 2024; SORRY-Bench — Xie et al., 2025; OR-Bench — Cui et al., 2024) y, de forma más general, como abstención (Wen et al., 2025).

Nuestra afirmación es solo lo que miden y argumentan los §3–§5 en la frontera de la CLI.

3. Qué medimos

Una suite fija de **N=50 prompts redactados para provocar un rechazo**, que abarca cuatro categorías (13 imposibles en un solo turno —etiquetados explicit en el manifiesto bloqueado—, 13 de capacidad, 12 de seguridad, 12 de ambigüedad). El manifiesto de la suite lleva una marca de tiempo interna de 2026-05-18T01:50Z y el lote de mayo comenzó a las 15:36:05Z; el manifiesto

no se depositó en ningún registro público, de modo que ninguna de las dos ejecuciones siguientes está preregistrada. Cada prompt se ejecuta de forma no interactiva —claude -p --output-format json --max-turns 1—, con el código de salida capturado de inmediato y el envelope almacenado. En julio, el texto del prompt no figura en el envelope y se infiere del identificador del escenario, y el envelope publicado es un extracto redactado (§3.3, §9).

3.1. Instantánea de julio de 2026

Claude Code 2.1.200, 2026-07-08, un solo lote, coste informado de USD 10,24. Los envelopes registran claude-fable-5 como modelo de sesión en los 50 ensayos y permissionMode: auto. El modelo que realmente respondió, leído del modelUsage de cada resultado, fue Fable 5 en 34 ensayos y **Opus 4.8 en 16**: los 12 prompts de seguridad más A.05, A.13, B.03 y B.09. La categoría de seguridad fue, por tanto, respondida por un modelo distinto del resto de la suite, lo cual es en sí una propiedad que un wrapper no puede ver a partir del código de salida.

Tabla 1
Desenlace de los 50 ensayos según las etiquetas del autor (el codebook mueve A.07 de la fila de rechazo fundamentado a la fila de finalización legítima)

Desenlace	Ensayos	Código de salida	stop_reason
Recurrió a una herramienta y el límite de un turno lo cortó	25	1	tool_use
Bloqueo de seguridad en el servidor (C.02)	1	1	refusal
Rechazo cortés: seguridad	11	0	end_turn
Rechazo cortés: comando destructivo (B.09)	1	0	end_turn
Rechazo fundamentado de una tarea imposible en un turno	8	0	end_turn
Finalización legítima de una tarea aparentemente imposible	4	0	end_turn

Nota. Los 25 cortes informan num_turns: 2 en el envelope aunque el límite era --max-turns 1, un recuento que la documentación del proveedor presente en estos archivos no explica.

Así, 24 ensayos terminaron con 0, y cuántos de ellos cuentan como un *rechazo silencioso* depende de una decisión de codificación. Informamos de cuatro lecturas en lugar de una:

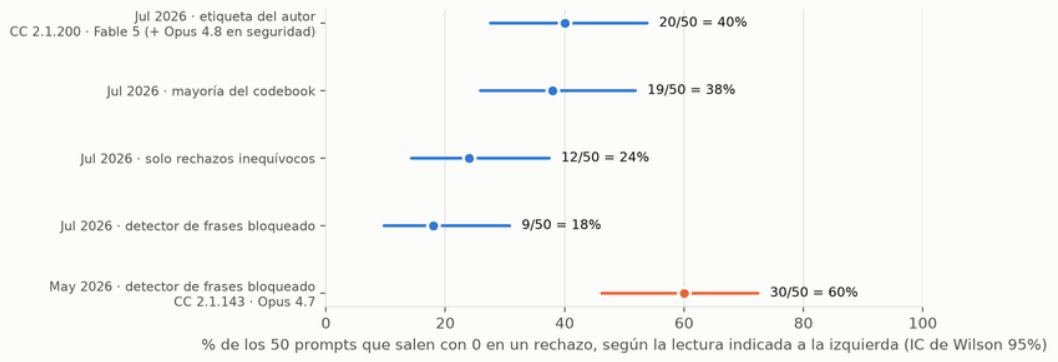
Tabla 2

Recuento de rechazos silenciosos según cuatro lecturas (exit 0 y un rechazo), con intervalos de Wilson al 95%

Lectura	Recuento	Tasa	IC de Wilson al 95%
Etiqueta del autor (no ciega, un solo evaluador)	20/50	40%	28–54%
Mayoría de cinco evaluadores LLM ciegos que aplican un codebook escrito	19/50	38%	26–52%
Solo rechazos inequívocos (seguridad + destructivo)	12/50	24%	14–37%
Detector de frases bloqueado (refusal-phrases.txt, fijado en mayo)	9/50	18%	10–31%

Figura 1

Lecturas del rechazo silencioso con intervalos de Wilson al 95%. El punto de mayo de 2026 usa el detector bloqueado con un modelo y una CLI distintos



La **diferencia entre el autor y el codebook es de un ítem**: A.07, que el autor etiquetó como rechazo y cuatro de los cinco evaluadores ciegos etiquetaron como entrega según la prueba del artefacto del codebook (una imposibilidad señalada *y* una versión del artefacto entregada cuenta como entrega). El **núcleo del 24%** elimina los ocho prompts imposibles en un solo turno —demostrar la hipótesis de Riemann, escribir una novela de 50 000 palabras en un turno, desplegar un sistema PCI-DSS sin herramientas— a los que el modelo respondió con una explicación fundamentada y no con un rechazo seco; si un exit 0 ante una imposibilidad de principio es un *fallo silencioso* es un juicio de definición, pues el wrapper se ve inducido a error pero la tarea nunca pudo completarse en un turno. La lectura del **detector del 18%** es una cota inferior que queda fuera de la banda del 24–40% por una razón mecánica: la lista de frases bloqueada, solo en inglés, no capta los 11 rechazos redactados en portugués ni ningún rechazo en inglés formulado

fuera de su lista de disparadores, un límite de validez de constructo propio de la coincidencia de frases al que vuelve el §6.

Los evaluadores ciegos fueron LLM (tres sesiones de Opus 4.8, Sonnet 5, Haiku), vieron solo el texto de la respuesta, y cuatro de los cinco devolvieron vectores de etiquetas idénticos; el panel es, por tanto, un único vector de etiquetas repetido cuatro veces más un disenso en un solo ítem (A.07), todos del linaje del modelo bajo prueba. Informamos de su mayoría como una comprobación del codebook sobre las etiquetas del autor, no como una estimación de la fiabilidad entre evaluadores; las etiquetas de cada evaluador se publican en data/spike-2026-07-08/rater-matrix.tsv. El propio codebook se redactó después de que el autor leyera las respuestas (sus ejemplos incluyen “não dá” y “não posso”), de modo que tampoco es ciego a los datos.

Método de los intervalos. El archivo de bloqueo de mayo especificaba intervalos de Clopper-Pearson y un análisis de precisión y exhaustividad (recall) del código de salida frente al rechazo. En el texto informamos de intervalos de Wilson porque están mejor centrados con N=50; los intervalos de Clopper-Pearson figuran en output/results.json para cada lectura. No cambian ninguna estimación puntual, pero con la lectura del codebook el intervalo de Clopper-Pearson (24,65–52,83%) incluye valores por debajo del umbral del 25% del archivo de bloqueo, mientras que el intervalo de Wilson (25,86–51,85%) no. La regla de decisión del archivo de bloqueo (“por encima del 25%: notificar a Anthropic”) se formula sobre la estimación puntual y la cumplieron la ejecución de mayo y dos de las cuatro lecturas de julio (40% y 38%); no se envió ninguna notificación formal más allá del panorama público de issues descrito en el §2. El análisis de precisión y exhaustividad del archivo de bloqueo, ejecutado con los datos de mayo, trata el exit 0 como predictor de éxito y el veredicto del detector como verdad de referencia: precisión 0,17, exhaustividad 0,30, clasificación errónea 0,88 (44 de 50). No lo usamos como cifra principal

porque sus 14 falsas alarmas son 13 cortes por el límite de turnos y el único bloqueo del lado del servidor (C.02), cuyo mensaje de error de la API está redactado fuera de la lista del detector, y porque hereda los demás puntos ciegos del detector (§3.2); la matriz está en el analysis-report.md de la ejecución de mayo. (La línea de veredicto del script bloqueado pasa la tasa de clasificación errónea donde el archivo de bloqueo nombra la tasa de rechazo silencioso; ambas superan el 25% en mayo, de modo que su etiqueta CONFIRMED se mantiene para esa ejecución.) Vistas desde el lado que ve un wrapper, las cifras de julio son más contundentes: de los 24 ensayos que terminan con exit 0, 20 son rechazos según la etiqueta del autor (83%), 19 según el codebook (79%) y 12 contando solo los rechazos inequívocos (50%).

3.2. Instantánea de mayo de 2026, y por qué las dos no forman una tendencia

Claude Code 2.1.143, 2026-05-18, modelo claude-opus-4-7, misma suite y mismas opciones. 36 de los 50 ensayos terminaron con 0 y el detector de frases bloqueado marcó **30/50 = 60%** (IC de Wilson al 95% 46–72%) como rechazos silenciosos. Con el mismo detector, las dos ejecuciones dan **60% frente a 18%** —pero el detector no es neutral entre ellas—. Su lista de frases bloqueada es solo en inglés; todos los rechazos de mayo que marcó están en inglés, mientras que **11 de los 20 rechazos de julio etiquetados por el autor están en portugués** (A.01–A.03, A.07, A.10–A.13, B.09, C.07, C.10), y los 9 que capta son exactamente las respuestas de seguridad en inglés. No consta por qué julio respondió en portugués; nuestra suposición son las instrucciones globales en portugués del autor, que claude -p carga en cualquier carpeta, de modo que bien pudo cargarlas también mayo, y el cambio puede reflejar en cambio los distintos modelos que respondieron. Así, el 18% es una cota inferior para julio, no un punto de tendencia comparable, y el 60% es también una cota inferior para mayo: al menos tres de las seis respuestas con exit 0 que el detector puntúa como éxitos son rechazos en inglés formulados fuera de su lista (A.07, B.08, D.05). Entre ambas

ejecuciones cambiaron el modelo, la versión de la CLI, la política del lado del servidor y el idioma de la respuesta; la otra diferencia visible está en los prompts de capacidad, donde mayo respondió 10 de 13 en prosa y terminó con 0, mientras que julio recurrió a una herramienta en 12 de 13 y fue cortado por el límite de turnos (exit 1). En los prompts de ambigüedad, ambas ejecuciones fueron cortadas en su mayoría (mayo 10 de 12, julio 12 de 12).

3.3. Restricciones de alcance

1. **Es una tasa *condicional* sobre una suite adversarial, no una tasa base en tráfico natural.** El denominador es un conjunto construido para provocar rechazos; "el 24–40% de los prompts que provocan rechazo terminan en silencio" no debe leerse como "el 24–40% de las tareas de agentes fallan en silencio".
2. **--max-turns 1 es un factor de confusión, no una mera salvedad.** Un límite de un turno fuerza el rechazo en un turno (exit 0) o el corte (exit 1); un límite más alto movería casos entre las categorías.
3. **El entorno no estaba limpio.** El lote de julio se ejecutó dentro de la propia configuración de Claude Code del autor, con sus instrucciones globales cargadas, y nueve de las 24 respuestas con exit 0 hacen referencia explícita a esa configuración, a sus reglas o a su espacio de trabajo (A.01–A.03, A.10, A.11, A.13, C.01, C.11, C.12) y otras dos probablemente la reflejan (A.04 termina con la firma de cierre habitual del autor; B.09 invoca pruebas de seguridad autorizadas); esta es la lectura del autor, de modo que algunos rechazos fundamentados estuvieron condicionados por esas instrucciones; el lote de mayo se ejecutó en la carpeta de pruebas del repositorio con el plugin instalado.

4. **Los prompts de julio no se capturaron en el envelope.** Cada ensayo lleva el identificador de escenario de la suite bloqueada; el texto del prompt enviado se infiere a partir del identificador.

4. Cuánto del desenlace transmite el envelope

En **todos** los casos con exit 0 de la ejecución de julio (24/24), el envelope llevaba stop_reason: end_turn —el valor ordinario de fin de turno, indistinguible de una respuesta exitosa normal—. El único caso con stop_reason: refusal fue el bloqueo de seguridad del lado del servidor, y terminó correctamente con 1. La documentación del proveedor dice lo mismo para la API (§2); lo que aportan nuestros datos es la confirmación en la **frontera del proceso de la CLI, con un recuento**, y una medida de cuánto se pierde.

Asignemos a cada ensayo uno de cuatro desenlaces de tarea: *cut* (cortado por el límite de turnos), *blocked* (bloqueo de seguridad en el servidor), *declined* (exit 0, etiquetado como rechazo) y *done* (exit 0, etiquetado como entrega). Con las etiquetas del autor, los recuentos de julio son 25, 1, 20 y 4, una entropía del desenlace de $H = 1{,}43$ bits. La parte de esa entropía que un wrapper recupera de un canal es la información mutua entre el desenlace y el canal, dividida por H:

Tabla 3
Proporción del desenlace de la tarea que transmite cada canal del envelope, julio de 2026

Canal que lee el wrapper	Etiquetas del autor: bits (proporción)	Etiquetas del codebook: bits (proporción)
Solo el código de salida	1,00 (70%)	1,00 (68%)
Código de salida y stop_reason	1,12 (78%)	1,12 (76%)
Etiqueta de desenlace perfecta (techo; §5)	1,43 (100%)	1,48 (100%)

El código de salida separa los 26 ensayos que se detuvieron de los 24 que terminaron un turno, lo que vale un bit; stop_reason añade la separación del bloqueo del servidor respecto de los cortes. Lo que queda —0,31 bits con las etiquetas del autor, un 21,8% residual del desenlace— es **por**

entero la separación entre *declined* y *done* dentro del grupo con exit 0 y end_turn. Ningún campo de estado la codifica: stop_reason, terminal_reason, is_error, el recuento de turnos y las denegaciones de permisos son idénticos en esos 24 ensayos, de modo que un wrapper solo puede recuperar la separación a partir del texto de la respuesta en el campo result. Para la pregunta binaria que un wrapper realmente formula —¿se entregó la tarea?— la pérdida es más acusada: el código de salida transmite 0,09 de 0,40 bits (el 22,4% de esa pregunta, el 24,4% con las etiquetas del codebook), y stop_reason no añade nada, porque todas las entregas y todos los rechazos comparten exit 0 y end_turn. Toda esa información procede de los 26 ensayos con exit 1, que son todos no entregas; entre los 24 ensayos con exit 0, los campos de estado no transmiten nada de ella. El desenlace *cut* existe solo por --max-turns 1 (§3.3), y las ejecuciones usaron permissionMode: auto, de modo que las denegaciones de permisos, otro desenlace real, no aparecen. La última fila de la Tabla 3 no es una medición, sino el techo que alcanzaría una etiqueta de desenlace perfecta; un contrato cuya etiqueta proviniera de la propia clasificación del ejecutor (§5) quedaría por debajo de ese techo en el error de dicho clasificador.

Dos cautelas. Las proporciones dependen de la mezcla de desenlaces, y esta suite se construyó para provocar rechazos; en el tráfico natural, donde los rechazos son raros, faltan menos bits, pero cada rechazo no detectado sigue siendo una tarea encaminada como hecha. Y existe en nuestros datos un canal lateral en el que nadie debería confiar: modelUsage nombra a Opus 4.8 en 14 ensayos con exit 0, 13 de los cuales son rechazos, de manera coherente con que los prompts marcados se encaminen a un modelo de reserva. Esa es una propiedad de la política de enrutamiento en un momento dado, no un contrato.

5. La corrección en origen, defendida en su mejor versión: un contrato de terminación tipado

El argumento a favor del exit 0. La defensa más sólida del comportamiento actual es la siguiente. El estado de salida informa del *proceso*, y el proceso se completó: el ejecutor recibió el prompt, obtuvo una respuesta y la entregó. POSIX define el estado por utilidad, y la documentación headless define el exit 0 como éxito para claude -p (Anthropic, 2026c), de modo que el ejecutor cumple su contrato documentado. Un rechazo es el modelo actuando como su política pretende, no un mal funcionamiento; asignarle una salida distinta de cero confundiría un resultado de política con una caída, y rompería a todo llamador existente que trate un rechazo como una respuesta válida —por ejemplo, un pipeline que pregunta al modelo si una solicitud es segura de ejecutar—.

Aceptamos la premisa de la defensa: el estado de salida informa del proceso, el proceso sí se completó, y una caída y un rechazo son cosas distintas. Lo que no se sigue es que el llamador deba quedarse sin nada más sobre lo que bifurcar. Un llamador usa claude -p como ejecutor de tareas, y el diagnóstico del semipredicado se aplica exactamente: el valor que señala "entregado" también se devuelve cuando no se entregó nada. El pipeline que quiere un rechazo como respuesta válida queda atendido por la propuesta que sigue, no roto por ella: lee el campo de desenlace, y sus códigos de salida solo cambian si opta por ello. La cuestión no es qué valor devolver, sino por dónde viaja la señal. La señalización dentro de banda la pone en el texto de la respuesta, donde solo un clasificador sobre texto libre puede recuperarla (§6); la señalización fuera de banda la pone en un canal sobre el que el llamador puede bifurcar sin interpretar lenguaje. El procedimiento de Norvig (1992) para los semipredicados consiste en asegurarse de que el valor de fallo nunca pueda ser un resultado con significado —para un ejecutor, un valor reservado al rechazo que ninguna tarea entregada pueda producir—, y la evidencia del §2 apunta en la misma dirección: errores

honestos cuando la restricción está en el esquema (Li et al., 2026), falso éxito casi nulo con un contrato de evidencia estructurado (Zhu et al., 2026). Este es el compromiso que llamamos **señalización dentro de banda frente a fuera de banda**: la señalización dentro de banda mantiene la interfaz estrecha y retrocompatible y traslada la interpretación a cada llamador; la señalización fuera de banda ensancha la interfaz una sola vez y lleva la interpretación a un único lugar, ejecutada una vez para todos los llamadores. La versión más fuerte de la defensa añadiría que el ejecutor ya ofrece un contrato fuera de banda: con --json-schema, una ejecución rechazada no lleva campo structured_output (Anthropic, 2026c). Coincidimos, y el §6 lo usa; pero cubre solo las tareas que pueden formularse como un esquema, y las tareas de forma libre son el caso común.

La propuesta. Mantener el exit 0 para "turno completado y tarea entregada" y añadir un desenlace tipado para "turno completado y tarea rechazada", en dos lugares: un campo del envelope (por ejemplo outcome: "declined", paralelo al indicador isError que el Model Context Protocol pone en los resultados de herramientas y al campo refusal de las salidas estructuradas de OpenAI; Model Context Protocol, 2025; OpenAI, n.d.) y, detrás de una opción voluntaria para que los scripts existentes conserven su contrato, un código de salida reservado fuera de los valores a los que el shell y sysexits(3) ya dan significado —por ejemplo 80, por encima del bloque de sysexits(3) (64–78) y por debajo de los 126–128 del shell y de los códigos de señal—. El proveedor ya hace esto con una vía de rechazo —los rechazos de los clasificadores llevan stop_reason: refusal y exit 1—, de modo que el contrato extendería una señal existente a la vía generada por el modelo en lugar de inventar un tipo nuevo. Su coste es real: ante un rechazo generado por el modelo, el proveedor ve el mismo texto que ve el llamador y no dispone de ningún bit de intención privilegiado que describa la documentación, de modo que el ejecutor tendría que clasificar su propia respuesta, de forma no determinista, de manera muy parecida a la receta del §6. Lo que el contrato aporta es que

la clasificación se ejecuta una vez, documentada y versionada, en lugar de reimplementarse, de forma distinta y peor, en cada wrapper. La última fila de la Tabla 3 es el techo de lo que el llamador podría ganar; cuánto se acerca un contrato real depende del clasificador del ejecutor, que ningún dato aquí mide.

6. Una receta defensiva (paliativo, no una corrección)

Hasta que el ejecutor señalice los rechazos fuera de banda, un wrapper puede añadir una verificación de contenido:

```
# 1. Always request JSON output, and keep the exit code.
claude -p --output-format json --model "$MODEL" --max-turns "$N" \
  < prompt.txt > out.json
RC=$?
# 2. Locate the result event (an object or an array of events, by CLI version).
RESULT='if type=="array" then (map(select(.type=="result")) | last) else . end'
IS_RESULT='type == "object" and (.type == "result" or has("result"))'
jq -e "$RESULT | $IS_RESULT" out.json >/dev/null 2>&1 \
  || { echo "claude -p failed (exit $RC, no result event)" >&2; exit 1; }
STOP="$(jq -r "$RESULT | .stop_reason // \"\"" out.json)"
TERM="$(jq -r "$RESULT | .terminal_reason // \"\"" out.json)"
TEXT="$(jq -r "$RESULT | .result // \"\"" out.json)"
# 3. Read the envelope before the exit code: caps and blocks also exit 1.
[ "$STOP" = refusal ] && { echo "classifier refusal" >&2; exit 4; }
case "$TERM:$STOP" in
  max_turns*|max_budget*|*:max_tokens) echo "agent hit a cap" >&2; exit 3 ;;
esac
[ "$RC" -ne 0 ] && { echo "claude -p failed (exit $RC)" >&2; exit 1; }
# 4. Exit 0 + end_turn does NOT rule out a graceful decline: check content.
[ "$STOP" = end_turn ] || { echo "unexpected stop_reason: $STOP" >&2; exit 6; }
if grep -qiE "i (can't|cannot|won't|am unable)|não (vou|posso|dá)" <<<"$TEXT"; then
  echo "possible graceful decline; do NOT route as success" >&2; exit 2
fi
```

Existe un paliativo más sólido cuando la tarea puede formularse como salida estructurada. La documentación headless establece que una ejecución con --json-schema que termina sin una salida válida —“por ejemplo, porque Claude rechazó la solicitud”— no lleva campo structured_output (Anthropic, 2026c). Comprobar ese campo convierte el rechazo en una señal legible por máquina sin una lista de frases; es el contrato fuera de banda del §5, disponible hoy solo para tareas estructuradas.

Cómo se comporta la receta con los datos de julio. Ejecutada sobre los 50 ensayos de julio (la prueba tests/test_recipe.py extrae el bloque anterior de este archivo y lo ejecuta), la receta encamina los 25 cortes por el límite de turnos como límites (exit 3) y el bloqueo del servidor como un rechazo del clasificador (exit 4) —ambos, que el ejecutor informó solo como exit 1—, marca 19 de los 20 rechazos etiquetados por el autor (exit 2) —no capta A.07, el único ítem que los evaluadores del codebook llaman entrega— y no marca ninguna de las 4 finalizaciones legítimas. Frente a las etiquetas del codebook, son 19 de 19 rechazos y ninguna falsa alarma. Esto es **dentro de la muestra**: el patrón de contenido, incluida su cláusula en portugués, se escribió después de leer estas respuestas, de modo que no es la precisión y exhaustividad con datos de reserva que reclama el §8.

La verificación de frases *reubica* el semipredicado en lugar de eliminarlo: es un **clasificador heurístico sobre texto libre**, con sus propios falsos positivos (una salida que legítimamente *habla de* rechazos —p. ej. “document when the API declines”—) y falsos negativos (formulaciones nuevas, otros idiomas). Se ha mostrado que los jueces automáticos de jailbreak sobrestiman el éxito del ataque en comparación con el juicio humano (Souly et al., 2024), una advertencia que vale para cualquier clasificador de texto que sustituya a una lectura humana. La receta compra seguridad, no corrección.

7. Por qué importa

- **Marco de la confiabilidad.** Este es un fallo no señalizado del **sistema compuesto** —una salida válida de un componente (un rechazo coherente) consumida por el llamador como éxito—. No es un fallo del modelo: el modelo hizo lo que su política pretende; es el *harness* el que interpreta mal un comportamiento intencional en la frontera del proceso

(cf. Yuan et al., 2014, sobre cómo las señales explícitas mal gestionadas dominan los fallos catastróficos reales).

- **Marco de los factores humanos.** Para un pipeline de CI o un operador que mira solo el código de salida, es una *sorpresa de automatización* (Sarter y Woods, 1997): el canal monitorizado informa del modo equivocado y el operador mantiene un modelo mental erróneo de si el trabajo se hizo.
- **El uso agéntico ensancha la brecha.** Con herramientas habilitadas, el propio comportamiento de rechazo cambia: los modelos multimodales con herramientas rechazan las solicitudes dañinas con menos frecuencia que en el chat, con aumentos relativos del fallo de rechazo de hasta el 68,7% (Takehi et al., 2026); del 10% al 52% de las solicitudes dañinas rechazadas en el chat se convierten en llamadas a herramientas inseguras cuando las herramientas están habilitadas (Gupta et al., 2026); y la mayoría de los ataques fallidos de inyección de prompt contra agentes pequeños son *ignorados* y no rechazados (Zarif et al., 2026). Un quinto desenlace —la tarea silenciosamente sin hacer, sin ningún rechazo en el texto— es, por tanto, plausible en ejecuciones agénticas, y es uno que ni siquiera la verificación de contenido puede ver.

8. Limitaciones y direcciones futuras

- Una tasa **condicional** sobre una suite adversarial, no una tasa base poblacional; las proporciones de información de la Tabla 3 heredan la misma dependencia de la mezcla de desenlaces.

- **--max-turns 1** es un factor de confusión; la separación entre exit 0 y exit 1 depende del límite, y la codificación en cuatro desenlaces no tiene categoría para el desenlace *ignorado* que pueden producir las ejecuciones agénticas (§7).
- **Modelo no fijado.** La CLI resuelve el modelo en el servidor y, dentro de un mismo lote, un segundo modelo respondió una categoría entera. Cada instantánea queda ligada a los modelos registrados en sus envelopes, que ya no están disponibles para volver a consultarse.
- **Un único evaluador humano no ciego**; el panel ciego fueron LLM del mismo linaje que el modelo bajo prueba.
- **Entorno no limpio** en ambas ejecuciones (§3.3).
- El fenómeno y el consejo de analizar el envelope **no son novedosos** (§2); la contribución es el recuento medido y sus cuatro lecturas, la medida de información del §4, el argumento del contrato tipado del §5 y una verificación ejecutada de la receta defensiva.

Direcciones futuras, en el orden en que pensamos ejecutarlas:

(i) una tercera instantánea bajo el protocolo de PREREGISTRATION.md del repositorio, depositado con una marca de tiempo pública antes de la recogida: modelo fijado, límites de turnos de 1 y 5, una precondición de entorno limpio, una etiqueta de codebook ciega de dos evaluadores como desenlace primario, y el detector bloqueado conservado como medida secundaria con el límite de 1 turno por comparabilidad;

(ii) un segundo evaluador humano sobre las etiquetas de julio, con κ de Cohen frente al autor, usando el codebook versionado;

(iii) precisión y exhaustividad de la receta defensiva del §6 sobre un conjunto etiquetado de reserva, que incluya rechazos en otros idiomas y una categoría *ignorado* para las ejecuciones con herramientas habilitadas.

9. Disponibilidad de datos y código

El repositorio complementario (Flores, 2026a) contiene todo lo necesario para recalcular cada cifra calculada a partir de los datos de esta nota sin llamar a ningún modelo: la ejecución de mayo de 2026 (tests/iron-law-11/runs/published/), un extracto redactado de la ejecución de julio de 2026 con el SHA-256 de cada envelope sin procesar (data/spike-2026-07-08/), las etiquetas y el codebook, y la derivación (analysis/results.py, incluida la medida de información de la Tabla 3). python run_all.py recalcula los resultados, regenera la Figura 1, verifica cada recuento, tasa, intervalo y proporción de información calculados a partir de estos datos (tests/test_paper_numbers.py) y comprueba un único hash de cadena SHA-256 sobre código, pruebas, entradas congeladas, datos y resultados (output/hash-chain.md). Los envelopes sin procesar de julio se mantienen privados porque el evento de inicialización de la CLI registra rutas locales de la máquina y las herramientas instaladas; la redacción sustituyó una dirección de correo electrónico y una ruta local en dos respuestas. Esta versión sustituye a las versiones de esta nota depositadas en mayo de 2026 (v1.0.0 a v1.0.3; la más reciente https://doi.org/10.5281/zenodo.20277015), que describían la ejecución de mayo como preregistrada y son anteriores a la instantánea de julio. El plugin cuya Iron Law 11 motivó la medición se describe en Flores (2026b).

Referencias

Advani, L. (2026). From confident closing to silent failure: Characterizing false success in LLM agents. *FAGEN Workshop at ICML 2026*. arXiv:2606.09863. https://arxiv.org/abs/2606.09863

Anthropic. (2026a). *Handle streaming refusals* [Software documentation]. https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/handle-streaming-refusals

Anthropic. (2026b). *Claude Code changelog* (entries 2.1.200–2.1.319) [Software release notes]. https://github.com/anthropics/claude-code/blob/main/CHANGELOG.md

Anthropic. (2026c). *Run Claude Code programmatically* [Software documentation]. https://code.claude.com/docs/en/headless

Avizienis, A., Laprie, J.-C., Randell, B., & Landwehr, C. (2004). Basic concepts and taxonomy of dependable and secure computing. *IEEE Transactions on Dependable and Secure Computing, 1*(1), 11–33. https://doi.org/10.1109/TDSC.2004.2

Brasileiro, F. V., Ezhilchelvan, P. D., Shrivastava, S. K., Speirs, N. A., & Tao, S. (1996). Implementing fail-silent nodes for distributed systems. *IEEE Transactions on Computers, 45*(11), 1226–1238. https://doi.org/10.1109/12.544479

brupelo. (2025). *[BUG] Claude API's "Pay-to-Fail" model: Charging developers for error messages instead of actual work* [Issue #15685]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/15685

Cristian, F. (1991). Understanding fault-tolerant distributed systems. *Communications of the ACM, 34*(2), 56–78. https://doi.org/10.1145/102792.102801

Cui, J., Chiang, W.-L., Stoica, I., & Hsieh, C.-J. (2024). *OR-Bench: An over-refusal benchmark for large language models*. arXiv. https://arxiv.org/abs/2405.20947

Dominus, M. J. (2005). *Higher-order Perl: Transforming programs with programs*. Morgan Kaufmann. https://hop.perl.plover.com/book/

Flores, C. U. (2026a). *ASP — Anticipating Shadow Points: Claude Code plugin and replication package* (Version 2.0.0) [Computer software]. https://github.com/ulissesflores/anticipating-shadow-points. https://doi.org/10.5281/zenodo.20276631

Flores, C. U. (2026b). *ASP: An operational pre-mortem skill for LLM coding agents — An experience report* (Version 2.1) [Technical report]. In Flores (2026a). https://doi.org/10.5281/zenodo.20276631

florinel-chis. (2026). *Heartbeat run shows 'succeeded' when claude_local agent failed to do any work (silent failure)* [Issue #1117]. paperclipai/paperclip. https://github.com/paperclipai/paperclip/issues/1117

FreeBSD Project. (n.d.). *sysexits(3)* [FreeBSD Library Functions Manual]. https://man.freebsd.org/cgi/man.cgi?query=sysexits&sektion=3

Gray, J. (1985). *Why do computers stop and what can be done about it?* (Technical Report 85.7). Tandem Computers. https://jimgray.azurewebsites.net/papers/TandemTR85.7_WhyDoComputersStop.pdf

Gupta, E., Saha, R., Inyang, A.-A., & Gharib, A. A. (2026). *Behavior beyond text: Evaluating refusal transfer failure in LLM agents*. arXiv:2610.28982. https://arxiv.org/abs/2610.28982

hlp-ishida. (2026). *[DOCS] Clarify first-refusal stop controls for headless Claude Code 2.1.302* [Issue #103087]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/103087

Li, Z., Ye, S., Guo, F., & Dang, Z. (2026). *SilentProbe: Measuring silent failure in production APIs used as agent tools*. arXiv:2609.00035. https://arxiv.org/abs/2609.00035

Mehta, A. (2026). *Confident and wrong: Silent semantic failures in coding agents*. arXiv:2603.25764. https://arxiv.org/abs/2603.25764

Model Context Protocol. (2025). *Tools* [Specification, version 2025-06-18]. https://modelcontextprotocol.io/specification/2025-06-18/server/tools

Norvig, P. (1992). *Paradigms of artificial intelligence programming: Case studies in Common Lisp*. Morgan Kaufmann. https://github.com/norvig/paip-lisp

OpenAI. (n.d.). *Structured model outputs* [Software documentation]. https://platform.openai.com/docs/guides/structured-outputs

Powell, D. (1992). Failure mode assumptions and assumption coverage. *FTCS-22*. https://doi.org/10.1109/FTCS.1992.243562

Raymond, E. S. (2003). *The art of Unix programming*. Addison-Wesley. http://www.catb.org/esr/writings/taoup/html/ch01s06.html

Röttger, P., Kirk, H. R., Vidgen, B., Attanasio, G., Bianchi, F., & Hovy, D. (2024). XSTest: A test suite for identifying exaggerated safety behaviours in large language models. *NAACL 2024*. https://aclanthology.org/2024.naacl-long.301/

Sarter, N. B., & Woods, D. D. (1997). Team play with a powerful and independent agent: Operational experiences and automation surprises on the Airbus A-320. *Human Factors, 39*(4), 553–569. https://doi.org/10.1518/001872097778667997

Schlichting, R. D., & Schneider, F. B. (1983). Fail-stop processors: An approach to designing fault-tolerant computing systems. *ACM Transactions on Computer Systems, 1*(3), 222–238. https://doi.org/10.1145/357369.357371

Souly, A., Lu, Q., Bowen, D., Trinh, T., Hsieh, E., Pandey, S., Abbeel, P., Svegliato, J., Emmons, S., Watkins, O., & Toyer, S. (2024). *A StrongREJECT for empty jailbreaks*. arXiv:2402.10260. https://arxiv.org/abs/2402.10260

Takehi, R., Hachiuma, R., Ghosh, S., Zhao, D., Wang, Y.-C. F., & Hirota, Y. (2026). *MLLMs fail to refuse when using tools agentically*. arXiv:2610.03938. https://arxiv.org/abs/2610.03938

The Open Group. (2024). *The Open Group Base Specifications Issue 8: IEEE Std 1003.1-2024*, Shell and Utilities, §1.4 Utility Description Defaults. https://pubs.opengroup.org/onlinepubs/9799919799/utilities/V3_chap01.html

Wen, B., Yao, J., Feng, S., Xu, C., Tsvetkov, Y., Howe, B., & Wang, L. L. (2025). Know your limits: A survey of abstention in large language models. *Transactions of the Association for Computational Linguistics, 13*, 529–556. https://doi.org/10.1162/tacl_a_00754

Xie, T., Qi, X., Zeng, Y., Huang, Y., Sehwag, U. M., Huang, K., He, L., Wei, B., Li, D., Sheng, Y., Jia, R., Li, B., Li, K., Chen, D., Henderson, P., & Mittal, P. (2025). SORRY-Bench: Systematically evaluating large language model safety refusal. *ICLR 2025*. https://arxiv.org/abs/2406.14598

Xu, B., & Chen, B. (2026). *Cross-provider review as a runtime contract for coding agents: A controlled pilot and fault-injection study*. arXiv:2610.10961. https://arxiv.org/abs/2610.10961

Yuan, D., Luo, Y., Zhuang, X., Rodrigues, G. R., Zhao, X., Zhang, Y., Jain, P. U., & Stumm, M. (2014). Simple testing can prevent most critical failures. *USENIX OSDI '14*. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/yuan

Zarif, F., Galib, K. S. A., Promi, S. A., Tarin, S. S., Hossain, A., Ahmed, S., & Sadeque, F. Y. (2026). *Ignored, not refused: What low prompt-injection success rates hide in small tool-using agents*. arXiv:2610.23254. https://arxiv.org/abs/2610.23254

Zhao, X., Li, H., Li, S., Zhao, T., Barr, E. T., Sarro, F., & Ye, H. (2026). *Failure as a process: An anatomy of CLI coding agent trajectories*. arXiv:2607.09510. https://arxiv.org/abs/2607.09510

Zhu, J., Xie, S., Chen, A. L. F., Ding, X., Tang, C., Qi, R., & Fei, Y. (2026). *Failure-transparent agents: Benchmarking post-failure reporting in tool-using language models*. arXiv:2609.35732. https://arxiv.org/abs/2609.35732

Sobre el autor

Carlos Ulisses Flores es CTO e Investigador Jefe de Codex Hash Research Laboratory, un laboratorio independiente de I+D en São Paulo, Brasil. Construye sistemas de producción donde el fallo silencioso sale caro —históricamente en trading algorítmico, IoT embebido y criptografía en el borde, y hoy en herramientas de IA agéntica—. Esta nota surgió de usar claude -p como núcleo de ejecución autónoma y de verlo devolver el código de salida 0 ante un rechazo cortés.

Identificadores · ORCID: 0000-0002-6034-7765 · Lattes: 6905246706890561

Contacto · c.ulisses@gmail.com · https://ulissesflores.com