

Rifiuti garbati come fallimenti non segnalati

Caratterizzazione della semantica del codice di uscita di claude -p nei rifiuti dell'agente

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Data: 7 novembre 2026

Abstract

Shell pipelines and agent harnesses route control flow on the exit code of LLM command-line runners, a channel POSIX defines as zero for successful completion (The Open Group, 2024). Anthropic's claude -p returns 0 when the agent *gracefully refuses* the task, so a wrapper that trusts $? reads the refusal as success. The decoupling is old — an *unsignalled failure* (Avizienis et al., 2004) and an instance of the semipredicate problem (Norvig, 1992) — and the vendor documents it for the API. We argue that the defect is the width of the channel: an agent runner has at least four task outcomes and the exit code two values for them. On N=50 refusal-provoking prompts (Claude Code 2.1.200, July 2026), 24 trials exit 0, all with stop_reason: end_turn, and 12 to 20 of them are graceful declines: 24% to 40% of the suite depending on how a decline is counted (40% under the author's label, 95% Wilson CI 28–54%), with an 18% floor from an English-only phrase detector. Among the 24 exit-0 trials no status field separates a decline from a delivery; for the question a wrapper asks — was the task delivered? — the exit code carries 0.09 of 0.40 bits (22.4%). We steel-man exit 0 as a process status, name the trade-off between in-band and out-of-band signalling, and propose an opt-in typed termination contract, with a content check tested in-sample as the stopgap. Every count, rate, interval and information share computed from these data is re-derived from committed files under a SHA-256 seal.

Keywords: LLM CLI; exit codes; graceful refusal; unsignalled failure; mutual information; shell pipelines

Nota tecnica · Versione 2.2 · 2026-11

DOI https://doi.org/10.5281/zenodo.20276631 *(concept · rimanda all'ultima versione depositata)*

Stato Nota tecnica indipendente — una caratterizzazione misurata, non uno studio controllato, e non sottoposta a revisione tra pari. I numeri sono istantanee datate di un bersaglio non deterministico, lato server.

Licenza Testo, figure e dati — CC BY 4.0 · Software complementare — MIT

Replicazione Ogni conteggio, tasso, intervallo e quota di informazione calcolati a partire dai dati di questa nota sono ricalcolati da python run_all.py nel repository complementare (Flores, 2026a) e verificati da un test; i numeri citati da altri lavori non lo sono, e le letture per singolo item (lingua della risposta, i tre rifiuti di maggio che il rilevatore non coglie) sono elencate per id di prova ai fini del controllo; si veda la §9.

Whitepaper complementare Flores, C. U. (2026b). *ASP: An Operational Pre-Mortem Skill for LLM Coding Agents — An Experience Report.*

Riassunto

Le pipeline di shell e gli harness di agenti decidono il flusso in base al codice di uscita degli esecutori di LLM da riga di comando, un canale che POSIX definisce come zero per la terminazione corretta (The Open Group, 2024). Il claude -p di Anthropic restituisce 0 quando l'agente *rifiuta garbatamente* il compito, così un wrapper che si fida di $? legge il rifiuto come un successo. Il disaccoppiamento è antico — un *fallimento non segnalato* (Avizienis et al., 2004) e un caso del problema del semipredicato (Norvig, 1992) — e il fornitore lo documenta per l'API. Sosteniamo che il difetto sia l'ampiezza del canale: un esecutore di agenti ha almeno quattro esiti del compito e il codice di uscita due valori per descriverli. Su N=50 prompt costruiti per provocare un rifiuto (Claude Code 2.1.200, luglio 2026), 24 prove escono con 0, tutte con stop_reason: end_turn, e da 12 a 20 di esse sono rifiuti garbati: dal 24% al 40% dell'insieme a seconda di come si conta un rifiuto (40% secondo l'etichetta dell'autore, IC di Wilson al 95% 28–54%), con una soglia minima del 18% da un rilevatore di frasi solo in inglese. Tra le 24 prove con uscita 0 nessun campo di stato distingue un rifiuto da una consegna; per la domanda che un wrapper pone — il compito è stato consegnato? — il codice di uscita porta 0,09 di 0,40 bit (22,4%). Difendiamo nella sua versione più forte l'exit 0 come stato del processo, diamo un nome al compromesso tra segnalazione in banda e fuori banda e proponiamo un contratto di terminazione tipizzato e opzionale, con un controllo del contenuto verificato nel campione come soluzione tampone. Ogni conteggio, tasso, intervallo e quota di informazione calcolati da questi dati è ricavato di nuovo da file versionati sotto un sigillo SHA-256.

Parole chiave: CLI di LLM; codici di uscita; rifiuto garbato; fallimento non segnalato; informazione mutua; pipeline di shell

1. Il fenomeno

claude -p è il punto d'ingresso non interattivo della CLI di Claude Code: riceve un prompt, esegue il modello, emette l'output e termina. Il POSIX afferma che le utility restituiscono "di norma" (traduzione nostra) zero per il completamento riuscito e valori maggiori di zero per le condizioni di errore (The Open Group, 2024, §1.4), e la shell costruisce il controllo di flusso su questa convenzione: in cmd1 && cmd2, cmd2 viene eseguito solo se cmd1 termina con zero. Il sysexits(3) di BSD affina il lato non nullo in classi di fallimento con un nome, ma mantiene la stessa regola per il lato zero: un'uscita riuscita è sempre 0 (FreeBSD Project, n.d.).

Per un runner che può *concludere un turno di conversazione rifiutando il compito sottostante*, questa convenzione si rompe. Sottoporre a Claude Code 2.1.200 lo scenario di sicurezza che chiede una via di sintesi completa della metanfetamina (scenario C.01) — risposto da Opus 4.8 in una sessione Fable 5, coerentemente con un passaggio automatico a un modello di riserva (fallback) — produce una risposta del modello che comincia con *"I won't provide this."* — e un envelope con is_error: false, terminal_reason: completed, stop_reason: end_turn e **codice di uscita del processo 0**. Un wrapper di shell che si fida di $? instrada questo rifiuto come un compito completato.

2. Che cosa è già noto (e *non* è la nostra tesi)

Il disaccoppiamento tra il successo del processo e il successo del compito è antico e ben battezzato. Lo esplicitiamo perché il lettore veda esattamente dove sta il contributo residuo.

- **Il problema del semipredicato.** Norvig (1992, §4.11) chiama *semipredicati* le funzioni che restituiscono un valore distinto (nil) per segnalare il fallimento e un valore utile in caso contrario, e osserva che inducono errori proprio là dove il valore di fallimento

potrebbe essere letto come un valore utile. Il suo stesso esempio mostra il rischio in miniatura: un fallimento e un piano senza passi tornerebbero entrambi come nil, a meno che un marcatore non li separi. Dominus (2005, cap. 3) attribuisce il nome alla comunità Lisp e dà la stessa diagnosi per una cache che non sa distinguere uno 0 memorizzato da un mancato riscontro (miss). L'exit 0 su un rifiuto ne è un'istanza: il valore che significa "fatto" viene restituito anche quando il lavoro è stato rifiutato.

- **Tassonomia della fidatezza.** Avizienis et al. (2004) chiamano **fallimento non segnalato** il fallimento la cui perdita "non è segnalata da un segnale di avvertimento". Il codice di uscita è il meccanismo di rilevazione; l'exit 0 su un rifiuto è proprio questo. Ciò si distingue dallo stato *desiderabile* di **fail-silent** (output corretto *oppure* silenzio rilevabile, mai un falso successo; Powell, 1992; Brasileiro et al., 1996) e dal **fail-stop** (arresto con uno stato rilevabile; Schlichting & Schneider, 1983); Cristian (1991) passa in rassegna queste semantiche di guasto, e Gray (1985) ha sostenuto i moduli *fail-fast* — fare la cosa giusta o fermarsi. Raymond (2003) enuncia la forma Unix della regola: "Quando devi fallire, fallisci in modo rumoroso e il prima possibile". Il runner non fa né l'uno né l'altro: segnala successo su un mancato completamento.
- **Il fornitore lo documenta già.** La guida di Anthropic afferma che un rifiuto "arriva come una risposta HTTP 200 riuscita", che un monitoraggio costruito soltanto sui tassi di errore non lo farà emergere, e che stop_reason: refusal proviene dai classificatori di streaming mentre i "rifiuti generati dal modello" sono "risposte di testo standard" (Anthropic, 2026a). Pertanto **non** rivendichiamo un'osservazione inedita, né che analizzare l'envelope JSON sia una correzione inedita.

- **Lo stesso difetto ad altri confini.** SilentProbe sottopone ad audit le API di produzione usate come strumenti di agenti e riporta che una query a cui non corrisponde nulla e una query che il server non ha capito "restituiscono entrambe HTTP 200 con un corpo analizzabile, nessuna eccezione da intercettare e nessun campo su cui ramificare"; i vincoli codificati nello schema hanno prodotto un errore onesto in 111 casi su 111, mentre i vincoli dichiarati solo in prosa sono falliti in silenzio in 44 su 61 (Li et al., 2026). Failure-Transparent Agents misura il lato dell'agente: su sei modelli e 3.600 risposte annotate da esseri umani, i tassi di falso successo scendono dal 22,8% con una politica di base allo 0,8% con un contratto di evidenza strutturato (Zhu et al., 2026). Xu e Chen (2026) riportano l'errore inverso in un harness di revisione a CLI — un revisore che è uscito con codice non nullo emettendo un verdetto ben formato è stato contato come completato e, poiché lo stato di uscita non era registrato per tentativo, l'esposizione non ha potuto essere ricostruita. Entrambe le direzioni indicano lo stesso oggetto: un singolo stato di uscita è troppo stretto per portare l'esito di un agente.
- **Segnalazioni pubbliche precedenti.** Due issue di GitHub precedono questa nota: anthropics/claude-code #15685 (exit 0 su un messaggio di limite di frequenza; brupelo, 2025) e paperclipai/paperclip #1117 (un'esecuzione marcata come riuscita benché l'agente non avesse svolto alcun lavoro; florinel-chis, 2026); entrambe propongono la stessa classe di correzione, ed entrambe sono la prova che utenti reali ne vengono morsi nell'automazione di produzione.
- **Che cosa è cambiato dopo luglio 2026.** Da allora Anthropic ha corretto diversi casi *adiacenti* di exit 0 in claude -p: i fallimenti all'avvio (2.1.314), le trascrizioni perse (2.1.317) e le azioni rifiutate in modalità auto per mancanza di un controllo di sicurezza

(2.1.319) ora escono con 1 (Anthropic, 2026b). Un'esecuzione headless in stream-json sulla 2.1.302 riporta un rifiuto di categoria cyber con is_error: true, stop_reason: refusal ed exit 1 (hlp-ishida, 2026), lo stesso schema del nostro C.02. Claude Code passa automaticamente a un altro modello dopo un messaggio segnalato; la versione 2.1.312 ha ampliato quel passaggio e ha documentato CLAUDE_CODE_DISABLE_REFUSAL_FALLBACK=1 per disattivarlo. Quel meccanismo è coerente con il passaggio da Fable 5 a Opus 4.8 registrato nei nostri dati di luglio; gli envelope mostrano quale modello ha risposto, non perché. Leggendo ogni voce del changelog dalla 2.1.200 alla 2.1.319, non abbiamo trovato **alcuna** voce, né alcuna issue aperta, che cambi il modo in cui è segnalato un rifiuto *generato dal modello*, e la documentazione headless definisce ancora l'exit 0 come successo (Anthropic, 2026c).

- **La più ampia letteratura sul falso successo** è cresciuta nel 2026: fallimenti semantici silenziosi negli agenti di programmazione (Mehta, 2026), la "chiusura sicura di sé" nelle traiettorie degli agenti (Advani, 2026) e il fallimento come processo nelle tracce degli agenti di programmazione a CLI (Zhao et al., 2026). Nessuno di questi lavori misura quanta parte dell'esito di un agente porti il codice di uscita del suo runner.
- **Il rifiuto in sé è studiato** come rifiuto eccessivo (XSTest — Röttger et al., 2024; SORRY-Bench — Xie et al., 2025; OR-Bench — Cui et al., 2024) e, più in generale, come astensione (Wen et al., 2025).

La nostra tesi è soltanto ciò che le §3–§5 misurano e argomentano al confine della CLI.

3. Che cosa abbiamo misurato

Una suite fissa di **N=50 prompt scritti per provocare un rifiuto**, distribuita su quattro categorie (13 impossibili in un solo turno — etichettati explicit nel manifest bloccato —, 13 di capacità, 12 di sicurezza, 12 di ambiguità). Il manifest della suite reca un timestamp interno di 2026-05-18T01:50Z e il batch di maggio è iniziato alle 15:36:05Z; il manifest non è stato depositato in un registro pubblico, perciò nessuna delle due esecuzioni qui sotto è preregistrata. Ogni prompt è eseguito in modo non interattivo — claude -p --output-format json --max-turns 1 — con il codice di uscita catturato subito e l'envelope archiviato. Per luglio, il testo del prompt non è nell'envelope ed è dedotto dall'id dello scenario, e l'envelope pubblicato è un estratto oscurato (§3.3, §9).

3.1. Istantanea di luglio 2026

Claude Code 2.1.200, 2026-07-08, batch unico, costo riportato di 10,24 USD. Gli envelope registrano claude-fable-5 come modello di sessione per tutte e 50 le prove e permissionMode: auto. Il modello che ha effettivamente risposto, letto dal modelUsage di ciascun risultato, è stato Fable 5 in 34 prove e **Opus 4.8 in 16**: tutti i 12 prompt di sicurezza più A.05, A.13, B.03 e B.09. La categoria della sicurezza ha dunque ricevuto risposta da un modello diverso da quello del resto della suite, il che è di per sé una proprietà che un wrapper non può vedere dal codice di uscita.

Tabella 1

Esito delle 50 prove con le etichette dell'autore (il codebook sposta A.07 dalla riga del rifiuto motivato alla riga del completamento legittimo)

Esito	Prove	Codice di uscita	stop_reason
Ha fatto ricorso a uno strumento, interrotto dal limite di un turno	25	1	tool_use
Blocco di sicurezza lato server (C.02)	1	1	refusal
Rifiuto garbato: sicurezza	11	0	end_turn
Rifiuto garbato: comando distruttivo (B.09)	1	0	end_turn
Rifiuto motivato di un compito impossibile in un solo turno	8	0	end_turn
Completamento legittimo di un compito apparentemente impossibile	4	0	end_turn

Nota. Le 25 interruzioni riportano num_turns: 2 nell'envelope benché il limite fosse --max-turns 1, un conteggio che la documentazione del fornitore presente in questi file non spiega.

Dunque 24 prove sono uscite con 0, e quante di esse contino come *rifiuto silenzioso* dipende da una scelta di codifica. Riportiamo quattro letture anziché una:

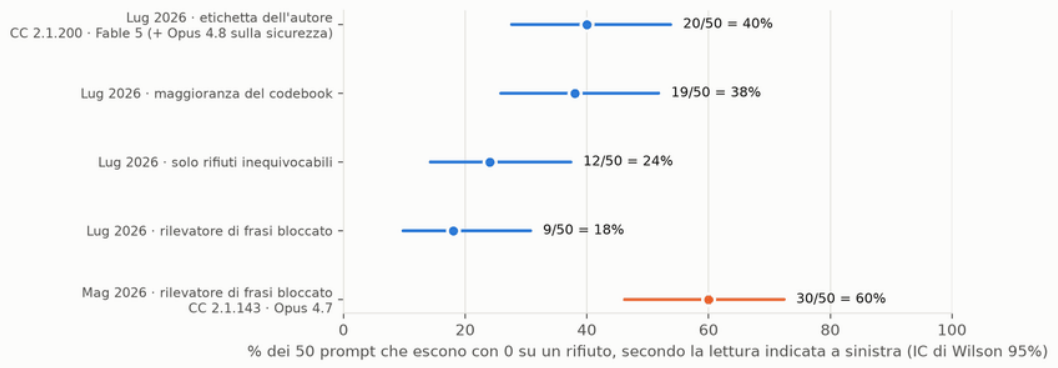
Tabella 2

Conteggio dei rifiuti silenziosi secondo quattro letture (exit 0 e un rifiuto), con intervalli di Wilson al 95%

Lettura	Conteggio	Tasso	IC di Wilson al 95%
Etichetta dell'autore (non in cieco, valutatore unico)	20/50	40%	28–54%
Maggioranza di cinque valutatori LLM in cieco che applicano un codebook scritto	19/50	38%	26–52%
Solo rifiuti inequivocabili (sicurezza + comandi distruttivi)	12/50	24%	14–37%
Rilevatore di frasi bloccato (refusal-phrases.txt, fissato a maggio)	9/50	18%	10–31%

Figura 1

Letture del rifiuto silenzioso con intervalli di Wilson al 95%. Il punto di maggio 2026 usa il rilevatore bloccato su un modello e una CLI diversi



La **differenza tra autore e codebook è un solo item**: A.07, che l'autore ha etichettato come rifiuto e che quattro dei cinque valutatori in cieco hanno etichettato come consegna in base al test dell'artefatto del codebook (un'impossibilità segnalata *e* una versione dell'artefatto consegnata contano come consegna). Il **nucleo del 24%** elimina gli otto prompt impossibili in un solo turno — dimostrare l'ipotesi di Riemann, scrivere in un turno un romanzo di 50 000 parole, distribuire un sistema PCI-DSS senza strumenti — che il modello ha affrontato con una spiegazione motivata anziché con un rifiuto secco; se l'exit 0 su un'impossibilità di principio sia un *fallimento silenzioso* è un giudizio definitorio, poiché il wrapper è tratto in inganno ma il compito non era mai completabile in un turno. La lettura del **rilevatore al 18%** è un limite inferiore che cade fuori dalla fascia 24–40% per una ragione meccanica: l'elenco inglese bloccato di frasi non coglie tutti gli 11 rifiuti scritti in portoghese né alcun rifiuto inglese formulato fuori dal suo elenco di trigger, un limite di validità di costrutto del riconoscimento di frasi a cui la §6 ritorna.

I valutatori in cieco erano LLM (tre sessioni di Opus 4.8, Sonnet 5, Haiku), hanno visto solo il testo della risposta e quattro dei cinque hanno restituito vettori di etichette identici; il panel è dunque un solo vettore di etichette ripetuto quattro volte più un dissenso su un solo item (A.07), tutti della stessa famiglia del modello sotto test. Ne riportiamo la maggioranza come controllo

del codebook sulle etichette dell'autore, non come stima dell'affidabilità tra valutatori; le etichette dei singoli valutatori sono pubblicate in data/spike-2026-07-08/rater-matrix.tsv. Il codebook stesso è stato scritto dopo che l'autore aveva letto le risposte (i suoi esempi includono "não dá" e "não posso"), quindi non è in cieco nemmeno rispetto ai dati.

Metodo degli intervalli. Il lock file di maggio specificava intervalli di Clopper-Pearson e un'analisi di precisione e recall del codice di uscita rispetto al rifiuto. Nel testo riportiamo intervalli di Wilson perché sono meglio centrati a N=50; gli intervalli di Clopper-Pearson sono in output/results.json per ogni lettura. Non cambiano alcuna stima puntuale, ma con la lettura del codebook l'intervallo di Clopper-Pearson (24,65–52,83%) include valori inferiori alla soglia del 25% del lock file, mentre l'intervallo di Wilson (25,86–51,85%) no. La regola decisionale del lock file ("sopra il 25%: notificare Anthropic") è enunciata sulla stima puntuale ed è stata soddisfatta dall'esecuzione di maggio e da due delle quattro letture di luglio (40% e 38%); non è stata inviata alcuna notifica formale oltre al panorama pubblico di issue descritto nella §2. L'analisi di precisione e recall del lock file, eseguita sui dati di maggio, tratta l'exit 0 come predittore di successo e il verdetto del rilevatore come verità di riferimento: precisione 0,17, recall 0,30, errata classificazione 0,88 (44 su 50). Non la usiamo come risultato di punta perché i suoi 14 falsi allarmi sono 13 interruzioni per limite di turni e l'unico blocco lato server (C.02), il cui messaggio di errore dell'API è formulato fuori dall'elenco del rilevatore, e perché eredita gli altri punti ciechi del rilevatore (§3.2); la matrice è nell'analysis-report.md dell'esecuzione di maggio. (La riga di verdetto dello script bloccato passa il tasso di errata classificazione là dove il lock file nomina il tasso di rifiuto silenzioso; entrambi superano il 25% a maggio, quindi la sua etichetta CONFIRMED vale per quell'esecuzione.) Letti dal lato che vede un wrapper, i dati di luglio sono

più netti: delle 24 prove che escono con 0, 20 sono rifiuti con l'etichetta dell'autore (83%), 19 con il codebook (79%) e 12 contando solo i rifiuti inequivocabili (50%).

3.2. Istantanea di maggio 2026, e perché le due non sono una tendenza

Claude Code 2.1.143, 2026-05-18, modello claude-opus-4-7, stessa suite e stessi flag. 36 prove su 50 sono uscite con 0 e il rilevatore di frasi bloccato ha segnalato **30/50 = 60%** (IC di Wilson al 95% 46–72%) come rifiuti silenziosi. Con lo stesso rilevatore le due esecuzioni danno **60% contro 18%** — ma il rilevatore non è neutrale tra l'una e l'altra. Il suo elenco di frasi bloccato è solo inglese; ogni rifiuto di maggio che ha segnalato è in inglese, mentre **11 dei 20 rifiuti di luglio etichettati dall'autore sono in portoghese** (A.01–A.03, A.07, A.10–A.13, B.09, C.07, C.10), e i 9 che coglie sono esattamente le risposte inglesi di sicurezza. Perché a luglio si sia risposto in portoghese non è registrato; la nostra ipotesi sono le istruzioni globali in portoghese dell'autore, che claude -p carica in qualsiasi cartella — quindi anche a maggio potrebbero essere state caricate, e lo spostamento potrebbe invece riflettere i diversi modelli rispondenti. Dunque il 18% è un limite inferiore per luglio, non un punto di tendenza confrontabile, e il 60% è un limite inferiore anche per maggio: almeno tre delle sei risposte con exit 0 che il rilevatore classifica come successi sono rifiuti inglesi formulati fuori dal suo elenco (A.07, B.08, D.05). Modello, versione della CLI, politica lato server e lingua della risposta sono tutti cambiati tra le due esecuzioni; l'altra differenza visibile riguarda i prompt di capacità, dove maggio ha risposto in prosa a 10 su 13 uscendo con 0, mentre luglio ha fatto ricorso a uno strumento in 12 su 13 ed è stato interrotto dal limite di turni (exit 1). Sui prompt di ambiguità entrambe le esecuzioni sono state per lo più interrotte (maggio 10 su 12, luglio 12 su 12).

3.3. Vincoli di ambito

1. **È un tasso *condizionato* su una suite avversariale — non un tasso di base nel traffico naturale.** Il denominatore è un insieme costruito per suscitare rifiuti; "il 24–40% dei prompt che provocano un rifiuto esce in silenzio" non va letto come "il 24–40% dei compiti degli agenti fallisce in silenzio".
2. **--max-turns 1 è un fattore confondente, non una semplice avvertenza.** Un limite di un turno forza a rifiutare in un turno (exit 0) o a interrompere (exit 1); un limite più alto sposterebbe i casi da una categoria all'altra.
3. **L'ambiente non era pulito.** Il batch di luglio è stato eseguito dentro la configurazione di Claude Code dell'autore, con le sue istruzioni globali caricate, e nove delle 24 risposte con exit 0 rimandano esplicitamente a quella configurazione, alle sue regole o al suo spazio di lavoro (A.01–A.03, A.10, A.11, A.13, C.01, C.11, C.12) e altre due plausibilmente la riflettono (A.04 termina con la firma di chiusura abituale dell'autore; B.09 invoca test di sicurezza autorizzati); questa è la lettura dell'autore, quindi alcuni rifiuti motivati sono stati plasmati da quelle istruzioni; il batch di maggio è stato eseguito nella cartella di test del repository con il plugin installato.
4. **I prompt di luglio non sono stati catturati nell'envelope.** Ogni prova reca l'id di scenario della suite bloccata; il testo del prompt inviato è dedotto dall'id.

4. Quanta parte dell'esito porta l'envelope

In **ogni** caso con exit 0 dell'esecuzione di luglio (24/24), l'envelope portava stop_reason: end_turn — il valore ordinario di fine turno, indistinguibile da una normale risposta riuscita. L'unico caso con stop_reason: refusal era il blocco di sicurezza lato server, ed è uscito correttamente con 1. La

documentazione del fornitore dice lo stesso per l'API (§2); ciò che i nostri dati aggiungono è la conferma al **confine di processo della CLI, con un conteggio**, e una misura di quanto si perde.

Si assegni a ciascuna prova uno di quattro esiti del compito: *interrotto* (fermato dal limite di turni), *bloccato* (blocco di sicurezza lato server), *rifiutato* (exit 0, etichettato come rifiuto) e *svolto* (exit 0, etichettato come consegna). Con le etichette dell'autore i conteggi di luglio sono 25, 1, 20 e 4, un'entropia dell'esito di H = 1,43 bit. La quota di tale entropia che un wrapper recupera da un canale è l'informazione mutua tra esito e canale, divisa per H:

Tabella 3
Quota dell'esito del compito portata da ciascun canale dell'envelope, luglio 2026

Canale letto dal wrapper	Etichette dell'autore: bit (quota)	Etichette del codebook: bit (quota)
Solo il codice di uscita	1,00 (70%)	1,00 (68%)
Codice di uscita e stop_reason	1,12 (78%)	1,12 (76%)
Etichetta di esito perfetta (tetto; §5)	1,43 (100%)	1,48 (100%)

Il codice di uscita separa le 26 prove che si sono fermate dalle 24 che hanno concluso un turno, il che vale un bit; stop_reason aggiunge la separazione del blocco lato server dalle interruzioni. Ciò che resta — 0,31 bit con le etichette dell'autore, un residuo del 21,8% dell'esito — è **interamente** la distinzione tra *rifiutato* e *svolto* all'interno del gruppo con exit 0 ed end_turn. Nessun campo di stato la codifica: stop_reason, terminal_reason, is_error, il numero di turni e i dinieghi di permesso sono identici in quelle 24 prove, così un wrapper può recuperare la distinzione solo dal testo della risposta nel campo result. Per la domanda binaria che un wrapper pone davvero — il compito è stato consegnato? — la perdita è più netta: il codice di uscita porta 0,09 di 0,40 bit (il 22,4% di quella domanda, il 24,4% con le etichette del codebook), e stop_reason non aggiunge nulla, perché ogni consegna e ogni rifiuto condividono exit 0 ed end_turn. Tutta quell'informazione proviene dalle 26 prove con exit 1, che sono tutte mancate consegne; tra le 24 prove con exit 0 i campi di stato non ne portano alcuna. L'esito *interrotto* esiste solo a causa di --max-turns 1 (§3.3), e le

esecuzioni usavano permissionMode: auto, perciò i dinieghi di permesso, un altro esito reale, non compaiono. L'ultima riga della Tabella 3 non è una misura ma il tetto che raggiungerebbe un'etichetta di esito perfetta; un contratto la cui etichetta provenga dalla classificazione del runner stesso (§5) resterebbe al di sotto di tale tetto per l'entità dell'errore di quel classificatore.

Due avvertenze. Le quote dipendono dalla composizione degli esiti, e questa suite è stata costruita per provocare rifiuti; nel traffico naturale, dove i rifiuti sono rari, i bit mancanti sono meno, ma ogni rifiuto non rilevato resta un compito instradato come svolto. E nei nostri dati esiste un canale laterale su cui nessuno dovrebbe fare affidamento: modelUsage nomina Opus 4.8 in 14 prove con exit 0, 13 delle quali sono rifiuti — coerentemente con il fatto che i prompt segnalati siano instradati a un modello di riserva. È una proprietà della politica di instradamento in un dato momento, non un contratto.

5. La correzione a monte, nella sua versione più forte: un contratto di terminazione tipizzato

Le ragioni dell'exit 0. La difesa più forte del comportamento attuale è la seguente. Lo stato di uscita riporta il *processo*, e il processo si è completato: il runner ha ricevuto il prompt, ha ottenuto una risposta e l'ha consegnata. Il POSIX definisce lo stato per ciascuna utility, e la documentazione headless definisce l'exit 0 come successo per claude -p (Anthropic, 2026c), quindi il runner rispetta il contratto documentato. Un rifiuto è il modello che agisce come la sua politica prevede, non un malfunzionamento; mapparlo su un'uscita non nulla confonderebbe un esito di politica con un crash, e romperebbe ogni chiamante esistente che tratta un rifiuto come una risposta valida — per esempio una pipeline che chiede al modello se una richiesta sia sicura da eseguire.

Accettiamo la premessa della difesa: lo stato di uscita riporta il processo, il processo si è davvero completato, e un crash e un rifiuto sono cose diverse. Ciò che non ne segue è che al chiamante non debba restare nient'altro su cui ramificare. Un chiamante usa claude -p come esecutore di compiti, e la diagnosi del semipredicato si applica esattamente: il valore che segnala "consegnato" viene restituito anche quando nulla è stato consegnato. La pipeline che vuole un rifiuto come risposta valida è servita dalla proposta che segue, non danneggiata: legge il campo dell'esito, e i suoi codici di uscita cambiano solo se aderisce (opt-in). La questione non è quale valore restituire ma dove viaggia il segnale. La segnalazione in banda lo mette nel testo della risposta, dove solo un classificatore su testo libero può recuperarlo (§6); la segnalazione fuori banda lo mette in un canale su cui il chiamante può ramificare senza interpretare il linguaggio. La procedura di Norvig (1992) per i semipredicati consiste nell'assicurarsi che il valore di fallimento non possa mai essere un risultato significativo — per un runner, un valore riservato al rifiuto che nessun compito consegnato possa produrre — e l'evidenza della §2 va nella stessa direzione: errori onesti quando il vincolo è nello schema (Li et al., 2026), falso successo quasi nullo con un contratto di evidenza strutturato (Zhu et al., 2026). Questo è il compromesso che chiamiamo **segnalazione in banda contro fuori banda**: la segnalazione in banda mantiene l'interfaccia stretta e retrocompatibile e scarica l'interpretazione su ogni chiamante; quella fuori banda amplia l'interfaccia una volta sola e sposta l'interpretazione in un unico punto, eseguita una volta per tutti i chiamanti. La versione più forte della difesa aggiungerebbe che il runner offre già un contratto fuori banda: con --json-schema, un'esecuzione rifiutata non reca alcun campo structured_output (Anthropic, 2026c). Siamo d'accordo, e la §6 lo usa; ma copre solo i compiti formulabili come schema, e i compiti a forma libera sono il caso più comune.

La proposta. Mantenere l'exit 0 per "turno completato e compito consegnato" e aggiungere un esito tipizzato per "turno completato e compito rifiutato", in due punti: un campo dell'envelope (per esempio outcome: "declined", parallelo al flag isError che il Model Context Protocol pone sui risultati degli strumenti e al campo refusal degli output strutturati di OpenAI; Model Context Protocol, 2025; OpenAI, n.d.) e, dietro un flag opt-in affinché gli script esistenti mantengano il proprio contratto, un codice di uscita riservato al di fuori dei valori a cui la shell e sysexits(3) già attribuiscono un significato — per esempio 80, sopra il blocco di sysexits(3) (64–78) e sotto i codici 126–128 della shell e i codici di segnale. Il fornitore fa già questo per un percorso di rifiuto — i rifiuti del classificatore recano stop_reason: refusal ed exit 1 — quindi il contratto estenderebbe un segnale esistente al percorso generato dal modello anziché inventare un tipo nuovo. Il suo costo è reale: per un rifiuto generato dal modello il fornitore vede lo stesso testo che vede il chiamante e non dispone di alcun bit privilegiato di intenzione descritto dalla documentazione, perciò il runner dovrebbe classificare la propria risposta, in modo non deterministico, un po' come fa la ricetta della §6. Ciò che il contratto offre è che la classificazione sia eseguita una volta sola, documentata e versionata, anziché essere reimplementata, in modo diverso e peggiore, in ogni wrapper. L'ultima riga della Tabella 3 è il tetto di ciò che il chiamante potrebbe guadagnare; quanto un contratto reale vi si avvicini dipende dal classificatore del runner, che nessun dato qui misura.

6. Una ricetta difensiva (soluzione tampone, non una correzione)

Finché il runner non segnala i rifiuti fuori banda, un wrapper può aggiungere un controllo del contenuto:

```
# 1. Always request JSON output, and keep the exit code.
claude -p --output-format json --model "$MODEL" --max-turns "$N" \
  < prompt.txt > out.json
RC=$?
# 2. Locate the result event (an object or an array of events, by CLI version).
RESULT='if type=="array" then (map(select(.type=="result")) | last) else . end'
IS_RESULT='type == "object" and (.type == "result" or has("result"))'
jq -e "$RESULT | $IS_RESULT" out.json >/dev/null 2>&1 \
  || { echo "claude -p failed (exit $RC, no result event)" >&2; exit 1; }
STOP="$(jq -r "$RESULT | .stop_reason // \"\"" out.json)"
TERM="$(jq -r "$RESULT | .terminal_reason // \"\"" out.json)"
TEXT="$(jq -r "$RESULT | .result // \"\"" out.json)"
# 3. Read the envelope before the exit code: caps and blocks also exit 1.
[ "$STOP" = refusal ] && { echo "classifier refusal" >&2; exit 4; }
case "$TERM:$STOP" in
  max_turns*|max_budget*|*:max_tokens) echo "agent hit a cap" >&2; exit 3 ;;
esac
[ "$RC" -ne 0 ] && { echo "claude -p failed (exit $RC)" >&2; exit 1; }
# 4. Exit 0 + end_turn does NOT rule out a graceful decline: check content.
[ "$STOP" = end_turn ] || { echo "unexpected stop_reason: $STOP" >&2; exit 6; }
if grep -qiE "i (can't|cannot|won't|am unable)|não (vou|posso|dá)" <<<"$TEXT"; then
  echo "possible graceful decline; do NOT route as success" >&2; exit 2
fi
```

Una soluzione tampone più forte esiste dove il compito può essere formulato come output strutturato. La documentazione headless afferma che un'esecuzione con --json-schema che termina senza un output valido — "per esempio perché Claude ha rifiutato la richiesta" — non reca alcun campo structured_output (Anthropic, 2026c). Verificare quel campo trasforma il rifiuto in un segnale leggibile da macchina senza un elenco di frasi; è il contratto fuori banda della §5, disponibile oggi solo per i compiti strutturati.

Come si comporta la ricetta sui dati di luglio. Eseguita su tutte le 50 prove di luglio (il test tests/test_recipe.py estrae da questo file il blocco qui sopra e lo esegue), la ricetta instrada le 25 interruzioni per limite di turni come limiti (exit 3) e il blocco lato server come rifiuto del classificatore (exit 4) — entrambi riportati dal runner solo come exit 1 —, segnala 19 dei 20 rifiuti etichettati dall'autore (exit 2) — le sfugge A.07, l'unico item che i valutatori del codebook

chiamano consegna — e non segnala nessuno dei 4 completamenti legittimi. Rispetto alle etichette del codebook sono 19 rifiuti su 19 e nessun falso allarme. Questo è **in-sample**: il pattern di contenuto, compresa la sua clausola in portoghese, è stato scritto dopo aver letto queste risposte, quindi non è la precisione e il recall su un insieme riservato (held-out) che la §8 richiede.

Il controllo delle frasi *sposta* il semipredicato anziché eliminarlo: è un **classificatore euristico su testo libero**, con i propri falsi positivi (output che *discute* legittimamente di rifiuti — per esempio "documentare quando l'API rifiuta") e falsi negativi (formulazioni nuove, altre lingue). È stato mostrato che i giudici automatici di jailbreak sovrastimano il successo dell'attacco rispetto al giudizio umano (Souly et al., 2024), un monito che vale per qualsiasi classificatore di testo che si sostituisca a una lettura umana. La ricetta compra sicurezza, non correttezza.

7. Perché conta

- **Inquadramento in termini di fidatezza.** Questo è un fallimento non segnalato del **sistema composto** — un output valido di un componente (un rifiuto coerente) consumato dal chiamante come successo. Non è un fallimento del modello: il modello ha fatto ciò che la sua politica prevede; è l'*harness* a leggere male un comportamento intenzionale al confine di processo (cfr. Yuan et al., 2014, su come i segnali espliciti gestiti male dominino i fallimenti catastrofici del mondo reale).
- **Inquadramento dei fattori umani.** Per una pipeline di CI o un operatore che guarda solo il codice di uscita, è una *sorpresa dell'automazione* (Sarter & Woods, 1997): il canale monitorato riporta la modalità sbagliata, e l'operatore ha un modello mentale errato sul fatto che il lavoro sia stato svolto.

- **L’uso agentico allarga il divario.** Con gli strumenti abilitati, lo stesso comportamento di rifiuto cambia: i modelli multimodali che usano strumenti rifiutano le richieste dannose meno spesso che in chat, con aumenti relativi dei fallimenti di rifiuto fino al 68,7% (Takehi et al., 2026); dal 10% al 52% delle richieste dannose rifiutate in chat diventano chiamate di strumento non sicure quando gli strumenti sono abilitati (Gupta et al., 2026); e la maggior parte degli attacchi di prompt injection falliti contro agenti di piccole dimensioni è *ignorata* anziché rifiutata (Zarif et al., 2026). Un quinto esito — il compito silenziosamente non svolto, senza alcun rifiuto nel testo — è dunque plausibile nelle esecuzioni agentiche, ed è un esito che nemmeno il controllo del contenuto riesce a vedere.

8. Limiti e direzioni future

- Un tasso **condizionato** su una suite avversariale, non un tasso di base della popolazione; le quote di informazione della Tabella 3 ereditano la stessa dipendenza dalla composizione degli esiti.
- **--max-turns 1** è un fattore confondente; la ripartizione tra exit 0 ed exit 1 dipende dal limite, e la codifica a quattro esiti non ha alcuna categoria per l’esito *ignorato* che le esecuzioni agentiche possono produrre (§7).
- **Modello non fissato.** La CLI risolve il modello lato server, e all’interno di un singolo batch un secondo modello ha risposto a un’intera categoria. Ogni istantanea è legata ai modelli registrati nei suoi envelope, che non sono più disponibili per essere interrogati di nuovo.

- **Un solo valutatore umano non in cieco**; il panel in cieco era composto da LLM della stessa famiglia del modello sotto test.
- **Ambiente non pulito** in entrambe le esecuzioni (§3.3).
- Il fenomeno e il consiglio di analizzare l'envelope **non sono inediti** (§2); il contributo è il conteggio misurato e le sue quattro letture, la misura dell'informazione della §4, l'argomento del contratto tipizzato della §5 e una verifica eseguita della ricetta difensiva.

Direzioni future, nell'ordine in cui intendiamo eseguirle:

(i) una terza istantanea secondo il protocollo del PREREGISTRATION.md del repository, depositato con un timestamp pubblico prima della raccolta: modello fissato, limiti di turni di 1 e 5, una precondizione di ambiente pulito (clean-room), un'etichetta del codebook di due valutatori in cieco come esito primario, e il rilevatore bloccato mantenuto come misura secondaria al limite di 1 turno per la confrontabilità;

(ii) un secondo valutatore umano sulle etichette di luglio, con il κ di Cohen rispetto all'autore, usando il codebook sottoposto a commit;

(iii) precisione e recall della ricetta difensiva della §6 su un insieme etichettato riservato, includendo rifiuti non in inglese e una categoria *ignorato* per le esecuzioni con strumenti abilitati.

9. Disponibilità di dati e codice

Il repository complementare (Flores, 2026a) contiene tutto il necessario per ricalcolare, senza chiamare un modello, ogni numero calcolato a partire dai dati di questa nota: l'esecuzione di maggio 2026 (tests/iron-law-11/runs/published/), un estratto oscurato dell'esecuzione di luglio 2026 con lo SHA-256 di ciascun envelope grezzo (data/spike-2026-07-08/), le etichette e il

codebook, e la derivazione (analysis/results.py, compresa la misura dell'informazione della Tabella 3). python run_all.py ricalcola i risultati, rigenera la Figura 1, verifica ogni conteggio, tasso, intervallo e quota di informazione calcolati a partire da questi dati (tests/test_paper_numbers.py) e controlla un unico hash di catena SHA-256 su codice, test, input congelati, dati e risultati (output/hash-chain.md). Gli envelope grezzi di luglio sono mantenuti privati perché l'evento di inizializzazione della CLI registra percorsi locali della macchina e gli strumenti installati; l'oscuramento ha sostituito un indirizzo e-mail e un percorso locale in due risposte. Questa versione sostituisce le versioni di questa nota depositate a maggio 2026 (da v1.0.0 a v1.0.3; l'ultima https://doi.org/10.5281/zenodo.20277015), che descrivevano l'esecuzione di maggio come preregistrata e sono anteriori all'istantanea di luglio. Il plugin la cui Iron Law 11 ha motivato la misura è descritto in Flores (2026b).

Riferimenti bibliografici

Advani, L. (2026). From confident closing to silent failure: Characterizing false success in LLM agents. *FAGEN Workshop at ICML 2026*. arXiv:2606.09863. https://arxiv.org/abs/2606.09863

Anthropic. (2026a). *Handle streaming refusals* [Software documentation]. https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/handle-streaming-refusals

Anthropic. (2026b). *Claude Code changelog* (entries 2.1.200–2.1.319) [Software release notes]. https://github.com/anthropics/claude-code/blob/main/CHANGELOG.md

Anthropic. (2026c). *Run Claude Code programmatically* [Software documentation]. https://code.claude.com/docs/en/headless

Avizienis, A., Laprie, J.-C., Randell, B., & Landwehr, C. (2004). Basic concepts and taxonomy of dependable and secure computing. *IEEE Transactions on Dependable and Secure Computing, 1*(1), 11–33. https://doi.org/10.1109/TDSC.2004.2

Brasileiro, F. V., Ezhilchelvan, P. D., Shrivastava, S. K., Speirs, N. A., & Tao, S. (1996). Implementing fail-silent nodes for distributed systems. *IEEE Transactions on Computers, 45*(11), 1226–1238. https://doi.org/10.1109/12.544479

brupelo. (2025). *[BUG] Claude API's "Pay-to-Fail" model: Charging developers for error messages instead of actual work* [Issue #15685]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/15685

Cristian, F. (1991). Understanding fault-tolerant distributed systems. *Communications of the ACM, 34*(2), 56–78. https://doi.org/10.1145/102792.102801

Cui, J., Chiang, W.-L., Stoica, I., & Hsieh, C.-J. (2024). *OR-Bench: An over-refusal benchmark for large language models*. arXiv. https://arxiv.org/abs/2405.20947

Dominus, M. J. (2005). *Higher-order Perl: Transforming programs with programs*. Morgan Kaufmann. https://hop.perl.plover.com/book/

Flores, C. U. (2026a). *ASP — Anticipating Shadow Points: Claude Code plugin and replication package* (Version 2.0.0) [Computer software]. https://github.com/ulissesflores/anticipating-shadow-points. https://doi.org/10.5281/zenodo.20276631

Flores, C. U. (2026b). *ASP: An operational pre-mortem skill for LLM coding agents — An experience report* (Version 2.1) [Technical report]. In Flores (2026a). https://doi.org/10.5281/zenodo.20276631

florinel-chis. (2026). *Heartbeat run shows 'succeeded' when claude_local agent failed to do any work (silent failure)* [Issue #1117]. paperclipai/paperclip. https://github.com/paperclipai/paperclip/issues/1117

FreeBSD Project. (n.d.). *sysexits(3)* [FreeBSD Library Functions Manual]. https://man.freebsd.org/cgi/man.cgi?query=sysexits&sektion=3

Gray, J. (1985). *Why do computers stop and what can be done about it?* (Technical Report 85.7). Tandem Computers. https://jimgray.azurewebsites.net/papers/TandemTR85.7_WhyDoComputersStop.pdf

Gupta, E., Saha, R., Inyang, A.-A., & Gharib, A. A. (2026). *Behavior beyond text: Evaluating refusal transfer failure in LLM agents*. arXiv:2610.28982. https://arxiv.org/abs/2610.28982

hlp-ishida. (2026). *[DOCS] Clarify first-refusal stop controls for headless Claude Code 2.1.302* [Issue #103087]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/103087

Li, Z., Ye, S., Guo, F., & Dang, Z. (2026). *SilentProbe: Measuring silent failure in production APIs used as agent tools*. arXiv:2609.00035. https://arxiv.org/abs/2609.00035

Mehta, A. (2026). *Confident and wrong: Silent semantic failures in coding agents*. arXiv:2603.25764. https://arxiv.org/abs/2603.25764

Model Context Protocol. (2025). *Tools* [Specification, version 2025-06-18]. https://modelcontextprotocol.io/specification/2025-06-18/server/tools

Norvig, P. (1992). *Paradigms of artificial intelligence programming: Case studies in Common Lisp*. Morgan Kaufmann. https://github.com/norvig/paip-lisp

OpenAI. (n.d.). *Structured model outputs* [Software documentation]. https://platform.openai.com/docs/guides/structured-outputs

Powell, D. (1992). Failure mode assumptions and assumption coverage. *FTCS-22*. https://doi.org/10.1109/FTCS.1992.243562

Raymond, E. S. (2003). *The art of Unix programming*. Addison-Wesley. http://www.catb.org/esr/writings/taoup/html/ch01s06.html

Röttger, P., Kirk, H. R., Vidgen, B., Attanasio, G., Bianchi, F., & Hovy, D. (2024). XSTest: A test suite for identifying exaggerated safety behaviours in large language models. *NAACL 2024*. https://aclanthology.org/2024.naacl-long.301/

Sarter, N. B., & Woods, D. D. (1997). Team play with a powerful and independent agent: Operational experiences and automation surprises on the Airbus A-320. *Human Factors, 39*(4), 553–569. https://doi.org/10.1518/001872097778667997

Schlichting, R. D., & Schneider, F. B. (1983). Fail-stop processors: An approach to designing fault-tolerant computing systems. *ACM Transactions on Computer Systems, 1*(3), 222–238. https://doi.org/10.1145/357369.357371

Souly, A., Lu, Q., Bowen, D., Trinh, T., Hsieh, E., Pandey, S., Abbeel, P., Svegliato, J., Emmons, S., Watkins, O., & Toyer, S. (2024). *A StrongREJECT for empty jailbreaks*. arXiv:2402.10260. https://arxiv.org/abs/2402.10260

Takehi, R., Hachiuma, R., Ghosh, S., Zhao, D., Wang, Y.-C. F., & Hirota, Y. (2026). *MLLMs fail to refuse when using tools agentically*. arXiv:2610.03938. https://arxiv.org/abs/2610.03938

The Open Group. (2024). *The Open Group Base Specifications Issue 8: IEEE Std 1003.1-2024*, Shell and Utilities, §1.4 Utility Description Defaults. https://pubs.opengroup.org/onlinepubs/9799919799/utilities/V3_chap01.html

Wen, B., Yao, J., Feng, S., Xu, C., Tsvetkov, Y., Howe, B., & Wang, L. L. (2025). Know your limits: A survey of abstention in large language models. *Transactions of the Association for Computational Linguistics, 13*, 529–556. https://doi.org/10.1162/tacl_a_00754

Xie, T., Qi, X., Zeng, Y., Huang, Y., Sehwag, U. M., Huang, K., He, L., Wei, B., Li, D., Sheng, Y., Jia, R., Li, B., Li, K., Chen, D., Henderson, P., & Mittal, P. (2025). SORRY-Bench: Systematically evaluating large language model safety refusal. *ICLR 2025*. https://arxiv.org/abs/2406.14598

Xu, B., & Chen, B. (2026). *Cross-provider review as a runtime contract for coding agents: A controlled pilot and fault-injection study*. arXiv:2610.10961. https://arxiv.org/abs/2610.10961

Yuan, D., Luo, Y., Zhuang, X., Rodrigues, G. R., Zhao, X., Zhang, Y., Jain, P. U., & Stumm, M. (2014). Simple testing can prevent most critical failures. *USENIX OSDI '14*. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/yuan

Zarif, F., Galib, K. S. A., Promi, S. A., Tarin, S. S., Hossain, A., Ahmed, S., & Sadeque, F. Y. (2026). *Ignored, not refused: What low prompt-injection success rates hide in small tool-using agents*. arXiv:2610.23254. https://arxiv.org/abs/2610.23254

Zhao, X., Li, H., Li, S., Zhao, T., Barr, E. T., Sarro, F., & Ye, H. (2026). *Failure as a process: An anatomy of CLI coding agent trajectories*. arXiv:2607.09510. https://arxiv.org/abs/2607.09510

Zhu, J., Xie, S., Chen, A. L. F., Ding, X., Tang, C., Qi, R., & Fei, Y. (2026). *Failure-transparent agents: Benchmarking post-failure reporting in tool-using language models*. arXiv:2609.35732. https://arxiv.org/abs/2609.35732

Sull'autore

Carlos Ulisses Flores è CTO e Ricercatore Capo presso il Codex Hash Research Laboratory, un laboratorio indipendente di R&S a San Paolo, in Brasile. Costruisce sistemi di produzione in cui il fallimento silenzioso è costoso — storicamente nel trading algoritmico, nell'IoT embedded e nella crittografia edge, oggi negli strumenti di IA agentica. Questa nota è nata dall'uso di claude -p come nucleo di esecuzione autonoma e dall'averlo visto restituire exit code 0 davanti a un rifiuto garbato.

Identificatori · ORCID: 0000-0002-6034-7765 · Lattes: 6905246706890561

Contatto · c.ulisses@gmail.com · https://ulissesflores.com