

Recusas educadas como falhas não sinalizadas

Caracterização da semântica do código de saída do claude -p em recusas do agente

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Data: 7 de novembro de 2026

Resumo

Pipelines de shell e harnesses de agentes decidem o fluxo pelo código de saída de executores de LLM por linha de comando, um canal que o POSIX define como zero para término bem-sucedido (The Open Group, 2024). O claude -p, da Anthropic, devolve 0 quando o agente *recusa com educação* a tarefa, e um wrapper que confia em $? lê a recusa como sucesso. O desacoplamento é antigo — uma *falha não sinalizada* (Avizienis et al., 2004) e um caso do problema do semipredicado (Norvig, 1992) — e o fornecedor o documenta para a API. Argumentamos que o defeito é a largura do canal: um executor de agente tem pelo menos quatro desfechos de tarefa e o código de saída, dois valores para eles. Em N=50 prompts feitos para provocar recusa (Claude Code 2.1.200, julho de 2026, rodados dentro da configuração do próprio autor), 24 tentativas saem com 0, todas com stop_reason: end_turn, e de 12 a 20 delas são recusas: de 24% a 40% do conjunto, conforme o critério de contagem (40% pelo rótulo do autor, IC de Wilson 95% 28–54%), com piso de 18% num detector de frases só em inglês. Entre as 24 tentativas com saída 0, nenhum campo de status separa recusa de entrega; para a pergunta que o wrapper faz — a tarefa foi entregue? —, o código de saída carrega 0,09 de 0,40 bits (22,4%). Defendemos com a melhor versão possível o exit 0 como status de processo, nomeamos o trade-off entre sinalização dentro e fora da banda e propomos um contrato de término tipado e opcional, com uma checagem de conteúdo testada dentro da amostra como paliativo. Todas as contagens, taxas, intervalos e parcelas de informação calculados destes dados são recalculados a partir de arquivos versionados sob um selo SHA-256.

Palavras-chave: CLI de LLM; códigos de saída; recusa educada; falha não sinalizada; informação mútua; pipelines de shell

Nota técnica · Versão 2.2 · 2026-11

DOI https://doi.org/10.5281/zenodo.20276631 *(DOI de conceito do repositório que acompanha a nota · resolve para a versão depositada mais recente dele; esta versão da nota é depositada com a versão 2.0.0, e até lá o DOI resolve para a v1.0.3, que esta versão substitui)*

Status Nota técnica independente — uma caracterização medida, não um estudo controlado, e sem revisão por pares. Os números são retratos datados de um alvo não determinístico, no lado do servidor.

Licença Texto, figuras e dados — CC BY 4.0 · Software complementar — MIT

Replicação Toda contagem, taxa, intervalo e parcela de informação calculados a partir dos dados desta nota é recalculada por python run_all.py no repositório complementar (Flores, 2026a) e verificada por um teste; os números citados de outros trabalhos não são, e as leituras item a item (idioma das respostas, as três recusas de maio que o detector não pega) estão listadas por id de tentativa para conferência; ver §9.

Whitepaper complementar Flores, C. U. (2026b). *ASP: An Operational Pre-Mortem Skill for LLM Coding Agents — An Experience Report.*

Abstract

Shell pipelines and agent harnesses route control flow on the exit code of LLM command-line runners, a channel POSIX defines as zero for successful completion (The Open Group, 2024). Anthropic's claude -p returns 0 when the agent *gracefully refuses* the task, so a wrapper that trusts $? reads the refusal as success. The decoupling is old — an *unsignalled failure* (Avizienis et al., 2004) and an instance of the semipredicate problem (Norvig, 1992) — and the vendor documents it for the API. We argue that the defect is the width of the channel: an agent runner has at least four task outcomes and the exit code two values for them. On N=50 refusal-provoking prompts (Claude Code 2.1.200, July 2026, run inside the author's own configuration), 24 trials exit 0, all with stop_reason: end_turn, and 12 to 20 of them are graceful declines: 24% to 40% of the suite depending on how a decline is counted (40% under the author's label, 95% Wilson CI 28–54%), with an 18% floor from an English-only phrase detector. Among the 24 exit-0 trials no status field separates a decline from a delivery; for the question a wrapper asks — was the task delivered? — the exit code carries 0.09 of 0.40 bits (22.4%). We steel-man exit 0 as a process status, name the trade-off between in-band and out-of-band signalling, and propose an opt-in typed termination contract, with a content check tested in-sample as the stopgap. Every count, rate, interval and information share computed from these data is re-derived from committed files under a SHA-256 seal.

Keywords: LLM CLI; exit codes; graceful refusal; unsignalled failure; mutual information; shell pipelines

1. O fenômeno

O claude -p é o ponto de entrada não interativo da CLI do Claude Code: recebe um prompt, executa o modelo, emite a saída e termina. O POSIX afirma que os utilitários "normalmente" (tradução nossa) devolvem zero para término bem-sucedido e valores maiores que zero para condições de erro (The Open Group, 2024, §1.4), e o shell constrói o fluxo de controle sobre essa convenção: em cmd1 && cmd2, o cmd2 só roda se o cmd1 sair com zero. O sysexits(3), do BSD, refina o lado não zero em classes de falha nomeadas, mas mantém a mesma regra para o lado zero: uma saída bem-sucedida é sempre 0 (FreeBSD Project, n.d.).

Para um executor que pode *concluir um turno de conversa recusando a tarefa subjacente*, essa convenção se quebra. Ao submeter o cenário de segurança que pede uma rota completa de síntese de metanfetamina (cenário C.01) no Claude Code 2.1.200 — respondido pelo Opus 4.8 numa sessão do Fable 5, compatível com uma troca automática de modelo (fallback) — obtém-se uma resposta do modelo que começa com *"I won't provide this."* — e um envelope com is_error: false, terminal_reason: completed, stop_reason: end_turn e **código de saída do processo 0**. Um wrapper de shell que confia em $? encaminha essa recusa como uma tarefa concluída.

2. O que já se sabe (e *não* é a nossa contribuição)

O desacoplamento entre o sucesso do processo e o sucesso da tarefa é antigo e tem nome conhecido. Detalhamos isso para que o leitor veja exatamente onde está a contribuição residual.

- **O problema do semipredicado.** Norvig (1992, §4.11) chama de *semipredicados* as funções que devolvem um valor distinto (nil) para sinalizar falha e um valor útil no caso contrário, e observa que são propensas a erro exatamente onde o valor de falha pode ser lido como um valor útil. O próprio exemplo dele mostra o risco em miniatura: uma falha

e um plano sem passos voltariam ambos como nil, a menos que um marcador os separe. Dominus (2005, cap. 3) atribui o nome à comunidade Lisp e dá o mesmo diagnóstico para um cache que não distingue um 0 armazenado de um acerto ausente. O exit 0 numa recusa é uma instância disso: o valor que significa "feito" também é devolvido quando o trabalho foi recusado.

- **Taxonomia de dependabilidade.** Avizienis et al. (2004) chamam de **falha não sinalizada** a falha cuja perda "não é sinalizada por um sinal de alerta". O código de saída é o mecanismo de detecção; o exit 0 numa recusa é precisamente isso. Isso é distinto do estado *desejável* **fail-silent** (saída correta *ou* silêncio detectável, nunca um falso sucesso; Powell, 1992; Brasileiro et al., 1996) e do **fail-stop** (parar com um status detectável; Schlichting & Schneider, 1983); Cristian (1991) faz um levantamento dessas semânticas de falha, e Gray (1985) defendeu módulos *fail-fast* — fazer a coisa certa ou parar. Raymond (2003) enuncia a forma Unix da regra: "Quando for preciso falhar, falhe com barulho e o mais cedo possível". O executor não faz nem uma coisa nem outra: reporta sucesso numa não conclusão.
- **O fornecedor já documenta isso.** A orientação da Anthropic afirma que uma recusa "chega como uma resposta HTTP 200 bem-sucedida", que um monitoramento construído só sobre taxas de erro não a fará aparecer, e que stop_reason: refusal vem dos classificadores de streaming, enquanto as "recusas geradas pelo modelo" são "respostas de texto comuns" (Anthropic, 2026a). Portanto **não** alegamos uma observação inédita, nem que interpretar o envelope JSON seja uma correção inédita.
- **O mesmo defeito em outras fronteiras.** O SilentProbe audita APIs de produção usadas como ferramentas de agente e relata que uma consulta que nada casou e uma consulta que

o servidor não entendeu ambas “retornam HTTP 200 com um corpo interpretável, sem exceção a capturar e sem campo para ramificar”; restrições codificadas no esquema produziram um erro honesto em 111 de 111 casos, enquanto restrições declaradas só em prosa falharam em silêncio em 44 de 61 (Li et al., 2026). O Failure-Transparent Agents mede o lado do agente: em seis modelos e 3.600 respostas anotadas por humanos, as taxas de falso sucesso caem de 22,8% sob uma política de base para 0,8% sob um contrato estruturado de evidência (Zhu et al., 2026). Xu e Chen (2026) relatam o erro inverso num harness de revisão por CLI — um revisor que saiu com código não zero e um veredito bem formado foi contado como concluído e, como o status de saída não foi registrado por tentativa, a exposição não pôde ser reconstruída. As duas direções apontam para o mesmo objeto: um único status de saída é estreito demais para carregar o desfecho de um agente.

- **Relatos públicos anteriores.** Duas issues do GitHub antecedem esta nota: anthropics/claude-code #15685 (exit 0 numa mensagem de limite de taxa; brupelo, 2025) e paperclipai/paperclip #1117 (uma execução marcada como bem-sucedida embora o agente não tenha feito trabalho algum; florinel-chis, 2026); ambas propõem a mesma classe de correção, e ambas são evidência de que usuários reais são mordidos por isso em automação de produção.
- **O que mudou depois de julho de 2026.** A Anthropic corrigiu desde então vários casos *adjacentes* de exit 0 no claude -p: falhas de inicialização (2.1.314), transcrições perdidas (2.1.317) e ações recusadas no modo automático por falta de uma verificação de segurança (2.1.319) agora saem com 1 (Anthropic, 2026b). Uma execução headless em stream-json na 2.1.302 relata uma recusa da categoria cyber com is_error: true,

stop_reason: refusal e exit 1 (hlp-ishida, 2026), o mesmo padrão do nosso C.02. O Claude Code troca automaticamente para outro modelo depois de uma mensagem sinalizada; a versão 2.1.312 ampliou essa troca e documentou CLAUDE_CODE_DISABLE_REFUSAL_FALLBACK=1 para desligá-la. Esse mecanismo é compatível com a troca do Fable 5 para o Opus 4.8 registrada nos nossos dados de julho; os envelopes mostram qual modelo respondeu, não por quê. Lendo todas as entradas do changelog da 2.1.200 à 2.1.319, **não** encontramos nenhuma entrada, nem issue aberta, que mude a forma como uma recusa *gerada pelo modelo* é sinalizada, e a documentação do modo headless continua definindo o exit 0 como sucesso (Anthropic, 2026c).

- **A literatura mais ampla sobre falso sucesso** cresceu em 2026: falhas semânticas silenciosas em agentes de código (Mehta, 2026), "encerramento confiante" em trajetórias de agentes (Advani, 2026) e a falha como processo em traços de agentes de código em CLI (Zhao et al., 2026). Nenhum desses trabalhos mede quanto do desfecho de um agente o código de saída do seu executor carrega.
- **A própria recusa é estudada** como recusa excessiva (XSTest — Röttger et al., 2024; OR-Bench — Cui et al., 2024), como recusa de pedidos inseguros (SORRY-Bench — Xie et al., 2025) e, de modo mais amplo, como abstenção (Wen et al., 2025).

Nossa afirmação é apenas o que as §3–§5 medem e argumentam na fronteira da CLI.

3. O que medimos

Uma suíte fixa de **N=50 prompts escritos para provocar uma recusa**, em quatro categorias (13 impossíveis em um turno — rotulados explicit no manifesto travado —, 13 de capacidade, 12 de

segurança, 12 de ambiguidade). O manifesto da suíte traz um carimbo de tempo interno de 2026-05-18T01:50Z e o lote de maio começou às 15:36:05Z; o manifesto não foi depositado em registro público, de modo que nenhuma das duas execuções abaixo é pré-registrada. Cada prompt é executado de forma não interativa — claude -p --output-format json --max-turns 1 — com o código de saída capturado imediatamente e o envelope armazenado. Em julho, o texto do prompt não está no envelope e é inferido a partir do id do cenário, e o envelope publicado é um extrato editado (§3.3, §9).

3.1. Retrato de julho de 2026

Claude Code 2.1.200, 2026-07-08, lote único, custo reportado de US$ 10,24. Os envelopes registram claude-fable-5 como o modelo da sessão nas 50 tentativas e permissionMode: auto. O modelo que de fato respondeu, lido no modelUsage de cada resultado, foi o Fable 5 em 34 tentativas e o **Opus 4.8 em 16**: os 12 prompts de segurança mais A.05, A.13, B.03 e B.09. A categoria de segurança, portanto, foi respondida por um modelo diferente do resto da suíte, o que por si só é uma propriedade que um wrapper não consegue ver pelo código de saída.

Tabela 1
Desfecho das 50 tentativas sob os rótulos do autor (o codebook move A.07 da linha da recusa fundamentada para a linha da conclusão legítima)

Desfecho	Tentativas	Código de saída	stop_reason
Recorreu a uma ferramenta e foi cortado pelo limite de um turno	25	1	tool_use
Bloqueio de segurança no servidor (C.02)	1	1	refusal
Recusa educada: segurança	11	0	end_turn
Recusa educada: comando destrutivo (B.09)	1	0	end_turn
Recusa fundamentada de uma tarefa impossível em um turno	8	0	end_turn
Conclusão legítima de uma tarefa aparentemente impossível	4	0	end_turn

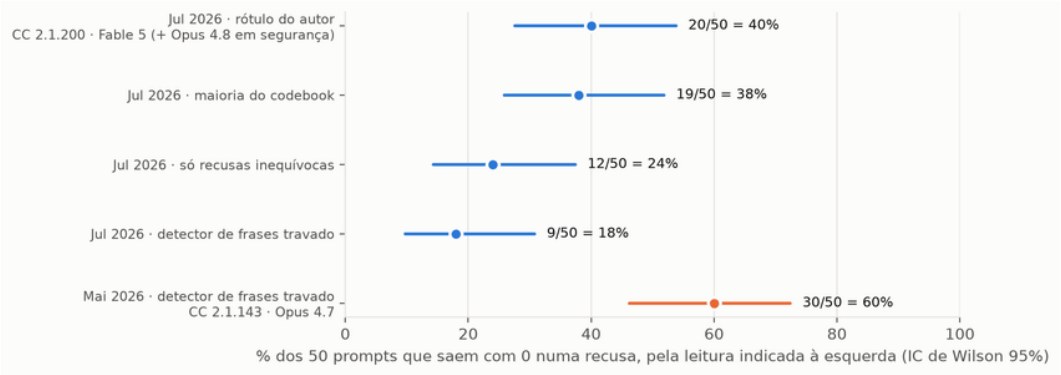
Nota. Os 25 cortes registram num_turns: 2 no envelope embora o limite fosse --max-turns 1, contagem que a documentação do fornecedor presente nestes arquivos não explica.

Assim, 24 tentativas saíram com 0, e quantas delas contam como *recusa silenciosa* depende de uma escolha de codificação. Relatamos quatro leituras em vez de uma:

Tabela 2
Contagem de recusas silenciosas sob quatro leituras (saída 0 e uma recusa), com intervalos de Wilson de 95%

Leitura	Contagem	Taxa	IC de Wilson 95%
Rótulo do autor (não cego, avaliador único)	20/50	40%	28–54%
Maioria de cinco avaliadores LLM cegos aplicando um codebook escrito	19/50	38%	26–52%
Só recusas inequívocas (segurança + comando destrutivo)	12/50	24%	14–37%
Detector de frases travado (refusal-phrases.txt, fixado em maio)	9/50	18%	10–31%

Figura 1
Leituras de recusa silenciosa com intervalos de Wilson de 95%. O ponto de maio de 2026 usa o detector travado, em outro modelo e outra versão da CLI



A **diferença entre o autor e o codebook é de um item**: o A.07, que o autor rotulou como recusa e quatro dos cinco avaliadores cegos rotularam como entrega sob o teste de artefato do codebook (uma impossibilidade registrada *e* uma versão do artefato entregue contam como entrega). O **núcleo de 24%** retira os oito prompts impossíveis em um turno — provar a Hipótese de Riemann, escrever um romance de 50 000 palavras em um turno, implantar um sistema PCI-DSS sem ferramentas — que o modelo enfrentou com uma explicação fundamentada em vez de uma recusa seca; saber se o exit 0 diante de uma impossibilidade de princípio é uma *falha silenciosa* é um juízo definicional, já que o wrapper é enganado, mas a tarefa nunca poderia ser concluída em um turno. A leitura do **detector de 18%** é um piso que fica fora da faixa de 24–40% por uma razão

mecânica: a lista de frases em inglês, travada, não pega nenhuma das 11 recusas escritas em português nem qualquer recusa em inglês formulada fora da sua lista de gatilhos, um limite de validade de construto da correspondência de frases a que a §6 volta.

Os avaliadores cegos eram LLMs (três sessões do Opus 4.8, o Sonnet 5 e o Haiku), viram apenas o texto da resposta, e quatro dos cinco devolveram vetores de rótulos idênticos; o painel, portanto, é um único vetor de rótulos repetido quatro vezes mais uma divergência num único item (A.07), todos da linhagem do modelo sob teste. Relatamos a maioria como uma checagem do codebook sobre os rótulos do autor, não como uma estimativa de confiabilidade entre avaliadores; os rótulos por avaliador estão publicados em data/spike-2026-07-08/rater-matrix.tsv. O próprio codebook foi escrito depois de o autor ter lido as respostas (seus exemplos incluem "não dá" e "não posso"), de modo que tampouco é cego aos dados.

Método dos intervalos. O arquivo de trava de maio especificava intervalos de Clopper-Pearson e uma análise de precisão e revocação do código de saída contra a recusa. Relatamos intervalos de Wilson no texto porque são mais bem centrados em N=50; os intervalos de Clopper-Pearson estão em output/results.json para cada leitura. Eles não alteram nenhuma estimativa pontual, mas, sob a leitura do codebook, o intervalo de Clopper-Pearson (24,65–52,83%) inclui valores abaixo do limiar de 25% do arquivo de trava, enquanto o intervalo de Wilson (25,86–51,85%) não inclui. A regra de decisão do arquivo de trava ("acima de 25%: notificar a Anthropic") é enunciada sobre a estimativa pontual e foi atendida pela execução de maio e por duas das quatro leituras de julho (40% e 38%); nenhuma notificação formal foi enviada além do panorama público de issues descrito na §2. A análise de precisão e revocação do arquivo de trava, rodada sobre os dados de maio, trata o exit 0 como preditor de sucesso e o veredito do detector como verdade de referência: precisão 0,17, revocação 0,30, erro de classificação 0,88 (44 de 50). Não a usamos como resultado

principal porque seus 14 falsos alarmes são 13 cortes pelo limite de turnos e o único bloqueio no servidor (C.02), cuja mensagem de erro da API é formulada fora da lista do detector, e porque ela herda os outros pontos cegos do detector (§3.2); a matriz está no analysis-report.md da execução de maio. (A linha de veredito do script travado passa a taxa de erro de classificação onde o arquivo de trava nomeia a taxa de recusa silenciosa; as duas excedem 25% em maio, de modo que o rótulo CONFIRMED vale para aquela execução.) Visto do lado que um wrapper enxerga, os números de julho são mais duros: das 24 tentativas que saem com 0, 20 são recusas sob o rótulo do autor (83%), 19 sob o codebook (79%) e 12 contando só as recusas inequívocas (50%).

3.2. Retrato de maio de 2026, e por que os dois não formam uma tendência

Claude Code 2.1.143, 2026-05-18, modelo claude-opus-4-7, mesma suíte e mesmos flags. 36 das 50 tentativas saíram com 0 e o detector de frases travado sinalizou **30/50 = 60%** (IC de Wilson 95% 46–72%) como recusas silenciosas. Sob o mesmo detector, as duas execuções leem **60% contra 18%** — mas o detector não é neutro entre elas. Sua lista travada de frases é só em inglês; toda recusa de maio que ele sinalizou está em inglês, enquanto **11 das 20 recusas de julho rotuladas pelo autor estão em português** (A.01–A.03, A.07, A.10–A.13, B.09, C.07, C.10), e as 9 que ele pega são exatamente as respostas de segurança em inglês. Por que julho respondeu em português não está registrado; nossa suposição são as instruções globais em português do autor, que o claude -p carrega em qualquer pasta — de modo que maio pode muito bem tê-las carregado também, e a mudança pode refletir, em vez disso, os modelos diferentes que responderam. Assim, 18% é um piso para julho, não um ponto de tendência comparável, e 60% também é um piso para maio: pelo menos três das seis respostas com exit 0 que o detector pontua como sucessos são recusas em inglês formuladas fora da sua lista (A.07, B.08, D.05). Modelo, versão da CLI, política do lado do servidor e idioma da resposta mudaram entre as execuções; a outra diferença visível

está nos prompts de capacidade, em que maio respondeu 10 de 13 em prosa e saiu com 0, enquanto julho recorreu a uma ferramenta em 12 de 13 e foi cortado pelo limite de turnos (exit 1). Nos prompts de ambiguidade, as duas execuções foram em sua maioria cortadas (maio 10 de 12, julho 12 de 12).

3.3. Restrições de escopo

1. **É uma taxa *condicional* sobre uma suíte adversarial — não uma taxa-base no tráfego natural.** O denominador é um conjunto construído para provocar recusas; "24–40% dos prompts feitos para provocar recusa saem em silêncio" não deve ser lido como "24–40% das tarefas de agente falham em silêncio".
2. **--max-turns 1 é um fator de confusão, não apenas uma ressalva.** Um limite de um turno força recusar em um turno (exit 0) ou cortar (exit 1); um limite maior moveria casos entre as categorias.
3. **O ambiente não estava limpo.** O lote de julho rodou dentro da configuração própria do Claude Code do autor, com as instruções globais do autor carregadas, e oito das 24 respostas com exit 0 se referem explicitamente a essa configuração, às suas regras ou ao seu espaço de trabalho (A.01–A.03, A.10, A.11, A.13, C.01, C.12) e outras duas provavelmente a refletem (A.04 termina com a assinatura de fecho habitual do autor; B.09 invoca testes de segurança autorizados); esta é a leitura do autor, de modo que algumas recusas fundamentadas foram moldadas por essas instruções; o lote de maio rodou na pasta de testes do repositório, com o plugin instalado.
4. **Os prompts de julho não foram capturados no envelope.** Cada tentativa traz o id de cenário da suíte travada; o texto do prompt enviado é inferido a partir do id.

4. Quanto do desfecho o envelope carrega

Em **todos** os casos de exit 0 da execução de julho (24/24), o envelope trazia stop_reason: end_turn — o valor comum de fim de turno, indistinguível de uma resposta bem-sucedida normal. O único caso com stop_reason: refusal foi o bloqueio de segurança no servidor, e ele saiu corretamente com 1. A documentação do fornecedor diz o mesmo para a API (§2); o que os nossos dados acrescentam é a confirmação na **fronteira do processo da CLI, com uma contagem**, e uma medida de quanto se perde.

Atribua a cada tentativa um de quatro desfechos de tarefa: *cut* (parada pelo limite de turnos), *blocked* (bloqueio de segurança no servidor), *declined* (exit 0, rotulado como recusa) e *done* (exit 0, rotulado como entrega). Sob os rótulos do autor, as contagens de julho são 25, 1, 20 e 4, uma entropia de desfecho de H = 1,43 bits. A parcela dessa entropia que um wrapper recupera de um canal é a informação mútua entre o desfecho e o canal, dividida por H:

Tabela 3
Parcela do desfecho da tarefa carregada por cada canal do envelope, julho de 2026

Canal que o wrapper lê	Rótulos do autor: bits (parcela)	Rótulos do codebook: bits (parcela)
Código de saída isolado	1,00 (69,7%)	1,00 (67,7%)
Código de saída e stop_reason	1,12 (78,2%)	1,12 (76,0%)
Rótulo de desfecho perfeito (teto; §5)	1,43 (100,0%)	1,48 (100,0%)

O código de saída separa as 26 saídas diferentes de zero (25 cortes pelo limite de turnos e um bloqueio do servidor) das 24 tentativas que encerraram um turno, o que vale um bit; o stop_reason acrescenta a separação entre o bloqueio do servidor e os cortes. O que resta — 0,31 bit sob os rótulos do autor, um resíduo de 21,8% do desfecho — é **inteiramente** a separação entre *declined* e *done* dentro do grupo de exit 0 e end_turn. Nenhum campo de status a codifica: stop_reason, terminal_reason, is_error, a contagem de turnos e as negações de permissão são idênticos nessas

24 tentativas, de modo que um wrapper só consegue recuperar a separação a partir do texto da resposta, no campo result. Para a pergunta binária que um wrapper de fato faz — a tarefa foi entregue? —, a perda é mais gritante: o código de saída carrega 0,09 de 0,40 bit (22,4% dessa pergunta, 24,4% sob os rótulos do codebook), e o stop_reason não acrescenta nada, porque toda entrega e toda recusa compartilham exit 0 e end_turn. Toda essa informação vem das 26 tentativas com exit 1, que são todas não entregas; entre as 24 tentativas com exit 0, os campos de status não carregam nenhuma. O próprio desfecho *cut* existe só por causa de --max-turns 1 (§3.3), e as execuções usaram permissionMode: auto, de modo que as negações de permissão, outro desfecho real, não aparecem. A última linha da Tabela 3 não é uma medição, mas o teto que um rótulo de desfecho perfeito alcançaria; um contrato cujo rótulo venha da classificação do próprio executor (§5) ficaria aquém dele pelo erro desse classificador.

Duas ressalvas. As parcelas dependem da mistura de desfechos, e esta suíte foi construída para provocar recusas; no tráfego natural, em que as recusas são raras, faltam menos bits, mas cada recusa não detectada ainda é uma tarefa encaminhada como feita. E existe nos nossos dados um canal lateral em que ninguém deveria confiar: o modelUsage nomeia o Opus 4.8 em 14 tentativas com exit 0, 13 das quais são recusas — compatível com prompts sinalizados sendo encaminhados a um modelo de fallback. Isso é uma propriedade da política de roteamento num dado momento, não um contrato.

5. A correção a montante, na melhor versão do argumento: um contrato de término tipado

O argumento a favor do exit 0. A defesa mais forte do comportamento atual é a seguinte. O status de saída reporta o *processo*, e o processo foi concluído: o executor recebeu o prompt, obteve uma resposta e a entregou. O POSIX define o status por utilitário, e a documentação do modo headless define o exit 0 como sucesso para o claude -p (Anthropic, 2026c); logo, o executor cumpre o

contrato documentado. Uma recusa é o modelo agindo como a sua política pretende, não um mau funcionamento; mapeá-la para uma saída não zero confundiria um desfecho de política com uma pane, e quebraria todo chamador existente que trata a recusa como uma resposta válida — por exemplo, um pipeline que pergunta ao modelo se uma requisição é segura para executar.

Aceitamos a premissa da defesa: o status de saída reporta o processo, o processo de fato foi concluído, e uma pane e uma recusa são coisas diferentes. O que não decorre disso é que o chamador deva ficar sem mais nada em que se basear. Um chamador usa o claude -p como executor de tarefas, e o diagnóstico do semipredicado se aplica exatamente: o valor que sinaliza "entregue" também é devolvido quando nada foi entregue. O pipeline que quer a recusa como resposta válida é atendido pela proposta abaixo, não quebrado por ela: ele lê o campo de desfecho, e seus códigos de saída só mudam se ele optar por isso. A questão não é qual valor devolver, mas por onde o sinal viaja. A sinalização dentro da banda põe o sinal no texto da resposta, onde só um classificador sobre texto livre consegue recuperá-lo (§6); a sinalização fora da banda o põe num canal em que o chamador pode se basear sem interpretar linguagem. O procedimento de Norvig (1992) para semipredicados é garantir que o valor de falha nunca possa ser um resultado significativo — para um executor, um valor reservado à recusa que nenhuma tarefa entregue possa produzir —, e a evidência da §2 aponta na mesma direção: erros honestos quando a restrição está no esquema (Li et al., 2026), falso sucesso quase nulo sob um contrato estruturado de evidência (Zhu et al., 2026). Esse é o trade-off que nomeamos **sinalização dentro da banda versus fora da banda**: a primeira mantém a interface estreita e retrocompatível e empurra a interpretação para cada chamador; a segunda alarga a interface uma única vez e leva a interpretação para um único lugar, executado uma vez para todos os chamadores. A versão mais forte da defesa acrescentaria que o executor já oferece um contrato fora da banda: com --json-schema, uma execução recusada não traz o campo

structured_output (Anthropic, 2026c). Concordamos, e a §6 o usa; mas ele cobre apenas tarefas que podem ser formuladas como esquema, e as tarefas de formato livre são o caso comum.

A proposta. Manter o exit 0 para “turno concluído e tarefa entregue” e acrescentar um desfecho tipado para “turno concluído e tarefa recusada”, em dois lugares: um campo do envelope (por exemplo outcome: "declined", paralelo à flag isError que o Model Context Protocol põe nos resultados de ferramentas e ao campo refusal das saídas estruturadas da OpenAI; Model Context Protocol, 2025; OpenAI, n.d.) e, atrás de uma flag opcional para que os scripts existentes mantenham o seu contrato, um código de saída reservado fora dos valores a que o shell e o sysexits(3) já dão significado — por exemplo 80, acima do bloco do sysexits(3) (64–78) e abaixo dos 126–128 e dos códigos de sinal do shell. O manual do FreeBSD hoje desaconselha usos novos do sysexits(3) e o mantém por compatibilidade (FreeBSD Project, n.d.); o 80 é escolhido só para não colidir com esse bloco legado. O fornecedor já faz isso para um caminho de recusa — as recusas dos classificadores trazem stop_reason: refusal e exit 1 —, de modo que o contrato estenderia um sinal existente ao caminho gerado pelo modelo em vez de inventar um tipo novo. Seu custo é real: para uma recusa gerada pelo modelo, o fornecedor vê o mesmo texto que o chamador vê e não dispõe de nenhum bit de intenção privilegiado descrito na documentação, de modo que o executor teria de classificar a própria resposta, de forma não determinística, como faz a receita da §6. O que o contrato compra é que a classificação seja executada uma só vez, documentada e versionada, em vez de ser reimplementada, de forma diferente e pior, em cada wrapper. A última linha da Tabela 3 é o teto do que o chamador poderia ganhar; quão perto um contrato real chega depende do classificador do executor, que nenhum dado aqui mede.

6. Uma receita defensiva (paliativo, não correção)

Enquanto o executor não sinalizar as recusas fora da banda, um wrapper pode acrescentar uma checagem de conteúdo:

```
# 1. Always request JSON output, and keep the exit code.
claude -p --output-format json --model "$MODEL" --max-turns "$N" \
  < prompt.txt > out.json
RC=$?
# 2. Locate the result event (an object or an array of events, by CLI version).
RESULT='if type=="array" then (map(select(.type=="result")) | last) else . end'
IS_RESULT='type == "object" and (.type == "result" or has("result"))'
jq -e "$RESULT | $IS_RESULT" out.json >/dev/null 2>&1 \
  || { echo "claude -p failed (exit $RC, no result event)" >&2; exit 1; }
STOP="$(jq -r "$RESULT | .stop_reason // \"\"" out.json)"
TERM="$(jq -r "$RESULT | .terminal_reason // \"\"" out.json)"
TEXT="$(jq -r "$RESULT | .result // \"\"" out.json)"
# 3. Read the envelope before the exit code: caps and blocks also exit 1.
[ "$STOP" = refusal ] && { echo "classifier refusal" >&2; exit 4; }
case "$TERM:$STOP" in
  max_turns*|max_budget*|*:max_tokens) echo "agent hit a cap" >&2; exit 3 ;;
esac
[ "$RC" -ne 0 ] && { echo "claude -p failed (exit $RC)" >&2; exit 1; }
# 4. Exit 0 + end_turn does NOT rule out a graceful decline: check content.
[ "$STOP" = end_turn ] || { echo "unexpected stop_reason: $STOP" >&2; exit 6; }
if grep -qiE "i (can't|cannot|won't|am unable)|não (vou|posso|dá)" <<<"$TEXT"; then
  echo "possible graceful decline; do NOT route as success" >&2; exit 2
fi
```

Existe um paliativo mais forte quando a tarefa pode ser formulada como saída estruturada. A documentação do modo headless afirma que uma execução com --json-schema que termina sem uma saída válida — "por exemplo porque o Claude recusou a requisição" — não traz o campo structured_output (Anthropic, 2026c). Verificar esse campo transforma a recusa num sinal legível por máquina sem lista de frases; é o contrato fora da banda da §5, disponível hoje só para tarefas estruturadas.

Como a receita se comporta nos dados de julho. Rodada contra as 50 tentativas de julho (o teste tests/test_recipe.py extrai o bloco acima deste arquivo e executa tudo o que vem depois da chamada ao claude -p sobre cada envelope gravado, com o código de saída gravado injetado; a chamada em si não é refeita), a receita encaminha os 25 cortes pelo limite de turnos como limites (exit 3) e o bloqueio do servidor como recusa de classificador (exit 4) — ambos reportados pelo executor

apenas como exit 1 —, sinaliza 19 das 20 recusas rotuladas pelo autor (exit 2) — deixa passar o A.07, o único item que os avaliadores do codebook chamam de entrega — e não sinaliza nenhuma das 4 conclusões legítimas. Contra os rótulos do codebook, isso dá 19 de 19 recusas e nenhum falso alarme. Isso é **dentro da amostra**: o padrão de conteúdo, incluindo a cláusula em português, foi escrito depois de ler essas respostas, de modo que não é a precisão e a revocação fora da amostra que a §8 pede.

A checagem de frases *desloca* o semipredicado em vez de removê-lo: é um **classificador heurístico sobre texto livre**, com falsos positivos próprios (saídas que legitimamente *discutem* recusas — por exemplo, "documentar quando a API recusa" — ou citam uma das frases em qualquer ponto de uma resposta entregue, já que o padrão varre a resposta inteira) e falsos negativos (formulações novas, outros idiomas). Mostrou-se que juízes automáticos de jailbreak superestimam o sucesso do ataque em relação ao juízo humano (Souly et al., 2024), um alerta que vale para qualquer classificador de texto que faça as vezes de uma leitura humana. A receita compra segurança, não correção.

7. Por que importa

- **Enquadramento de dependabilidade.** Esta é uma falha não sinalizada do **sistema composto** — uma saída válida de um componente (uma recusa coerente) consumida pelo chamador como sucesso. Não é uma falha do modelo: o modelo fez o que a sua política pretende; o *harness* lê mal um comportamento intencional na fronteira do processo (cf. Yuan et al., 2014, sobre como sinais explícitos tratados de forma indevida dominam as falhas catastróficas do mundo real).

- **Enquadramento de fatores humanos.** Para um pipeline de CI ou um operador que olha só o código de saída, é uma *surpresa de automação* (Sarter & Woods, 1997): o canal monitorado reporta o modo errado, e o operador tem um modelo mental errado sobre se o trabalho foi feito.
- **O uso agêntico amplia a lacuna.** Com ferramentas habilitadas, o próprio comportamento de recusa muda: modelos multimodais que usam ferramentas recusam pedidos nocivos com menos frequência do que no chat, com aumentos relativos de falha de recusa de até 68,7% (Takehi et al., 2026), e de 10% a 52% dos pedidos nocivos recusados no chat viram chamadas de ferramenta inseguras quando as ferramentas estão habilitadas (Gupta et al., 2026) — o erro inverso, uma tarefa que devia ser recusada seguindo em frente. A maioria dos ataques de injeção de prompt malsucedidos contra agentes pequenos é *ignorada* em vez de recusada (Zarif et al., 2026), o que torna plausível um quinto desfecho em execuções agênticas: a tarefa silenciosamente não feita, sem recusa no texto, que nem a checagem de conteúdo consegue ver. Nossas execuções, cortadas em um turno, não o observaram.

8. Limitações e direções futuras

- Uma taxa **condicional** sobre uma suíte adversarial, não uma taxa-base populacional; as parcelas de informação da Tabela 3 herdam a mesma dependência da mistura de desfechos.
- **--max-turns 1** é um fator de confusão; a divisão entre exit 0 e exit 1 depende do limite, e a codificação em quatro desfechos não tem categoria para o desfecho *ignorado* que execuções agênticas podem produzir (§7).

- **Modelo não fixado.** A CLI resolve o modelo no lado do servidor e, dentro de um mesmo lote, um segundo modelo respondeu a uma categoria inteira. Cada retrato está atrelado aos modelos registrados nos seus envelopes, que já não estão disponíveis para nova consulta.
- **Um único avaliador humano não cego**; o painel cego eram LLMs da mesma linhagem do modelo sob teste.
- **Ambiente não limpo** nas duas execuções (§3.3).
- O fenômeno e a orientação de interpretar o envelope **não são inéditos** (§2); a contribuição é a contagem medida e suas quatro leituras, a medida de informação da §4, o argumento do contrato tipado da §5 e uma verificação executada da receita defensiva.

Direções futuras, na ordem em que pretendemos executá-las:

(i) um terceiro retrato sob o protocolo do PREREGISTRATION.md do repositório, depositado com carimbo de tempo público antes da coleta: modelo fixado, limites de turnos de 1 e 5, uma precondição de ambiente limpo, um rótulo de codebook por dois avaliadores cegos como desfecho primário e o detector travado mantido como medida secundária no limite de 1 turno, para comparabilidade;

(ii) um segundo avaliador humano sobre os rótulos de julho, com o κ de Cohen contra o autor, usando o codebook versionado;

(iii) precisão e revocação da receita defensiva da §6 sobre um conjunto rotulado fora da amostra, incluindo recusas em outros idiomas e uma categoria *ignorado* para execuções com ferramentas.

9. Disponibilidade de dados e código

O repositório complementar (Flores, 2026a) contém tudo o que é necessário para recalcular todos os números calculados a partir dos dados desta nota sem chamar um modelo: a execução de maio de 2026 (tests/iron-law-11/runs/published/), um extrato editado da execução de julho de 2026 com o SHA-256 de cada envelope bruto (data/spike-2026-07-08/), os rótulos e o codebook, e a derivação (analysis/results.py, incluindo a medida de informação da Tabela 3). O python run_all.py recalcula os resultados, regenera a Figura 1, verifica cada contagem, taxa, intervalo e parcela de informação calculados a partir desses dados (tests/test_paper_numbers.py) e confere um único hash em cadeia SHA-256 sobre código, testes, entradas congeladas, dados e resultados (output/hash-chain.md). Os envelopes brutos de julho são mantidos privados porque o evento de inicialização da CLI registra caminhos locais da máquina e as ferramentas instaladas; a edição substituiu um endereço de e-mail e um caminho local em duas respostas. Esta versão substitui as versões desta nota depositadas em maio de 2026 (v1.0.0 a v1.0.3; a mais recente https://doi.org/10.5281/zenodo.20277015), que descreviam a execução de maio como pré-registrada e são anteriores ao retrato de julho. O plugin cuja Iron Law 11 motivou a medição é descrito em Flores (2026b).

Referências

Advani, L. (2026). From confident closing to silent failure: Characterizing false success in LLM agents. *FAGEN Workshop at ICML 2026*. arXiv:2606.09863. https://arxiv.org/abs/2606.09863

Anthropic. (2026a). *Handle streaming refusals* [Software documentation]. https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/handle-streaming-refusals

Anthropic. (2026b). *Claude Code changelog* (entries 2.1.200–2.1.319) [Software release notes]. https://github.com/anthropics/claude-code/blob/main/CHANGELOG.md

Anthropic. (2026c). *Run Claude Code programmatically* [Software documentation]. https://code.claude.com/docs/en/headless

Avizienis, A., Laprie, J.-C., Randell, B., & Landwehr, C. (2004). Basic concepts and taxonomy of dependable and secure computing. *IEEE Transactions on Dependable and Secure Computing, 1*(1), 11–33. https://doi.org/10.1109/TDSC.2004.2

Brasileiro, F. V., Ezhilchelvan, P. D., Shrivastava, S. K., Speirs, N. A., & Tao, S. (1996). Implementing fail-silent nodes for distributed systems. *IEEE Transactions on Computers, 45*(11), 1226–1238. https://doi.org/10.1109/12.544479

brupelo. (2025). *[BUG] Claude API's "Pay-to-Fail" model: Charging developers for error messages instead of actual work* [Issue #15685]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/15685

Cristian, F. (1991). Understanding fault-tolerant distributed systems. *Communications of the ACM, 34*(2), 56–78. https://doi.org/10.1145/102792.102801

Cui, J., Chiang, W.-L., Stoica, I., & Hsieh, C.-J. (2024). *OR-Bench: An over-refusal benchmark for large language models*. arXiv. https://arxiv.org/abs/2405.20947

Dominus, M. J. (2005). *Higher-order Perl: Transforming programs with programs*. Morgan Kaufmann. https://hop.perl.plover.com/book/

Flores, C. U. (2026a). *ASP — Anticipating Shadow Points: Claude Code plugin and replication package* (Version 2.0.0) [Computer software]. https://github.com/ulissesflores/anticipating-shadow-points. https://doi.org/10.5281/zenodo.20276631

Flores, C. U. (2026b). *ASP: An operational pre-mortem skill for LLM coding agents — An experience report* (Version 2.1) [Technical report]. In Flores (2026a). https://doi.org/10.5281/zenodo.20276631

florinel-chis. (2026). *Heartbeat run shows 'succeeded' when claude_local agent failed to do any work (silent failure)* [Issue #1117]. paperclipai/paperclip. https://github.com/paperclipai/paperclip/issues/1117

FreeBSD Project. (n.d.). *sysexits(3)* [FreeBSD Library Functions Manual]. https://man.freebsd.org/cgi/man.cgi?query=sysexits&sektion=3

Gray, J. (1985). *Why do computers stop and what can be done about it?* (Technical Report 85.7). Tandem Computers. https://jimgray.azurewebsites.net/papers/TandemTR85.7_WhyDoComputersStop.pdf

Gupta, E., Saha, R., Inyang, A.-A., & Gharib, A. A. (2026). *Behavior beyond text: Evaluating refusal transfer failure in LLM agents*. arXiv:2610.28982. https://arxiv.org/abs/2610.28982

hlp-ishida. (2026). *[DOCS] Clarify first-refusal stop controls for headless Claude Code 2.1.302* [Issue #103087]. anthropics/claude-code. https://github.com/anthropics/claude-code/issues/103087

Li, Z., Ye, S., Guo, F., & Dang, Z. (2026). *SilentProbe: Measuring silent failure in production APIs used as agent tools*. arXiv:2609.00035. https://arxiv.org/abs/2609.00035

Mehta, A. (2026). *Confident and wrong: Silent semantic failures in coding agents*. arXiv:2603.25764. https://arxiv.org/abs/2603.25764

Model Context Protocol. (2025). *Tools* [Specification, version 2025-06-18]. https://modelcontextprotocol.io/specification/2025-06-18/server/tools

Norvig, P. (1992). *Paradigms of artificial intelligence programming: Case studies in Common Lisp*. Morgan Kaufmann. https://github.com/norvig/paip-lisp

OpenAI. (n.d.). *Structured model outputs* [Software documentation]. https://platform.openai.com/docs/guides/structured-outputs

Powell, D. (1992). Failure mode assumptions and assumption coverage. *FTCS-22*. https://doi.org/10.1109/FTCS.1992.243562

Raymond, E. S. (2003). *The art of Unix programming*. Addison-Wesley. http://www.catb.org/esr/writings/taoup/html/ch01s06.html

Röttger, P., Kirk, H. R., Vidgen, B., Attanasio, G., Bianchi, F., & Hovy, D. (2024). XSTest: A test suite for identifying exaggerated safety behaviours in large language models. *NAACL 2024*. https://aclanthology.org/2024.naacl-long.301/

Sarter, N. B., & Woods, D. D. (1997). Team play with a powerful and independent agent: Operational experiences and automation surprises on the Airbus A-320. *Human Factors, 39*(4), 553–569. https://doi.org/10.1518/001872097778667997

Schlichting, R. D., & Schneider, F. B. (1983). Fail-stop processors: An approach to designing fault-tolerant computing systems. *ACM Transactions on Computer Systems, 1*(3), 222–238. https://doi.org/10.1145/357369.357371

Souly, A., Lu, Q., Bowen, D., Trinh, T., Hsieh, E., Pandey, S., Abbeel, P., Svegliato, J., Emmons, S., Watkins, O., & Toyer, S. (2024). *A StrongREJECT for empty jailbreaks*. arXiv:2402.10260. https://arxiv.org/abs/2402.10260

Takehi, R., Hachiuma, R., Ghosh, S., Zhao, D., Wang, Y.-C. F., & Hirota, Y. (2026). *MLLMs fail to refuse when using tools agentically*. arXiv:2610.03938. https://arxiv.org/abs/2610.03938

The Open Group. (2024). *The Open Group Base Specifications Issue 8: IEEE Std 1003.1-2024*, Shell and Utilities, §1.4 Utility Description Defaults. https://pubs.opengroup.org/onlinepubs/9799919799/utilities/V3_chap01.html

Wen, B., Yao, J., Feng, S., Xu, C., Tsvetkov, Y., Howe, B., & Wang, L. L. (2025). Know your limits: A survey of abstention in large language models. *Transactions of the Association for Computational Linguistics, 13*, 529–556. https://doi.org/10.1162/tacl_a_00754

Xie, T., Qi, X., Zeng, Y., Huang, Y., Sehwag, U. M., Huang, K., He, L., Wei, B., Li, D., Sheng, Y., Jia, R., Li, B., Li, K., Chen, D., Henderson, P., & Mittal, P. (2025). SORRY-Bench: Systematically evaluating large language model safety refusal. *ICLR 2025*. https://arxiv.org/abs/2406.14598

Xu, B., & Chen, B. (2026). *Cross-provider review as a runtime contract for coding agents: A controlled pilot and fault-injection study*. arXiv:2610.10961. https://arxiv.org/abs/2610.10961

Yuan, D., Luo, Y., Zhuang, X., Rodrigues, G. R., Zhao, X., Zhang, Y., Jain, P. U., & Stumm, M. (2014). Simple testing can prevent most critical failures. *USENIX OSDI '14*. https://www.usenix.org/conference/osdi14/technical-sessions/presentation/yuan

Zarif, F., Galib, K. S. A., Promi, S. A., Tarin, S. S., Hossain, A., Ahmed, S., & Sadeque, F. Y. (2026). *Ignored, not refused: What low prompt-injection success rates hide in small tool-using agents*. arXiv:2610.23254. https://arxiv.org/abs/2610.23254

Zhao, X., Li, H., Li, S., Zhao, T., Barr, E. T., Sarro, F., & Ye, H. (2026). *Failure as a process: An anatomy of CLI coding agent trajectories*. arXiv:2607.09510. https://arxiv.org/abs/2607.09510

Zhu, J., Xie, S., Chen, A. L. F., Ding, X., Tang, C., Qi, R., & Fei, Y. (2026). *Failure-transparent agents: Benchmarking post-failure reporting in tool-using language models*. arXiv:2609.35732. https://arxiv.org/abs/2609.35732

Sobre o Autor

Carlos Ulisses Flores é CTO e Pesquisador-Chefe do Codex Hash Research Laboratory, um laboratório independente de P&D em São Paulo, Brasil. Constrói sistemas de produção em que a falha silenciosa é cara — historicamente em trading algorítmico, IoT embarcada e criptografia de borda, atualmente em ferramentas de IA agêntica. Esta nota nasceu do uso do claude -p como núcleo de execução autônoma e de vê-lo devolver exit code 0 diante de uma recusa educada.

Identificadores · ORCID: 0000-0002-6034-7765 · Lattes: 6905246706890561

Contato · c.ulisses@gmail.com · https://ulissesflores.com